

# Fundamentos de ciencia de datos con R - Módulo 2

Clase 2: `select()` y `filter()`

CEPAL - Unidad de Estadísticas Sociales

2026-01-07

# Introducción

## Enfoque de esta sección

- ▶ Manipulación de datos con `dplyr`.
- ▶ Uso de `select()` para elegir variables.
- ▶ Uso de `filter()` para seleccionar observaciones.
- ▶ Ambas funciones se combinan frecuentemente con el operador `%>%`.

# Lectura de base de ejemplos

```
datos <- readRDS("data/base_personas_gasto.rds")
library(dplyr)
```

```
glimpse(datos)
```

Rows: 19,427

Columns: 17

```
$ id_hogar    <dbl> 262, 262, 265, 265, 265, 277, 277, 277, 277, 288, 288, 288,-
$ id_pers     <dbl> 1, 2, 1, 2, 3, 1, 2, 3, 4, 1, 2, 3, 4, 1, 2, 3, 4, 5, 1, 2,-
$ upm         <dbl> 1100100006, 1100100006, 1100100006, 1100100006, 1100100006,-
$ estrato     <dbl> 11001, 11001, 11001, 11001, 11001, 11001, 11001, 11001, 110-
$ area        <chr> "1", "1", "1", "1", "1", "1", "1", "1", "1", "1", "1", "1",-
$ fep         <dbl> 19, 19, 16, 16, 16, 16, 16, 16, 19, 19, 19, 19, 30, 30,-
$ pobreza     <chr> "3", "3", "3", "3", "3", "3", "3", "3", "3", "3", "3", "3",-
$ ingreso_hh  <dbl> 10783.053, 10783.053, 21259.723, 21259.723, 21259.723, 9618-
$ gasto_hh    <dbl> 10783.053, 10783.053, 21259.723, 21259.723, 21259.723, 9618-
$ parentesco  <chr> "1", "2", "1", "2", "3", "1", "3", "3", "3", "1", "2", "3",-
$ edad        <dbl> 51, 46, 26, 24, 7, 42, 20, 17, 13, 60, 32, 13, 5, 39, 31, 1-
$ sexo        <fct> Hombre, Mujer, Mujer, Hombre, Hombre, Mujer, Mujer, Hombre,-
$ etnia       <fct> 0, 0, 0, 0, 1, 0, 1, 1, 1, 0, 0, 0, 0, 0, 0, 0, 0,-
$ anoest      <dbl> 18, 12, 17, 15, 0, 15, 13, 8, 5, 10, 12, 7, 0, 12, 12, 6, 0-
$ niveduc_ee  <hvn_lbl> 7, 5, 7, 6, 1, 6, 6, 4, 1, 4, 5, 3, 1, 5, 5, 2, 1, 1, ~
$ ingreso     <dbl> 5391.527, 5391.527, 7077.083, 7105.557, 7077.083, 2418.750,-
$ gasto       <dbl> 5391.527, 5391.527, 7077.083, 7105.557, 7077.083, 2418.750,-
```

## select()

¿Para qué sirve?

Permite **seleccionar columnas** (variables) de un conjunto de datos.

```
temp <- select(datos, sexo, parentesco, edad)
head(temp)
```

| sexo   | parentesco | edad |
|--------|------------|------|
| Hombre | 1          | 51   |
| Mujer  | 2          | 46   |
| Mujer  | 1          | 26   |
| Hombre | 2          | 24   |
| Hombre | 3          | 7    |
| Mujer  | 1          | 42   |

Devuelve solo las variables indicadas.

## Selección por posición

```
temp <- select(datos, 1:3)  
head(temp)
```

| id_hogar | id_pers | upm        |
|----------|---------|------------|
| 262      | 1       | 1100100006 |
| 262      | 2       | 1100100006 |
| 265      | 1       | 1100100006 |
| 265      | 2       | 1100100006 |
| 265      | 3       | 1100100006 |
| 277      | 1       | 1100100006 |

## Selección por rango

```
temp <- select(datos, parentesco:anoest)
head(temp, 10)
```

| parentesco | edad | sexo   | etnia | anoest |
|------------|------|--------|-------|--------|
| 1          | 51   | Hombre | 0     | 18     |
| 2          | 46   | Mujer  | 0     | 12     |
| 1          | 26   | Mujer  | 0     | 17     |
| 2          | 24   | Hombre | 0     | 15     |
| 3          | 7    | Hombre | 1     | 0      |
| 1          | 42   | Mujer  | 0     | 15     |
| 3          | 20   | Mujer  | 1     | 13     |
| 3          | 17   | Hombre | 1     | 8      |
| 3          | 13   | Mujer  | 1     | 5      |
| 1          | 60   | Hombre | 0     | 10     |

## Selección por exclusión

```
temp <- select(datos,-c("id_hogar", "id_pers","upm", "estrato",  
                        "area", "fep", "pobreza",  
                        "ingreso_hh","gasto_hh")) # excluye variables  
head(temp, 5)
```

| parentesco | edad | sexo   | etnia | anoest | niveduc_ee | ingreso  | gasto    |
|------------|------|--------|-------|--------|------------|----------|----------|
| 1          | 51   | Hombre | 0     | 18     | 7          | 5391.527 | 5391.527 |
| 2          | 46   | Mujer  | 0     | 12     | 5          | 5391.527 | 5391.527 |
| 1          | 26   | Mujer  | 0     | 17     | 7          | 7077.083 | 7077.083 |
| 2          | 24   | Hombre | 0     | 15     | 6          | 7105.557 | 7105.557 |
| 3          | 7    | Hombre | 1     | 0      | 1          | 7077.083 | 7077.083 |

`select()` acepta rangos y exclusiones, lo que permite construir subconjuntos rápidamente.

## Selectores auxiliares

```
select(datos,  
  starts_with("e"), # variables que inician con "e"  
  ends_with("o"),   # variables que terminan con "o"  
  contains("ed"),    # variables que contienen "ed"  
  everything())      # todas las variables
```

*Los **selectores** permiten patrones más flexibles, útiles con grandes bases.*



## Selectores auxiliares: variables que inician con “e”

```
select(datos, starts_with("e")) %>% head()
```

| estrato | edad | etnia |
|---------|------|-------|
| 11001   | 51   | 0     |
| 11001   | 46   | 0     |
| 11001   | 26   | 0     |
| 11001   | 24   | 0     |
| 11001   | 7    | 1     |
| 11001   | 42   | 0     |

## Selectores auxiliares: variables que terminan con "o"

```
select(datos, ends_with("o")) %>% head()
```

| estrato | parentesco | sexo   | ingreso  | gasto    |
|---------|------------|--------|----------|----------|
| 11001   | 1          | Hombre | 5391.527 | 5391.527 |
| 11001   | 2          | Mujer  | 5391.527 | 5391.527 |
| 11001   | 1          | Mujer  | 7077.083 | 7077.083 |
| 11001   | 2          | Hombre | 7105.557 | 7105.557 |
| 11001   | 3          | Hombre | 7077.083 | 7077.083 |
| 11001   | 1          | Mujer  | 2418.750 | 2418.750 |

Selectores auxiliares: variables que contienen “ed”

```
select(datos, contains("ed")) %>% head()
```

| edad | niveduc_ee |
|------|------------|
| 51   | 7          |
| 46   | 5          |
| 26   | 7          |
| 24   | 6          |
| 7    | 1          |
| 42   | 6          |

## Renombrar variables al seleccionar

Puedes renombrar variables dentro de `select()`, sin usar `rename()` aparte.

```
select(datos,  
  Nivel_Educativo = niveduc_ee,  
  Años_estudio = anoest,  
  Sexo = sexo  
) %>%  
head()
```

| Nivel_Educativo | Años_estudio | Sexo   |
|-----------------|--------------|--------|
| 7               | 18           | Hombre |
| 5               | 12           | Mujer  |
| 7               | 17           | Mujer  |
| 6               | 15           | Hombre |
| 1               | 0            | Hombre |
| 6               | 15           | Mujer  |

filter()

¿Para qué sirve?

*Selecciona **filas (observaciones)** que cumplen condiciones lógicas.*

```
filter(datos, parentesco == 1) %>% head()
```

| id_hogar | id_pers | upm        | estrato | area | fep | pobreza | ingreso_hh | gasto_hh  | parentesco | edad | sexo   | etnia | anoest | niveduc_e | ingreso   | gasto     |
|----------|---------|------------|---------|------|-----|---------|------------|-----------|------------|------|--------|-------|--------|-----------|-----------|-----------|
| 262      | 1       | 1100100000 | 1001    | 1    | 19  | 3       | 10783.053  | 10783.053 | 1          | 51   | Hombre | 0     | 18     | 7         | 5391.527  | 5391.527  |
| 265      | 1       | 1100100000 | 1001    | 1    | 16  | 3       | 21259.723  | 21259.723 | 1          | 26   | Mujer  | 0     | 17     | 7         | 7077.083  | 7077.083  |
| 277      | 1       | 1100100000 | 1001    | 1    | 16  | 3       | 9618.053   | 9618.053  | 1          | 42   | Mujer  | 0     | 15     | 6         | 2418.750  | 2418.750  |
| 288      | 1       | 1100100000 | 1001    | 1    | 19  | 3       | 5414.580   | 5414.580  | 1          | 60   | Hombre | 0     | 10     | 4         | 1375.000  | 1375.000  |
| 289      | 1       | 1100100000 | 1001    | 1    | 30  | 3       | 7807.633   | 7807.633  | 1          | 39   | Hombre | 0     | 12     | 5         | 1561.527  | 1561.527  |
| 291      | 1       | 1100100000 | 1001    | 1    | 28  | 3       | 7337.633   | 7337.633  | 1          | 43   | Hombre | 0     | 12     | 5         | 1467.527  | 1467.527  |
| 295      | 1       | 1100100000 | 1001    | 1    | 36  | 3       | 50214.580  | 47566.942 | 1          | 71   | Mujer  | 0     | 11     | 4         | 12546.527 | 12546.527 |
| 296      | 1       | 1100100000 | 1001    | 1    | 21  | 3       | 7971.527   | 7971.527  | 1          | 67   | Hombre | 0     | 10     | 4         | 4000.000  | 4000.000  |
| 298      | 1       | 1100100000 | 1001    | 1    | 24  | 3       | 7261.040   | 7261.040  | 1          | 47   | Mujer  | 1     | 12     | 5         | 2420.347  | 2420.347  |
| 302      | 1       | 1100100000 | 1001    | 1    | 26  | 3       | 14717.796  | 14717.796 | 1          | 61   | Mujer  | 0     | 12     | 5         | 2943.559  | 2943.559  |

Devuelve solo los jefes de hogar.

## Condiciones múltiples

```
filter(datos, parentesco == 1, ingreso > 7100) %>%  
  select(id_hogar, parentesco,  
         ingreso, sexo) %>% head(10)
```

| id_hogar |   | parentesco | ingreso   | sexo   |
|----------|---|------------|-----------|--------|
| 295      | 1 |            | 12546.527 | Mujer  |
| 359      | 1 |            | 14729.860 | Mujer  |
| 362      | 1 |            | 7521.527  | Hombre |
| 406      | 1 |            | 8971.527  | Hombre |
| 495      | 1 |            | 8703.053  | Mujer  |
| 495      | 1 |            | 8760.000  | Mujer  |
| 549      | 1 |            | 19783.335 | Hombre |
| 555      | 1 |            | 7583.330  | Hombre |
| 557      | 1 |            | 8258.330  | Hombre |
| 572      | 1 |            | 7164.772  | Hombre |

## Operadores lógicos más usados

| Operador                   | Significado               | Ejemplo                                            |
|----------------------------|---------------------------|----------------------------------------------------|
| <code>==</code>            | Igual                     | <code>parentesco == 1</code>                       |
| <code>!=</code>            | Diferente                 | <code>pobreza != 3</code>                          |
| <code>&gt; / &lt;</code>   | Mayor / Menor             | <code>edad &gt; 17</code>                          |
| <code>&gt;= / &lt;=</code> | Mayor/igual / Menor/igual | <code>anoest &gt;= 12</code>                       |
| <code>%in%</code>          | Pertenencia               | <code>edad%in%<br/>c(1:10)</code>                  |
| <code>&amp; /  </code>     | Y / O lógicos             | <code>edad &gt; 17 &amp;<br/>anoest &gt; 20</code> |

## Uso de operadores de pertenencia

```
datos %>% filter(edad %in% c(1:10)) %>%  
  select(id_hogar, parentesco, ingreso, sexo, edad) %>%  
  head()
```

| id_hogar |   | parentesco | ingreso  | sexo   | edad |
|----------|---|------------|----------|--------|------|
| 265      | 3 |            | 7077.083 | Hombre | 7    |
| 288      | 3 |            | 1346.527 | Mujer  | 5    |
| 289      | 3 |            | 1561.527 | Mujer  | 5    |
| 289      | 3 |            | 1561.527 | Mujer  | 3    |
| 291      | 3 |            | 1467.527 | Mujer  | 10   |
| 302      | 4 |            | 2943.559 | Hombre | 8    |

Filtra solo las observaciones con edad de 1 a 10 años.



# Flujo de trabajo visual

1. `select()` → selecciona variables
2. `filter()` → aplica condiciones
3. Resultado: subconjunto depurado y legible

Piensa en estas funciones como una “lupa”: una observa **qué columnas**, la otra **qué filas**.

# Variantes útiles

`select()`

- ▶ `rename_with(fn, .cols)` → aplicar función a nombres
- ▶ `relocate(col, .before/.after)` → cambiar orden de columnas

`filter()`

- ▶ `filter(.data, between(var, a, b))`
- ▶ `filter(.data, near(var, value, tol))`

```
filter(datos, between(edad, 1, 10))
```

## Resumen de la clase

| Función               | Actúa sobre | Objetivo principal                    | Ejemplo                                   |
|-----------------------|-------------|---------------------------------------|-------------------------------------------|
| <code>select()</code> | Columnas    | Reducir o reorganizar variables       | <code>select(datos, edad, sexo)</code>    |
| <code>filter()</code> | Filas       | Seleccionar observaciones específicas | <code>filter(datos, edad &gt;= 18)</code> |

Combinadas, son la base de todo flujo de transformación en el tidyverse.