

# Fundamentos de ciencia de datos con R - Módulo 2

Clase 5: `group_by()` y `summarise()`

CEPAL - Unidad de Estadísticas Sociales

2026-01-07

# Introducción

El objetivo de esta sección es **aprender a agrupar y resumir información** usando las funciones `group_by()` y `summarise()`.

Estas herramientas permiten obtener **estadísticas agregadas por categorías** o combinaciones de variables, dentro del flujo natural del *tidyverse*.

## Lectura de base de ejemplos

```
datos <- readRDS("data/base_personas_gasto.rds")
library(dplyr)
datos %>% mutate(log_ingreso = log(ingreso) ) %>%
  select(id_hogar, id_pers, ingreso, log_ingreso) %>% head(4)
```

| id_hogar | id_pers | ingreso  | log_ingreso |
|----------|---------|----------|-------------|
| 262      | 1       | 5391.527 | 8.592584    |
| 262      | 2       | 5391.527 | 8.592584    |
| 265      | 1       | 7077.083 | 8.864617    |
| 265      | 2       | 7105.557 | 8.868632    |

# Sintaxis general

`group_by()` define los grupos y `summarise()` resume las variables.

```
datos %>%  
  group_by(variable_grupo) %>%  
  summarise(  
    nueva_variable = funcion(variable_interés, na.rm = TRUE)  
  )
```

## Promedio del ingreso por área

```
datos %>%  
  group_by(area) %>%  
  summarise(media_ingreso = mean(ingreso, na.rm = TRUE))
```

| area | media_ingreso |
|------|---------------|
| 1    | 3677.658      |
| 2    | 2436.735      |

## Combinando select() y filter()

Integración: selección, filtrado y resumen en una misma secuencia.

```
datos %>%  
  select(area, sexo, ingreso) %>%  
  filter(ingreso > 0) %>%  
  group_by(area, sexo) %>%  
  summarise(media_ingreso = mean(ingreso), .groups = "drop")
```

| area | sexo   | media_ingreso |
|------|--------|---------------|
| 1    | Hombre | 3796.482      |
| 1    | Mujer  | 3594.350      |
| 2    | Hombre | 2600.428      |
| 2    | Mujer  | 2296.654      |

## Múltiples estadísticas

Se pueden generar **múltiples medidas resumen** en un solo paso.

```
datos %>%  
  group_by(niveduc_ee) %>%  
  summarise(  
    media_ingreso = mean(ingreso),  
    mediana_ingreso = median(ingreso),  
    sd_ingreso = sd(ingreso) )
```

| niveduc_ee | media_ingreso | mediana_ingreso | sd_ingreso |
|------------|---------------|-----------------|------------|
| 1          | 2497.282      | 1840.673        | 2836.007   |
| 2          | 2553.615      | 2063.079        | 2480.526   |
| 3          | 2989.516      | 1844.828        | 11910.837  |
| 4          | 2598.814      | 1997.672        | 2479.123   |
| 5          | 3157.651      | 2319.757        | 4296.941   |
| 6          | 4443.027      | 3082.253        | 4880.921   |
| 7          | 9334.354      | 6082.638        | 14510.925  |
| NA         | 2296.833      | 1853.527        | 1733.412   |

# Uso de across()

Permite aplicar funciones a **varias columnas simultáneamente**.

```
datos %>%  
  group_by(area) %>%  
  summarise(  
    across(c(ingreso, gasto), mean, .names = "media_{.col}")  
  )
```

| area | media_ingreso | media_gasto |
|------|---------------|-------------|
| 1    | 3677.658      | 3546.095    |
| 2    | 2436.735      | 2414.815    |



## Incorporando mutate() + ifelse()

Ejemplo de creación previa de una variable categórica antes del agrupamiento.

```
datos %>%  
  mutate(tipo = ifelse(ingreso > 10000, "Alto", "Bajo")) %>%  
  group_by(tipo) %>%  
  summarise(media_gasto = mean(gasto))
```

| tipo | media_gasto |
|------|-------------|
| Alto | 16693.711   |
| Bajo | 2660.821    |

## Agrupación tras case\_when()

Muestra cómo agrupar por clasificaciones múltiples.

```
datos %>%  
  mutate(  
    grupo_edad = case_when(  
      edad < 18 ~ "Menor",  
      edad >= 18 & edad < 60 ~ "Adulto",  
      TRUE ~ "Mayor"  
    )  
  ) %>%  
  group_by(grupo_edad) %>%  
  summarise(media_ingreso = mean(ingreso))
```

| grupo_edad | media_ingreso |
|------------|---------------|
| Adulto     | 3649.755      |
| Mayor      | 3723.619      |
| Menor      | 2648.083      |

## Mutate + summarise en secuencia

Crea una nueva variable antes de resumir por grupo.

```
datos %>%  
  filter(id_pers == 1) %>%  
  mutate(razon_hh = gasto_hh/ingreso_hh) %>%  
  group_by(niveduc_ee) %>%  
  summarise(media_razon_hh = mean(razon_hh, na.rm = TRUE))
```

| niveduc_ee | media_razon_hh |
|------------|----------------|
| 1          | 1.0000000      |
| 2          | 1.0000000      |
| 3          | 1.0000000      |
| 4          | 0.9993295      |
| 5          | 0.9984701      |
| 6          | 0.9959953      |
| 7          | 0.9812437      |
| NA         | 1.0000000      |

# Agrupaciones múltiples

Agrupación cruzada entre **varias dimensiones**.

```
datos %>%  
  group_by(area, sexo, etnia) %>%  
  summarise(media_ingreso = mean(ingreso), .groups = "drop")
```

| area | sexo   | etnia | media_ingreso |
|------|--------|-------|---------------|
| 1    | Hombre | 0     | 3904.552      |
| 1    | Hombre | 1     | 2762.409      |
| 1    | Hombre | 99    | 1910.715      |
| 1    | Mujer  | 0     | 3701.783      |
| 1    | Mujer  | 1     | 2591.270      |
| 1    | Mujer  | 99    | 2288.176      |
| 2    | Hombre | 0     | 2665.902      |
| 2    | Hombre | 1     | 2172.085      |
| 2    | Mujer  | 0     | 2403.424      |
| 2    | Mujer  | 1     | 1717.478      |

# Ordenar resultados

Ordena los resultados del resumen de forma descendente.

```
datos %>%  
  group_by(area, etnia) %>%  
  summarise(media_ingreso = mean(ingreso), .groups = "drop") %>%  
  arrange(desc(media_ingreso))
```

| area | etnia | media_ingreso |
|------|-------|---------------|
| 1    | 0     | 3799.453      |
| 1    | 1     | 2670.701      |
| 2    | 0     | 2535.429      |
| 1    | 99    | 2018.561      |
| 2    | 1     | 1940.214      |

## Crear indicadores relativos

Conecta summarise() y mutate() para crear indicadores derivados.

```
datos %>%  
  group_by(area) %>%  
  summarise(  
    media_ingreso = mean(ingreso),  
    media_gasto = mean(gasto)  
  ) %>%  
  mutate(relacion = media_gasto / media_ingreso)
```

| area | media_ingreso | media_gasto | relacion  |
|------|---------------|-------------|-----------|
| 1    | 3677.658      | 3546.095    | 0.9642263 |
| 2    | 2436.735      | 2414.815    | 0.9910043 |

## Cuantiles con across()

Calcula cuantiles o medianas de múltiples variables en un solo paso.

```
datos %>%  
  group_by(sexo) %>%  
  summarise(across(c(ingreso, gasto), ~ quantile(.x, 0.5)))
```

| sexo   | ingreso  | gasto    |
|--------|----------|----------|
| Hombre | 2266.667 | 2266.667 |
| Mujer  | 2187.013 | 2187.013 |

# Conteo de observaciones

n() cuenta el número de registros por grupo.

```
datos %>%  
  group_by(pobreza) %>%  
  summarise(total_hogares = n())
```

| pobreza | total_hogares |
|---------|---------------|
| 1       | 397           |
| 2       | 2597          |
| 3       | 16433         |



# Proporciones

Mide la distribución relativa de cada categoría.

```
datos %>%  
  group_by(sexo) %>%  
  summarise(prop = n() / nrow(datos))
```

| sexo   | prop      |
|--------|-----------|
| Hombre | 0.4843774 |
| Mujer  | 0.5156226 |

## Dispersión por grupo

Evalúa variación intra grupo.

```
datos %>%  
  group_by(pobreza) %>%  
  summarise(  
    var_ingreso = var(ingreso),  
    rango_ingreso = max(ingreso) - min(ingreso)  
  )
```

| pobreza | var_ingreso | rango_ingreso |
|---------|-------------|---------------|
| 1       | 111500.1    | 1078.987      |
| 2       | 32298571.9  | 253749.913    |
| 3       | 33500457.9  | 253026.830    |

# Limpieza del agrupamiento

ungroup() elimina los grupos activos para posteriores análisis.

```
datos %>%  
  group_by(area) %>%  
  summarise(across(c(ingreso, gasto), mean)) %>%  
  ungroup()
```

| area | ingreso  | gasto    |
|------|----------|----------|
| 1    | 3677.658 | 3546.095 |
| 2    | 2436.735 | 2414.815 |

# Resumen de la clase

| Función                  | Propósito                          | Ejemplo                                          |
|--------------------------|------------------------------------|--------------------------------------------------|
| <code>group_by()</code>  | Define agrupamientos               | <code>group_by(area)</code>                      |
| <code>summarise()</code> | Resume valores                     | <code>summarise(mean(ingreso))</code>            |
| <code>mutate()</code>    | Crea nuevas variables              | <code>mutate(tipo = ifelse(...))</code>          |
| <code>across()</code>    | Simplifica aplicación de funciones | <code>across(c(ingreso, gasto),<br/>mean)</code> |