

Fundamentos de ciencia de datos con R - Módulo 5

Clase 2: Inferencia para medias y diferencia de medias I

CEPAL - Unidad de Estadísticas Sociales

2025-11-07

Introducción

En la clase anterior definimos los conceptos fundamentales de inferencia estadística. Hoy aplicaremos esas ideas a la estimación e inferencia para una media poblacional, utilizando ejemplos prácticos con R.

Nota

Aprenderemos a:

Calcular intervalos de confianza para una media.

Realizar pruebas de hipótesis sobre una media.

Interpretar resultados de forma estadística y práctica.

Base de datos y muestra

Utilizaremos nuevamente la base `base_personas_gasto.rds`, que contiene información sobre el ingreso y gasto de los hogares.

```
library(tidyverse)

datos <- readRDS("../Data/base_personas_gasto.rds")

set.seed(123)
muestra <- slice_sample(datos, n = 400)
head(muestra[, 2:8], 5)
```

| id_pers | upm | estrato | area | fep | pobreza | ingreso_hh |
|---------|-------------|---------|------|-----|---------|------------|
| 3 | 14128201182 | 141282 | 1 | 45 | 3 | 7236.040 |
| 2 | 14912200300 | 149122 | 2 | 22 | 3 | 12036.117 |
| 1 | 4102200159 | 41022 | 1 | 135 | 3 | 5414.580 |
| 2 | 3101400134 | 31014 | 1 | 17 | 3 | 7923.053 |
| 1 | 5902900064 | 59029 | 2 | 41 | 3 | 9714.580 |

Estimación de la media

```
x <- muestra$ingreso_hh  
x <- x[is.finite(x)]  
media <- mean(x)  
se <- sd(x)/sqrt(length(x))  
media; se
```

```
[1] 11897.43
```

```
[1] 672.6117
```

Nota

Interpretación: La media muestral \bar{X} es el mejor estimador puntual de la media poblacional μ . El error estándar (s/\sqrt{n}) mide la variabilidad esperada de la media entre muestras.

Intervalo de confianza para la media

```
ic_95 <- c(media - 1.96 * se, media + 1.96 * se)  
ic_95
```

```
[1] 10579.11 13215.75
```

Nota

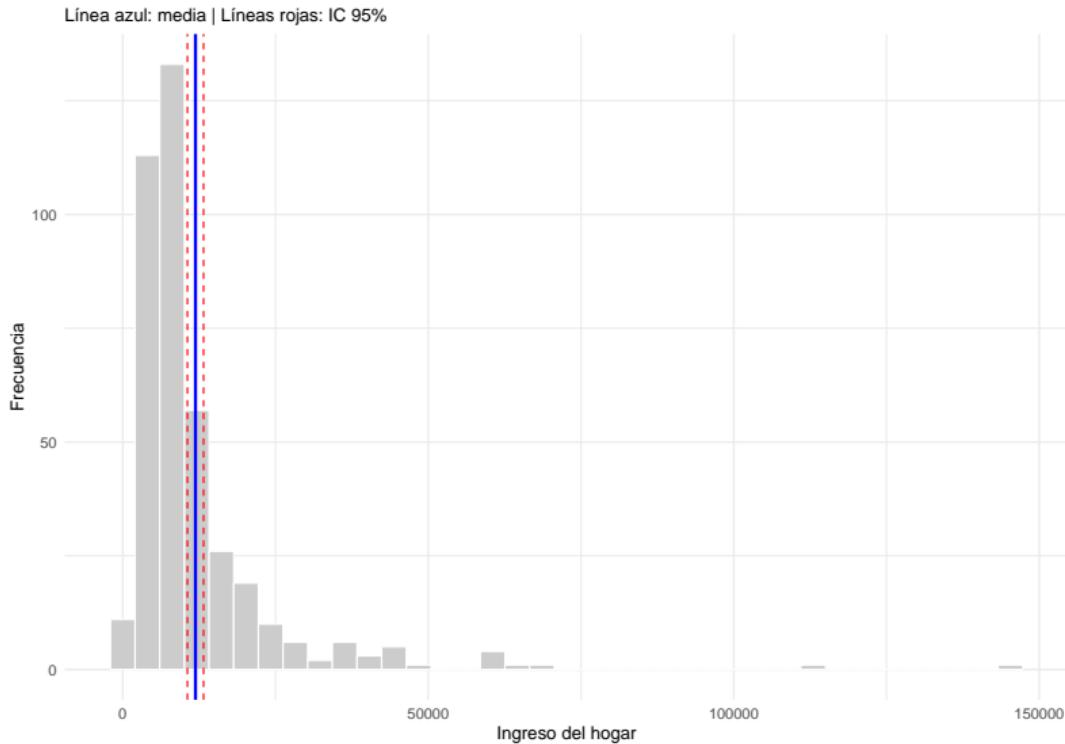
Interpretación: “Con un 95 % de confianza, la media poblacional se encuentra entre los límites del intervalo calculado.”

Visualización del IC

```
graf <- ggplot(as.data.frame(x), aes(x)) +
  geom_histogram(binwidth = 0.3*sd(x), fill = "gray80", color = "white") +
  geom_vline(xintercept = media, color = "blue", linewidth = 1) +
  geom_vline(xintercept = ic_95, linetype = "dashed", color = "red") +
  labs(subtitle = "Línea azul: media | Líneas rojas: IC 95%",
       x = "Ingreso del hogar", y = "Frecuencia") +
  theme_minimal(base_size = 12)
```

Visualización del IC

graf



Prueba de hipótesis para la media

Queremos contrastar:

$$H_0 : \mu = 1.500.000 \quad H_1 : \mu \neq 1.500.000$$



Tip

Interpretación:

Si el valor-p < 0.05 → se rechaza H_0 (la media difiere de 1.500.000).

Si el valor-p > 0.05 → no hay evidencia suficiente para rechazar H_0 .

Prueba de hipótesis para la media

Usamos la prueba t de Student:

```
t.test(muestra$gasto_hh, mu = 1500000)
```

One Sample t-test

```
data: muestra$gasto_hh
t = -2526.2, df = 399, p-value < 2.2e-16
alternative hypothesis: true mean is not equal to 1500000
95 percent confidence interval:
 10497.23 12813.77
sample estimates:
mean of x
11655.5
```

Prueba de hipótesis para la media

Con un valor p menor a 2.2×10^{-1} , inferior al nivel de significancia del 5% ($\alpha = 0.05$), se rechaza la hipótesis nula que planteaba que el gasto promedio de los hogares es igual a 1.500.000.

El promedio muestral fue de 11.655,5, con un intervalo de confianza al 95% entre 10.497,23 y 12.813,77, lo que indica que el gasto medio real difiere significativamente del valor hipotético propuesto.

Ejemplo práctico: comparación por sexo

Analizamos si el gasto promedio difiere entre hombres y mujeres.

```
muestra %>%
group_by(sexo) %>%
summarise(
  media = mean(gasto_hh, na.rm = TRUE),
  sd = sd(gasto_hh, na.rm = TRUE),
  n = n()
)
```

| sexo | media | sd | n |
|--------|----------|----------|-----|
| Hombre | 11610.56 | 12176.34 | 199 |
| Mujer | 11700.00 | 11411.50 | 201 |

Ejemplo práctico: comparación por sexo

Prueba de diferencia de medias (independientes)

```
t.test(gasto_hh ~ sexo, data = muestra, var.equal = TRUE)
```

Two Sample t-test

```
data: gasto_hh by sexo
t = -0.075804, df = 398, p-value = 0.9396
alternative hypothesis: true difference in means between group Hombre and grupo Mujer is not equal to 0
95 percent confidence interval:
-2408.924 2230.050
sample estimates:
mean in group Hombre mean in group Mujer
11610.56           11700.00
```

Ejemplo práctico: comparación por sexo

Prueba de diferencia de medias (independientes)

El resultado fue $t = -0.0758$, con $p\text{-valor} = 0.9396$, superior al nivel de significancia de 0.05. Por tanto, no se rechaza la hipótesis nula, lo que indica que no existen diferencias estadísticamente significativas en el gasto promedio entre hombres y mujeres. El resultado fue $t = -0.0758$, con $p\text{-valor} = 0.9396$, superior al nivel de significancia de 0.05. Por tanto, no se rechaza la hipótesis nula, lo que indica que no existen diferencias estadísticamente significativas en el gasto promedio entre hombres y mujeres.

Ejemplo práctico: comparación por sexo

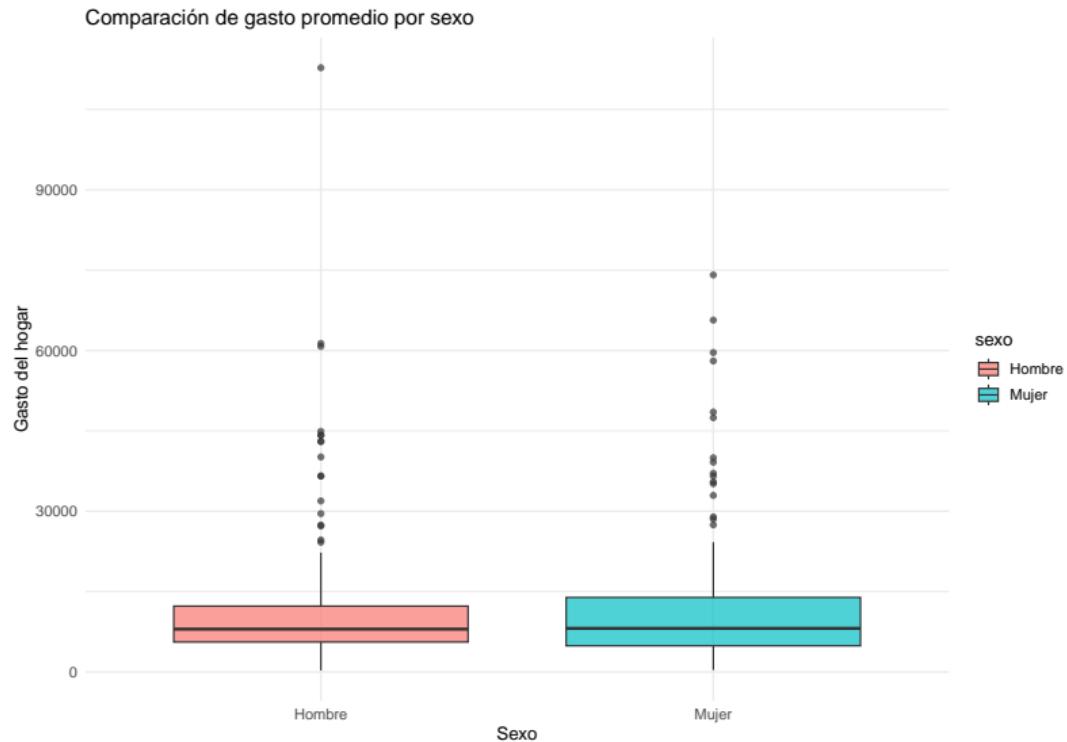
Visualización comparativa

```
graf2 <- ggplot(muestra, aes(x = sexo, y = gasto_hh, fill = sexo)) +  
  geom_boxplot(alpha = 0.7) +  
  labs(title = "Comparación de gasto promedio por sexo",  
       x = "Sexo", y = "Gasto del hogar") +  
  theme_minimal(base_size = 12)
```

Ejemplo práctico: comparación por sexo

Visualización comparativa

graf2



Conclusiones de la clase

| Concepto | Aplicación en esta clase |
|---|--|
| Media muestral (\bar{X}) | Estimador puntual de μ |
| Error estándar (s/\sqrt{n}) | Medida de precisión del estimador |
| Intervalo de confianza | Rango plausible para la media poblacional |
| Prueba t para una media | Contrasta hipótesis sobre la media poblacional |
| Valor-p | Mide la evidencia contra H_0 |
| Comparación inicial entre grupos | Introducción a la diferencia de medias |

Nota

En resumen: Hoy aplicamos los fundamentos de la inferencia sobre una media. En la Clase 3 profundizaremos en la comparación entre dos medias y sus aplicaciones prácticas.