

Fundamentos de ciencia de datos con R - Módulo 5

Clase 4: Inferencia para proporciones y diferencia de proporciones I

CEPAL - Unidad de Estadísticas Sociales

2025-12-22

Introducción

En las clases anteriores trabajamos la inferencia para medias y la diferencia de medias entre grupos. En esta clase nos centraremos en variables categóricas/binarias, donde el parámetro de interés es una proporción poblacional.

Ejemplos típicos:

- ▶ Proporción de hogares en pobreza.
- ▶ Proporción de personas ocupadas.
- ▶ Proporción de hogares con acceso a internet.

Introducción

Nota

Objetivos de esta clase:

- ▶ Definir la proporción poblacional y su estimador muestral.
- ▶ Construir intervalos de confianza para una proporción.
- ▶ Formular y aplicar pruebas de hipótesis para una proporción.

Base de datos y muestra

Usaremos nuevamente la base `base_personas_gasto.rds`, y construiremos una variable binaria que indique si el hogar tiene ingreso bajo.

```
library(tidyverse)

datos <- readRDS("../Data/base_personas_gasto.rds")

set.seed(123)
muestra <- slice_sample(datos, n = 400)
head(muestra[, 2:8], 5)
```

	id_pers	upm	estrato	area	fep	pobreza	ingreso_hh
	3	14128201182	141282	1	45	3	7236.040
	2	14912200300	149122	2	22	3	12036.117
	1	4102200159	41022	1	135	3	5414.580
	2	3101400134	31014	1	17	3	7923.053
	1	5902900064	59029	2	41	3	9714.580

Base de datos y muestra

```
mediana_ingreso <- median(muestra$ingreso_hh, na.rm = TRUE)

muestra <- muestra %>%
mutate(
  ingreso_bajo = if_else(ingreso_hh < mediana_ingreso, 1, 0)
)

head(muestra[, c("ingreso_hh", "ingreso_bajo", "sexo")], 5)
```

ingreso_hh	ingreso_bajo	sexo
7236.040	1	Hombre
12036.117	0	Mujer
5414.580	1	Hombre
7923.053	1	Hombre
9714.580	0	Hombre

Base de datos y muestra

Nota

Interpretación de ingreso_bajo:

1 = hogar con ingreso por debajo de la mediana (ingreso bajo).

0 = hogar con ingreso igual o superior a la mediana.

Proporción poblacional y estimador

Sea Y una variable binaria:

$Y_i = 1$ si el hogar cumple la condición de interés (ej. ingreso bajo).

$Y_i = 0$ en caso contrario.

La proporción poblacional se define como:

$$p = P(Y = 1)$$

En una muestra de tamaño n , el estimador natural de p es la proporción muestral:

$$\hat{p} = \frac{1}{n} \sum_{i=1}^n Y_i$$

Proporción muestral en el ejemplo

Calculamos la proporción de hogares con ingreso bajo en nuestra muestra:

```
y <- muestra$ingreso_bajo
n <- length(y)
x <- sum(y)      # número de "éxitos"

p_hat <- x / n
c(n = n, exitos = x, proporcion_muestral = p_hat)
```

n	exitos	proporcion_muestral
400.0	200.0	0.5



Tip

$\hat{p}$ es el porcentaje de hogares con ingreso bajo en la muestra y se usa como estimador de la proporción poblacional p .

Error estándar de la proporción

Bajo muestreo aleatorio simple y muestras grandes, el estimador $\hat{p}$ tiene:

Media: $E(\hat{p}) \approx p$

Varianza: $\text{Var}(\hat{p}) \approx \frac{p(1-p)}{n}$

Usando la muestra, el error estándar se estima reemplazando p por $\hat{p}$:

$$\widehat{SE}(\hat{p}) = \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}$$

Error estándar de la proporción

```
se_p <- sqrt(p_hat * (1 - p_hat) / n)
se_p
```

```
[1] 0.025
```

Intervalo de confianza para una proporción

Para muestras grandes, un intervalo de confianza al 95 % para p se puede aproximar como:

$$\hat{p} \pm z_{0.975} \cdot \widehat{SE}(\hat{p})$$

donde $z_{0.975} \approx 1.96$.

Intervalo de confianza para una proporción

```
z <- 1.96  
ic_95_p <- c(  
  p_hat - z * se_p,  
  p_hat + z * se_p  
)  
ic_95_p
```

```
[1] 0.451 0.549
```



“Con un 95 % de confianza, la proporción poblacional de hogares con ingreso bajo se encuentra entre los límites del intervalo calculado.”

Prueba de hipótesis para una proporción

Supongamos que se plantea la siguiente hipótesis sobre la proporción de hogares con ingreso bajo:

$$H_0 : p = 0.40$$

$$H_1 : p \neq 0.40$$

Donde $p = 0.40$ representa un valor de referencia de interés (por ejemplo, el valor esperado según una política o un dato histórico).

Prueba de hipótesis para una proporción# Prueba de hipótesis para una proporción

! Importante

Si la proporción observada $\hat{p}$ está “muy lejos” de 0.40 (según su error estándar), se rechaza H_0 .

Si no, no hay evidencia suficiente para rechazar H_0 .

Prueba de hipótesis para una proporción en R

Podemos usar `prop.test()` para realizar la prueba:

```
prop.test(x = x, n = n, p = 0.40,  
  alternative = "two.sided",  
  correct = FALSE  
)
```

1-sample proportions test without continuity correction

data: x out of n, null probability 0.4

X-squared = 16.667, df = 1, p-value = 4.456e-05

alternative hypothesis: true p is not equal to 0.4

95 percent confidence interval:

0.4512345 0.5487655

sample estimates:

p

0.5

Prueba de hipótesis para una proporción en R

Pregunta

Con base en el valor-p, ¿se debe **rechazar** o **no rechazar** la hipótesis nula H_0 ?

Resumen de la clase

Tema	Idea principal	Herramienta en R
Proporción poblacional p	Probabilidad de “éxito” en la población	—
Proporción muestral $\hat{p}$	Estimador puntual de p	<code>mean(y)</code>
IC para una proporción	$\hat{p} \pm z \cdot \sqrt{\hat{p}(1 - \hat{p})/n}$	
Prueba para una proporción	Contraste $H_0 : p = p_0$ vs H_1 alternativa	<code>prop.test(x, n, p = p0)</code>

Resumen de la clase

En resumen

- ▶ La inferencia para proporciones es clave cuando trabajamos con variables binarias.
- ▶ La proporción muestral $\hat{p}$ es un estimador sencillo pero muy poderoso.
- ▶ `prop.test()` permite, en una sola función, obtener intervalos de confianza y pruebas de hipótesis para una o dos proporciones.