

Fundamentos de ciencia de datos con R - Módulo 5

Clase 5: Inferencia para proporciones y diferencia de proporciones II

CEPAL - Unidad de Estadísticas Sociales

2025-12-22

Introducción

En la Clase 4 revisamos la inferencia para una proporción poblacional. En esta clase profundizaremos en la comparación entre dos proporciones provenientes de dos grupos independientes.

Introducción

i Objetivos de esta clase

- ▶ Entender la diferencia de proporciones como parámetro poblacional.
- ▶ Construir intervalos de confianza para $p_1 - p_2$
- ▶ Formular y evaluar hipótesis para comparar dos proporciones.

Estimador para dos proporciones

Sea Y_1 una variable binaria en el Grupo 1 y Y_2 en el Grupo 2.

$$\hat{p}_1 = \frac{x_1}{n_1}, \quad \hat{p}_2 = \frac{x_2}{n_2}$$

donde:

- ▶ X_1, X_2 : número de éxitos en cada grupo
- ▶ n_1, n_2 : tamaños de muestra

El estimador de la diferencia es:

$$\widehat{p_1 - p_2} = \hat{p}_1 - \hat{p}_2$$

Error estándar de la diferencia

Para muestras grandes, el error estándar se estima como:

$$SE(\hat{p}_1 - \hat{p}_2) = \sqrt{\frac{\hat{p}_1(1 - \hat{p}_1)}{n_1} + \frac{\hat{p}_2(1 - \hat{p}_2)}{n_2}}$$

Base de datos y muestra

```
library(tidyverse)

datos <- readRDS("../Data/base_personas_gasto.rds")

set.seed(123)
muestra <- slice_sample(datos, n = 1000)
head(muestra[, 2:8], 5)
```

	id_pers	upm	estrato	area	fep	pobreza	ingreso_hh
	3	14128201182	141282	1	45	3	7236.040
	2	14912200300	149122	2	22	3	12036.117
	1	4102200159	41022	1	135	3	5414.580
	2	3101400134	31014	1	17	3	7923.053
	1	5902900064	59029	2	41	3	9714.580

Base de datos y muestra

```
muestra <- muestra %>%  
mutate(  
  mediana_ingreso = median(ingreso_hh, na.rm = TRUE),  
  ingreso_bajo = if_else(ingreso_hh < mediana_ingreso, 1, 0)  
)
```

Comparación por sexo

```
tabla <- muestra %>%  
group_by(sexo) %>%  
summarise(  
  n = n(),  
  x = sum(ingreso_bajo),  
  p = mean(ingreso_bajo)  
)  
  
tabla
```

sexo	n	x	p
Hombre	490	246	0.5020408
Mujer	510	254	0.4980392

Intervalo de confianza para $p_1 - p_2$

```
p1 <- tabla$p[1]; n1 <- tabla$n[1]
p2 <- tabla$p[2]; n2 <- tabla$n[2]

dif <- p1 - p2
se_dif <- sqrt( (p1*(1-p1))/n1 + (p2*(1-p2))/n2 )

ic <- c(dif - 1.96*se_dif, dif + 1.96*se_dif)
ic
```

```
[1] -0.05799094  0.06599415
```

Intervalo de confianza para $p_1 - p_2$

Interpretación

- ▶ Si el intervalo de confianza incluye 0, no hay evidencia de diferencia significativa entre las dos proporciones.
- ▶ Si no incluye 0, existe diferencia estadísticamente significativa.

Prueba para dos proporciones en R

$$H_0 : p_1 = p_2$$

$$H_1 : p_1 \neq p_2$$

donde:

- ▶ H_0 : La proporción del Grupo 1 es igual a la proporción del Grupo 2.
- ▶ H_1 : Las proporciones de los dos grupos son diferentes.

Prueba para dos proporciones en R

```
prop.test(x = tabla$x, n = tabla$n,  
alternative = "two.sided",  
correct = FALSE  
)
```

2-sample test for equality of proportions without continuity correction

data: tabla\$x out of tabla\$n

X-squared = 0.016006, df = 1, p-value = 0.8993

alternative hypothesis: two.sided

95 percent confidence interval:

-0.05798981 0.06599301

sample estimates:

prop 1 prop 2

0.5020408 0.4980392

Prueba para dos proporciones en R

! Importante

Si el valor-p $< 0.05 \rightarrow$ evidencia de diferencia significativa entre proporciones.

Si el valor-p $\geq 0.05 \rightarrow$ no hay evidencia suficiente para afirmar una diferencia.

Resumen de la clase

Tema	Idea principal	Herramienta
Estimador ($\hat{p}_1 - \hat{p}_2$)	Mide la diferencia entre grupos	—
Error estándar	Determina la variabilidad del estimador	—
IC para dos proporciones	Evalúa si la diferencia incluye 0	cálculo manual
Prueba de hipótesis	Contrasta ($p_1 = p_2$)	<code>prop.test(c(x1,x2), c(n1,n2))</code>