

Fundamentos de ciencia de datos con R - Módulo 6

Clase 2: Exploración de datos

CEPAL - Unidad de Estadísticas Sociales

2025-12-09

Introducción

Antes de ajustar un modelo estadístico (regresión lineal, logística, etc.), necesitamos entender la estructura, patrones y calidad de los datos. A este proceso se le llama Exploración de Datos (EDA).



Idea principal

La exploración de datos permite conocer el dataset antes de modelar, detectar problemas y comprender relaciones entre variables.

¿Para qué sirve el EDA?

- ▶ Identificar valores extremos (outliers).
- ▶ Detectar datos faltantes o inconsistentes.
- ▶ Revisar distribuciones de las variables.
- ▶ Evaluar relaciones entre pares de variables.
- ▶ Guiar la selección del modelo estadístico adecuado.

Cómo se exploran las variables según su tipo

Tipo de variable	Cómo se explora	Herramientas
Numérica continua	Distribución, outliers, tendencia central	Histogramas, boxplots
Numérica discreta	Frecuencias y valores dominantes	Tablas, histogramas
Categórica nominal	Proporciones por categoría	Tablas, barras
Categórica ordinal	Tendencias según orden	Barras ordenadas
Binaria	Balance entre dos grupos	Proporciones, barras
Fecha / tiempo	Tendencias y estacionalidad	Series de tiempo

Historia: el equipo que monitoreaba la calidad del aire

Un equipo de estadística ambiental trabajaba con datos diarios de calidad del aire, donde se medían, entre otros:

- ▶ concentración de ozono (Ozone),
- ▶ radiación solar (Solar.R),
- ▶ velocidad del viento (Wind),
- ▶ temperatura (Temp),
- ▶ mes y día de la medición.

Historia: el equipo que monitoreaba la calidad del aire

Al comenzar el análisis, se dieron cuenta de que:

- ▶ había valores faltantes en las mediciones de ozono y radiación,
- ▶ algunas variables tenían distribuciones muy asimétricas,
- ▶ los patrones parecían diferentes según el mes.

Antes de ajustar cualquier modelo, el equipo decidió hacer una **exploración sistemática de los datos**.

```
datos_eda <- airquality  
head(datos_eda, 5)
```

Ozone	Solar.R	Wind	Temp	Month	Day
41	190	7.4	67	5	1
36	118	8.0	72	5	2
12	149	12.6	74	5	3
18	313	11.5	62	5	4
NA	NA	14.3	56	5	5

Exploración univariada: distribución de las variables

El primer paso fue examinar cada variable por separado:

- ▶ ¿Cuál es el rango de Ozone?
- ▶ ¿Hay valores extremos en Wind o Temp?
- ▶ ¿Cómo se distribuye Solar.R?

```
summary(datos_eda)
```

Ozone	Solar.R	Wind	Temp	Month	Day
Min. : 1.00	Min. : 7.0	Min. : 1.700	Min. :56.00	Min. :5.000	Min. : 1.0
1st Qu.: 18.00	1st Qu.:115.8	1st Qu.: 7.400	1st Qu.:72.00	1st Qu.:6.000	1st Qu.: 8.0
Median : 31.50	Median :205.0	Median : 9.700	Median :79.00	Median :7.000	Median :16.0
Mean : 42.13	Mean :185.9	Mean : 9.958	Mean :77.88	Mean :6.993	Mean :15.8
3rd Qu.: 63.25	3rd Qu.:258.8	3rd Qu.:11.500	3rd Qu.:85.00	3rd Qu.:8.000	3rd Qu.:23.0
Max. :168.00	Max. :334.0	Max. :20.700	Max. :97.00	Max. :9.000	Max. :31.0
NA's :37	NA's :7	NA	NA	NA	NA

Exploración univariada: distribución de las variables

Primer diagnóstico


El resumen reveló:

- ▶ valores faltantes (NA) en Ozone y Solar.R,
- ▶ diferencias importantes entre mínimos y máximos,
- ▶ posibles valores extremos en Ozone.

Exploración univariada

El equipo revisó la distribución de Ozone para identificar outliers y asimetrías.


```
hist(datos_eda$Ozone,  
main = "Distribución de Ozone",  
xlab = "Ozone (ppb)")
```



Exploración univariada

El equipo revisó la distribución de Ozone para identificar outliers y asimetrías.

```
boxplot(datos_eda$Ozone,  
main = "Boxplot de Ozone",  
ylab = "Ozone (ppb)")
```



Exploración univariada

💡 ¿Qué observaron?

- ▶ Distribución asimétrica hacia la derecha.
- ▶ Presencia de valores altos que podrían considerarse outliers.
- ▶ Datos faltantes que deben tratarse antes de modelar.

Datos faltantes y calidad de la información

```
colSums(is.na(datos_eda))
```

Ozone	Solar.R	Wind	Temp	Month	Day
37	7	0	0	0	0


Hallazgos de calidad de datos

Ozone y Solar.R presentan un número no despreciable de valores faltantes. Cualquier análisis posterior debe decidir cómo tratarlos: eliminación, imputación, etc.

Exploración bivariada: relaciones entre variables


Luego, el equipo examinó la relación entre pares de variables numéricas.

```
plot(datos_eda$Temp, datos_eda$Ozone,  
xlab = "Temperatura (°F)",  
ylab = "Ozone (ppb)",  
main = "Ozone vs Temperatura")
```



Exploración bivariada: variable temporal

```
boxplot(Ozone ~ Month,  
data = datos_eda,  
xlab = "Mes",  
ylab = "Ozone (ppb)",  
main = "Ozone por mes")
```



Exploración multivariada

Además de gráficos simples, el equipo podría:

- ▶ calcular una matriz de correlación entre Ozone, Solar.R, Wind y Temp
- ▶ usar gráficos de pares (pairs) para ver patrones

```
cor(na.omit(datos_eda[, c("Ozone", "Solar.R", "Wind", "Temp")]))
```

	Ozone	Solar.R	Wind	Temp
Ozone	1.0000000	0.3483417	-0.6124966	0.6985414
Solar.R	0.3483417	1.0000000	-0.1271835	0.2940876
Wind	-0.6124966	-0.1271835	1.0000000	-0.4971897
Temp	0.6985414	0.2940876	-0.4971897	1.0000000

Transformaciones sugeridas por el EDA

Con base en todo lo observado, el equipo definió una serie de pasos antes de modelar:

- ▶ tratar valores faltantes de Ozone y Solar.R,
- ▶ considerar transformaciones logarítmicas para variables muy asimétricas,
- ▶ incluir interacciones o términos no lineales si las relaciones no son lineales,
- ▶ tener en cuenta la estacionalidad (Month) en cualquier modelo de predicción.

! Moraleja de la historia

El EDA permitió detectar problemas y patrones que no eran evidentes inicialmente, evitando ajustar modelos sobre una base con valores faltantes, outliers no tratados y sin considerar efectos estacionales.

Resumen de la clase

Concepto	Idea clave
EDA	Primera etapa del análisis: conocer el dataset antes de modelar.
Exploración univariada	Revisa distribución, outliers y valores faltantes por variable.
Exploración bivariada	Analiza relaciones entre pares de variables.
Exploración multivariada	Busca patrones conjuntos y correlaciones.
Calidad de datos	Identifica faltantes, errores y codificaciones inconsistentes.