

Fundamentos de ciencia de datos con R - Módulo 6

Clase 3: Regresión lineal simple

CEPAL - Unidad de Estadísticas Sociales

2025-12-04

Introducción

En la clase anterior exploramos los datos (EDA), en particular la distribución del ingreso y su relación con la pobreza. Hoy daremos el siguiente paso: construir modelos de regresión lineal simple para relacionar el ingreso con una sola variable explicativa a la vez.



Idea principal

La regresión lineal simple permite cuantificar la relación entre una variable respuesta numérica (por ejemplo, ingreso) y una variable explicativa, que puede ser continua o categórica.

¿Qué es regresión lineal simple?

La regresión es una técnica estadística que permite **describir**, **explicar** y **predecir** una variable de interés (Y) usando una o varias variables explicativas (X).

En regresión **lineal simple**, utilizamos **solo una** variable explicativa.

La meta del modelo es aproximar la relación entre (X) e (Y) mediante una **recta**.



¿Por qué 'lineal'?

Porque la relación entre la variable explicativa y la respuesta se representa como una **línea recta** en promedio.

¿Cuándo puedo usar regresión lineal simple?

Se usa cuando:

- ▶ La variable **Y es numérica continua** (ej. ingreso).
- ▶ Hay **solo una** variable explicativa (X).
- ▶ La relación entre (X) e (Y) es *aproximadamente* lineal (o linealizable).
- ▶ Los valores de (X) pueden ser:
 - ▶ **continuos** (años de estudio, edad)
 - ▶ **categoricos** (pobre/no pobre, sexo, área)



Importante

La variable respuesta **no puede ser categórica**.

Si Y es binaria (ej. pobreza), se utiliza **regresión logística**, no lineal.

Ecuación del modelo

La forma general es:

$$Y = \beta_0 + \beta_1 X + \varepsilon$$

Donde:

- ▶ (Y) : variable respuesta (continua)
- ▶ (X) : covariable (continua o categórica)
- ▶ (β_0) : intercepto (valor medio de Y cuando $X = 0$)
- ▶ (β_1) : pendiente (cambio promedio en Y por unidad de X)
- ▶ (ε) : error aleatorio

¿Cómo estima R los coeficientes?

La función elige los valores de (β_0) y (β_1) que **minimizan la suma de cuadrados de los errores** (Mínimos Cuadrados Ordinarios — *OLS*):

$$\text{Minimizar } \sum (Y_i - \hat{Y}_i)^2$$

Esto garantiza:

- ▶ La recta está “lo más cerca posible” de los datos.
- ▶ Los residuos promedio sean cero.
- ▶ El modelo tenga la máxima eficiencia bajo los supuestos del OLS.

Supuestos principales del modelo lineal

Aunque no profundizamos aún en inferencia, es útil introducir los supuestos:

Supuesto	Explicación breve
Linealidad	La relación entre X e Y es lineal “en promedio”.
Independencia	Las observaciones no están correlacionadas entre sí.
Homoscedasticidad	La variabilidad de los errores es constante.
Normalidad del error	Los residuos siguen distribución normal (para inferencia).

Historia: Los científicos que querían predecir el peso de los pingüinos

Un grupo de biólogos de la Antártida estaba estudiando pingüinos. Querían saber si podían predecir el peso de un pingüino usando solo el largo de su aleta.



Pregunta problema

“¿Los pingüinos con aletas más largas tienden a pesar más?”

Usaremos la base `palmerpenguins`, que contiene mediciones reales de pingüinos.

Datos: penguins

```
library(palmerpenguins)
library(tidyverse)

datos <- penguins %>%
  select(flipper_length_mm, body_mass_g, species) %>%
  drop_na()

head(datos, 5)
```

flipper_length_mm	body_mass_g	species
181	3750	Adelie
186	3800	Adelie
195	3250	Adelie
193	3450	Adelie
190	3650	Adelie

Modelo lineal simple

i Variables del modelo

- ▶ **Y (respuesta)**: `body_mass_g` → peso del pingüino en gramos.
- ▶ **X (explicativa)**: `flipper_length_mm` → largo de la aleta en milímetros.

La regresión lineal simple modela:

$$peso = \beta_0 + \beta_1 \cdot largoaleta + \varepsilon$$

Modelo lineal simple

```
mod_ping <- lm(body_mass_g ~ flipper_length_mm, data = datos)
summary(mod_ping)
```

Call:

```
lm(formula = body_mass_g ~ flipper_length_mm, data = datos)
```

Residuals:

	Min	1Q	Median	3Q	Max
	-1058.80	-259.27	-26.88	247.33	1288.69

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-5780.831	305.815	-18.90	<2e-16 ***
flipper_length_mm	49.686	1.518	32.72	<2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 394.3 on 340 degrees of freedom

Multiple R-squared: 0.759, Adjusted R-squared: 0.7583

F-statistic: 1071 on 1 and 340 DF, p-value: < 2.2e-16

Modelo lineal simple

💡 ¿Qué nos dicen los coeficientes?


- ▶ La **pendiente** $\beta_1 = 49.686$ es positiva y significativa.
→ A mayor largo de aleta, **mayor peso** en promedio.
- ▶ Interpretación aproximada:
cada **1 mm** adicional de largo de aleta se asocia con unos **49.7 gramos más de peso** en promedio.
- ▶ El modelo no dice que la aleta “cause” el peso,
pero sí que existe una **relación lineal útil para describir y predecir**.

Modelo lineal simple

```
graf1 <- ggplot(datos, aes(x = flipper_length_mm, y = body_mass_g)) +  
  geom_point(alpha = 0.4, color = "steelblue") +  
  geom_smooth(method = "lm", se = FALSE, color = "red", size = 1) +  
  labs(  
    title = "¿Los pingüinos con aletas más largas pesan más?",  
    x = "Largo de la aleta (mm)",  
    y = "Peso (g)"  
  )
```

Modelo lineal simple

¿Los pingüinos con aletas más largas pesan más?



Existe una relación lineal fuerte y positiva entre el tamaño de la aleta y el peso del pingüino. Es decir, pingüinos más “robustos” tienden a tener aletas más grandes.

Predicción con el modelo — La historia continúa...

Después de ajustar el modelo, los biólogos quedaron fascinados. Ya habían comprobado que los pingüinos con aletas más largas tienden a pesar más.

Pero ahora querían ir más allá:

► “¿Podemos predecir cuánto pesará un pingüino solo midiendo su aleta?”

La idea era muy útil: pesar a los pingüinos era difícil, lento y estresante para los animales; pero medir la aleta era rápido y no invasivo.

El modelo como bola de cristal



Predicción con regresión lineal

Una vez aprendida la relación lineal, el modelo funciona como una bola de cristal estadística: dado un valor de X (largo de la aleta), devuelve un valor esperado de Y (peso).

Los científicos escribieron en su cuaderno la fórmula que aprendió el modelo:

$$\hat{p}eso = -5780.831 + 49.686 \cdot largoaleta$$

Prediciendo el peso de un nuevo pingüino

Un día, encontraron un pingüino juvenil con una aleta de 200 mm.

Le tomaron la medida... y con emoción hicieron su primera predicción:

```
nuevo_ping <- data.frame(flipper_length_mm = 200)
predict(mod_ping, newdata = nuevo_ping)
```

```
1
4156.282
```

i ¿Qué significa este número?

El valor no es el peso exacto del pingüino, sino el peso promedio esperado de un pingüino con una aleta de 200 mm.

Moraleja de la historia

Los científicos terminaron con:

- ▶ Un modelo simple pero poderoso
- ▶ Capaz de describir la relación entre tamaño y peso
- ▶ Y también de predecir el peso de nuevos pingüinos
- ▶ Con una estimación razonable de la incertidumbre

¿Qué cambia cuando X es categórica?

Caso: X categórica (ejemplo: especie del pingüino)

Supongamos que los científicos ahora se preguntan:



Nueva pregunta problema

“¿Los pingüinos de distintas especies pesan distinto en promedio?”

Entonces X ya no es numérica, sino categórica con 3 niveles:

- ▶ Adelie
- ▶ Chinstrap
- ▶ Gentoo

Esto cambia completamente la interpretación.

Modelo lineal simple con X categórica

```
mod_cat <- lm(body_mass_g ~ species, data = datos)
summary(mod_cat )
```

Call:

```
lm(formula = body_mass_g ~ species, data = datos)
```

Residuals:

Min	1Q	Median	3Q	Max
-1126.02	-333.09	-33.09	316.91	1223.98

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	3700.66	37.62	98.37	<2e-16 ***
speciesChinstrap	32.43	67.51	0.48	0.631
speciesGentoo	1375.35	56.15	24.50	<2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 462.3 on 339 degrees of freedom

Multiple R-squared: 0.6697, Adjusted R-squared: 0.6677

F-statistic: 343.6 on 2 and 339 DF, p-value: < 2.2e-16

Modelo lineal simple con X categórica

Interpretación

Los científicos comparan especies.

- ▶ Si $\beta_1 > 0$ los Chinstrap pesan más que los Adelie.
- ▶ Si $\beta_1 < 0$ los Chinstrap pesan menos que los Adelie.
- ▶ Igual para β_2 con Gentoo.

El modelo ya no tiene pendiente, sino diferencias de medias entre grupos.

Resumen de la clase

Tema	Idea esencial
Modelo lineal simple	Relación lineal entre una variable respuesta (Y) continua y una sola variable explicativa (X).
Ecuación	$Y = \beta_0 + \beta_1 X + \varepsilon$, recta que resume la tendencia promedio.
(X) continua	β_1 es la pendiente : cambio promedio en (Y) por unidad de (X).
(X) categórica	El modelo compara medias entre grupos; los coeficientes son diferencias respecto al grupo base .
Intercepto	Valor promedio de (Y) cuando (X=0) o para la categoría de referencia.
Interpretación	Describe asociaciones, no causalidad.
Predicción	El modelo entrega valores esperados de (Y) para nuevos valores de (X).