

Fundamentos de ciencia de datos con R - Módulo 6

Clase 4: Regresión lineal multiple

CEPAL - Unidad de Estadísticas Sociales

2025-12-04

Introducción

En la clase anterior aprendimos regresión lineal simple, donde analizamos la relación entre el ingreso y una sola variable explicativa (gasto o pobreza).

Hoy avanzamos hacia la regresión lineal múltiple, donde incorporamos más de una covariable para explicar el ingreso.



Idea principal

La regresión múltiple permite estimar el efecto de cada variable ajustando por las demás, es decir, calculando efectos parciales.

¿Qué es regresión lineal múltiple?

La forma general del modelo es:

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_k X_k + \varepsilon$$

Donde:

- ▶ Y : variable respuesta (continua)
- ▶ $X_1, \dots, X_k$: covariables (categóricas o continuas)
- ▶ β_1 : efecto parcial de la covariable (X_i) sobre (Y)
- ▶ ε : error aleatorio

i Diferencia con regresión simple

En regresión múltiple, los coefficients se interpretan manteniendo constantes todas las demás variables.

Supuestos del modelo múltiple

Supuesto	Explicación breve
Linealidad	Cada relación ($X_i \rightarrow Y$) es lineal en promedio.
Independencia	Las observaciones no están correlacionadas.
Homoscedasticidad	Varianza constante del error.
Normalidad	Los residuos deben ser aproximadamente normales.
No multicolinealidad	Las covariables no deben estar fuertemente correlacionadas entre sí.



Importante

Si dos variables explicativas están muy correlacionadas entre sí, los coeficientes pueden volverse inestables.

Historia: El misterio del precio de las casas en Boston

Pregunta problema

“¿Qué hace que un vecindario sea más costoso que otro?”

Un equipo de planificadores urbanos de Boston estaba intrigado: algunos vecindarios del área metropolitana tenían precios promedio de vivienda dos o tres veces más altos que otros, aun estando relativamente cerca.

- ▶ Tenían una hipótesis inicial: “Los vecindarios más cercanos al centro deben ser más caros.”
- ▶ Pero otra analista intervino: “No solo eso. También influyen la criminalidad, el tamaño promedio de las viviendas, el nivel socioeconómico del barrio...”

En ese momento todos entendieron que:

Para comprender el valor promedio de un vecindario no basta una sola variable. Necesitamos analizar varias a la vez. Por eso aplicaron regresión lineal múltiple.

Datos: el clásico dataset Boston

```
library(MASS)
library(tidyverse)

datos <- Boston %>% as_data_frame() %>% dplyr::select(medv,rm,lstat, crim)

head(datos, 5)
```

medv	rm	lstat	crim	dis
24.0	6.575	4.98	0.00632	4.0900
21.6	6.421	9.14	0.02731	4.9671
34.7	7.185	4.03	0.02729	4.9671
33.4	6.998	2.94	0.03237	6.0622
36.2	7.147	5.33	0.06905	6.0622

Covariables del modelo (Boston Housing)

Variable	Tipo	Qué representa	Por qué es útil en el modelo
medv	Continua (respuesta)	Valor mediano de las viviendas (\$1000 USD)	Es la variable que queremos explicar.
rm	Continua	Número promedio de habitaciones por vivienda	Las casas más grandes suelen valer más.
lstat	Continua	% de población con bajo nivel socioeconómico	Zonas más vulnerables suelen tener menor valor de vivienda.
crim	Continua	Tasa de criminalidad por sector	La seguridad influye en el precio.
dis	Continua	Distancia a centros laborales importantes	Captura accesibilidad: viviendas más cercanas a la ciudad suelen valer más.

El modelo de regresión múltiple

Los analistas plantean:

$$medv = \beta_0 + \beta_1 rm + \beta_2 lstat + \beta_3 crim + \beta_4 dis + \epsilon$$

```
mod_boston <- lm(medv ~ rm + lstat + crim + dis, data = datos)
```


Ajuste del modelo

```
summary(mod_boston)
```

Call:

```
lm(formula = medv ~ rm + lstat + crim + dis, data = datos)
```

Residuals:

Min	1Q	Median	3Q	Max
-19.006	-3.099	-1.047	1.885	26.571

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	2.23065	3.32214	0.671	0.502
rm	4.97649	0.43885	11.340	< 2e-16 ***
lstat	-0.66174	0.05101	-12.974	< 2e-16 ***
crim	-0.12810	0.03209	-3.992	7.53e-05 ***
dis	-0.56321	0.13542	-4.159	3.76e-05 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 5.403 on 501 degrees of freedom

Multiple R-squared: 0.6577, Adjusted R-squared: 0.6549

F-statistic: 240.6 on 4 and 501 DF, p-value: < 2.2e-16

Interpretación del modelo

Después de ajustar el modelo con información de los vecindarios de Boston, los analistas por fin pudieron entender qué factores explican el precio de las viviendas.

El modelo reveló:

- ▶ Más habitaciones (rm) → viviendas claramente más caras. Cada habitación adicional se asocia con un fuerte aumento en el valor.
- ▶ Mayor vulnerabilidad social (lstat) → viviendas más baratas. A mayor porcentaje de hogares de bajo estatus, menor precio promedio.
- ▶ Más criminalidad (crim) → precios más bajos. La inseguridad reduce el atractivo del barrio.
- ▶ Estar lejos del centro (dis) → viviendas menos valiosas. La distancia a las oportunidades económicas importa.

Predicciones con el modelo — “¿Cuánto valdrá en promedio una vivienda en un nuevo vecindario?”

Los urbanistas, emocionados con su modelo, decidieron usarlo como una herramienta predictiva.

Querían estimar el **valor mediano de las viviendas** en un **vecindario hipotético** con estas características promedio:

- ▶ $rm = 6 \rightarrow$ las viviendas del vecindario tienen, en promedio, **6 habitaciones**
- ▶ $lstat = 10 \rightarrow$ alrededor de **10 % de los hogares** son de bajo estatus socioeconómico
- ▶ $crim = 0.05 \rightarrow$ **baja criminalidad** en la zona
- ▶ $dis = 4 \rightarrow$ el vecindario está a una **distancia moderada** de los centros de empleo

Predicciones con el modelo — “¿Cuánto valdrá en promedio una vivienda en un nuevo vecindario?”

```
nuevo_vecindario <- data.frame(  
  rm    = 6,      # promedio de habitaciones  
  lstat = 10,     # % de hogares de bajo estatus  
  crim  = 0.05,   # baja criminalidad  
  dis   = 4       # distancia a centros de empleo  
)  
predict(mod_boston, newdata = nuevo_vecindario)
```

1

23.21302



¿Cómo interpretar esta predicción?

El modelo devuelve el valor mediano esperado de las viviendas (en miles de dólares) en un vecindario con estas características promedio.

Moraleja de la historia

Moraleja

El valor de una vivienda no depende de una sola característica, sino de una combinación de factores físicos, sociales y espaciales.

La regresión múltiple les permitió ver algo que antes no era evidente: un barrio es más que sus casas; es un sistema.

Resumen de la clase

Tema	Definición breve
Regresión múltiple	Relaciona ingreso con varias covariables simultáneamente.
Efecto parcial	Cada coeficiente mide el efecto ajustado por las demás variables.
Variables categóricas	Se convierten en dummies; se compara con una categoría base.
Variables continuas	Interpretación marginal: cambio en ingreso por unidad adicional.