

Fundamentos de ciencia de datos con R - Módulo 6

Clase 5: Regresión logística

CEPAL - Unidad de Estadísticas Sociales

2025-12-04

Introducción

En clases anteriores trabajamos con modelos lineales para predecir el ingreso, una variable continua.

Hoy aprenderemos un modelo para cuando la variable respuesta no es numérica, sino binaria, como:

- ▶ pobre / no pobre
- ▶ tiene empleo / no tiene
- ▶ accede a internet / no accede

Ese modelo es la regresión logística.

Idea principal

La regresión logística modela la probabilidad de que ocurra un evento.

¿Cuándo usar regresión logística?

Tipo de variable Y	Modelo adecuado
Continua	Regresión lineal
Binaria (0/1)	Regresión logística
Categorica multinomial	Regresión multinomial



Muy importante

No se puede usar regresión lineal cuando Y es binaria: predice fuera de 0–1 y viola supuestos.

¿Qué modela la logística?

No modelamos directamente $(P(Y = 1))$, sino el **logit**:

$$\text{logit}(p) = \log\left(\frac{p}{1-p}\right)$$

El modelo toma la forma:

$$\text{logit}(P(Y = 1)) = \beta_0 + \beta_1 X_1 + \dots + \beta_k X_k$$

Y la probabilidad se recupera como:

$$p = \frac{e^\eta}{1 + e^\eta} \quad \text{donde} \quad \eta = \beta_0 + \beta_1 X_1 + \dots + \beta_k X_k$$

Historia: El banco que quería anticipar el incumplimiento

Un banco estaba preocupado porque algunos clientes dejaban de pagar su tarjeta de crédito.

Querían dejar de reaccionar tarde y empezar a **anticipar**:



Pregunta problema

“¿Podemos predecir si un cliente va a incumplir el pago de su tarjeta?”

Disponían de información como:

- ▶ **balance**: saldo promedio en la tarjeta.
- ▶ **income**: ingreso anual del cliente.
- ▶ **student**: si es estudiante o no.
- ▶ **default**: si dejó de pagar (Yes/No).

Aquí la variable de interés es **binaria** → justo el caso para regresión logística.

Datos: clientes de tarjeta de crédito

Usaremos la base `Default` del paquete `ISLR`, que simula datos de clientes de tarjetas de crédito.

```
library(ISLR)
library(tidyverse)

datos <- Default %>%
  as_tibble() %>% mutate(
    default_bin = if_else(default == "Yes", 1, 0)
  )
head(datos, 5)
```

default	student	balance	income	default_bin
No	No	729.5265	44361.63	0
No	Yes	817.1804	12106.13	0
No	No	1073.5492	31767.14	0
No	No	529.2506	35704.49	0
No	No	785.6559	38463.50	0

Modelo logístico: variables del banco

i Variables del modelo

Y (respuesta): default_bin $\rightarrow$ 1 si el cliente incumple, 0 si paga.

X1: balance $\rightarrow$ saldo en la tarjeta (cuanto más debe).

X2: income $\rightarrow$ ingreso anual.

X3: student $\rightarrow$ estudiante / no estudiante.

La regresión logística modela:

$$\text{logit}(P(\text{default} = 1)) = \beta_0 + \beta_1 \cdot \text{balance} + \beta_2 \cdot \text{income} + \beta_3 \cdot \text{student}$$

Ajuste del modelo logístico

```
mod_log <- glm(default_bin ~ balance + income + student,data = datos,
               family = binomial(link = "logit")
)

summary(mod_log)
```

Call:

```
glm(formula = default_bin ~ balance + income + student, family = binomial(link = "logit"),
    data = datos)
```

Coefficients:

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-1.087e+01	4.923e-01	-22.080	< 2e-16 ***
balance	5.737e-03	2.319e-04	24.738	< 2e-16 ***
income	3.033e-06	8.203e-06	0.370	0.71152
studentYes	-6.468e-01	2.363e-01	-2.738	0.00619 **

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

Null deviance: 2920.6 on 9999 degrees of freedom

¿Qué nos dicen los coeficientes?



Lectura de los coeficientes

- ▶ Balance tiene un coeficiente positivo y grande → cuanto mayor es el saldo de la tarjeta, mayor es la probabilidad de incumplimiento, manteniendo constantes el ingreso y la condición de estudiante. Es el predictor más influyente del modelo.
- ▶ Income tiene un coeficiente muy pequeño y no significativo → una vez que controlamos por el saldo, el ingreso ya no aporta información adicional sobre el riesgo de default.
- ▶ Student (Yes) tiene un coeficiente negativo y significativo → ajustando por balance e ingreso, los estudiantes tienen menor probabilidad de incumplir que los no estudiantes.

Odds ratios

Cuando los analistas obtuvieron los coeficientes del modelo, todavía les costaba interpretarlos intuitivamente. Entonces aplicaron una transformación clave: `exp()`, que convierte los coeficientes logit en odds ratios.

Así obtuvieron:

```
odds <- exp(coef(mod_log))  
odds
```

(Intercept)	balance	income	studentYes
1.903854e-05	1.005753e+00	1.000003e+00	5.237317e-01

Odds ratios



Lectura de los odds ratios

- ▶ Balance ($OR = 1.0057$) Por cada dólar adicional de saldo en la tarjeta, los odds de incumplir aumentan en 0.57 %. **Es decir, el riesgo sube ligeramente con cada dólar... pero como los saldos pueden ser miles de dólares, su efecto acumulado es enorme**
- ▶ Income ($OR = 1$) El ingreso prácticamente no cambia los odds de incumplimiento. **Ajustando por el saldo real, ganar más o menos no altera significativamente el riesgo.**
- ▶ StudentYes ($OR = 0.52$) Ser estudiante reduce los odds de default aproximadamente a la mitad respecto a no serlo. **Ajustando por saldo e ingreso, los estudiantes incumplen menos, incluso si su balance es similar.**

Predicción de probabilidades

El banco quiere probabilidades, no solo coeficientes:

```
datos$prob_default <- predict(mod_log, type = "response")
datos %>%
  mutate(prob_default = predict(mod_log, type = "response")) %>%
  dplyr::select(default_bin, balance, prob_default) %>%
  arrange(desc(default_bin)) %>%
  head(5)
```

default_bin	balance	prob_default
1	1486.998	0.0506188
1	2205.800	0.7651368
1	1774.694	0.2186555
1	1889.599	0.5297540
1	1899.391	0.3641724

De probabilidades a clasificación (0/1)

Para tomar decisiones (por ejemplo, aprobar o no una tarjeta), el banco necesita clasificar:

```
cutoff <- 0.5
datos$pred_clase <- if_else(datos$prob_default > cutoff, 1, 0)

table(Real = datos$default_bin, Predicho = datos$pred_clase)
```

Real/Predicho	0	1
0	9627	40
1	228	105

De probabilidades a clasificación (0/1)

Interpretación rápida de la matriz de confusión

- ▶ Verdaderos negativos ($0 \rightarrow 0$): clientes que no incumplen y el modelo lo predice bien.
- ▶ Verdaderos positivos ($1 \rightarrow 1$): clientes que sí incumplen y son bien identificados.
- ▶ Falsos positivos ($0 \rightarrow 1$): el modelo “desconfía de más”, marca riesgo donde no lo hay.
- ▶ Falsos negativos ($1 \rightarrow 0$): los más peligrosos: el modelo dice “tranquilo” pero el cliente incumple.

Exactitud (accuracy)

```
accuracy <- mean(datos$default_bin == datos$pred_clase)
accuracy
```

```
[1] 0.9732
```

Exactitud (accuracy)

La exactitud es la proporción de clientes correctamente clasificados:

$$\text{Accuracy} = \frac{\text{Aciertos}}{\text{Total de Casos}}$$

En problemas de riesgo (como crédito), además de la exactitud suele interesar:

- ▶ la tasa de falsos negativos (incumplimientos no detectados)
- ▶ y la tasa de falsos positivos (clientes buenos que el modelo “castiga”).

Resumen de la clase

Tema	Idea esencial
Regresión logística	Modelo para variables respuesta binarias (0/1).
Logit	Se modela el logaritmo de las odds, no la probabilidad directamente.
Coeficientes	Cada β indica el cambio en el log-odds al variar una covariable.
Odds ratio	$\exp(\beta)$ indica cuánto se multiplican las odds al aumentar una unidad en X.
Predicción	El modelo entrega probabilidades entre 0 y 1.
Clasificación	Requiere elegir un umbral (cutoff) para pasar de probabilidad a 0/1.
Evaluación	Matriz de confusión, exactitud y tipos de error (FP, FN).