

Fundamentos de ciencia de datos con R - Módulo 7

Clase 1: Árboles de clasificación y de regresión

CEPAL - Unidad de Estadísticas Sociales

2025-11-20

Introducción

Los árboles de decisión son modelos predictivos basados en un conjunto de reglas de división que separan los datos en grupos cada vez más homogéneos.

Son ampliamente utilizados porque:

- ▶ No requieren supuestos estadísticos fuertes.
- ▶ Capturan relaciones no lineales.
- ▶ Son fáciles de interpretar y explicar.
- ▶ Funcionan tanto para variables categóricas como numéricas.

Árboles de clasificación y regresión

Los árboles pueden ser de dos tipos:

- ▶ Árboles de clasificación: Cuando la variable objetivo es categórica (por ejemplo, pobreza vs no pobreza).
- ▶ Árboles de regresión: Cuando la variable objetivo es numérica (por ejemplo, ingreso del hogar).

Cómo funciona un árbol

Un árbol se construye dividiendo los datos paso a paso:

- ▶ Nodo raíz: contiene todos los datos.
- ▶ Nodos internos: puntos donde se hace una pregunta (split).
- ▶ Hojas: grupos finales donde se hace la predicción.



Idea principal

Un árbol divide los datos en grupos cada vez más homogéneos.

Árboles de clasificación

En clasificación, cada partición se elige para que los grupos queden lo más “puros” posible (es decir, que predomine una sola clase).

Las medidas más usadas son:

1. Índice Gini

$$G = \sum_k p_k(1 - p_k)$$

2. Entropía

$$H = - \sum_k p_k \log(p_k)$$

Donde p_k es la proporción de casos en la clase k dentro del nodo.

Las divisiones buscan nodos “puros”, es decir, donde una clase domina claramente.

Árboles de regresión

En regresión, en lugar de pureza de clases, nos interesa que los valores de la variable objetivo sean similares dentro de cada nodo.

$$SST = \sum (y_i - \bar{y})^2$$

La regla es:

Buscar particiones que minimicen el error cuadrático medio dentro de cada nodo.

En cada hoja, la predicción es el promedio de la variable objetivo en ese grupo.

Ejemplo práctico: clasificación

Usaremos la base `base_personas_gasto.rds` para predecir si un hogar tiene ingreso bajo.

```
library(tidyverse)
library(rpart)
datos <- readRDS("../Data/base_personas_gasto.rds")

set.seed(123)
muestra <- slice_sample(datos, n = 500) %>%
  mutate(
    ingreso_bajo = if_else(ingreso < median(ingreso, na.rm = TRUE), "Sí",
    ingreso_bajo = factor(ingreso_bajo)
  ) %>%
  select(ingreso_bajo, edad, sexo, gasto_hh, area, pobreza, ingreso)
```

Ejemplo práctico: clasificación

```
head(muestra, 10)
```

ingreso_bajo	edad	sexo	gasto_hh	area	pobreza	ingreso
No	35	Hombre	7236.040	1	3	2412.013
No	65	Mujer	12036.117	2	3	6018.058
Sí	58	Hombre	5414.580	1	3	1804.860
No	27	Hombre	7923.053	1	3	3961.527
No	38	Hombre	9714.580	2	3	3238.193
No	80	Mujer	5728.647	2	3	2864.323
No	58	Hombre	13989.580	1	3	4663.193
Sí	60	Hombre	11139.010	2	3	1856.502
Sí	17	Mujer	13910.910	1	3	1738.864
Sí	19	Hombre	6281.937	1	3	1256.387

Ajuste del árbol de clasificación

Ahora construiremos un árbol que predice si **el hogar tiene ingreso bajo (ingreso_hh)** usando variables socioeconómicas.

```
arbol_clas <- rpart(  
  ingreso_bajo ~ sexo + area + pobreza,  
  data = muestra,  
  method = "class"  
)
```

Ajuste del árbol de clasificación

```
arbol_clas
```

```
n= 500
```

```
node), split, n, loss, yval, (yprob)
```

```
    * denotes terminal node
```

```
1) root 500 250 No (0.5000000 0.5000000)
```

```
  2) pobreza=3 426 187 No (0.5610329 0.4389671)
```

```
    4) area=1 326 125 No (0.6165644 0.3834356) *
```


```
    5) area=2 100  38 Sí (0.3800000 0.6200000) *
```

```
  3) pobreza=1,2 74  11 Sí (0.1486486 0.8513514) *
```

Visualización del árbol

```
library(rpart.plot)
```

```
rpart.plot(arbol_clas, type = 2, extra = 104, under = TRUE,  
main = "Árbol de clasificación: ingreso bajo")
```



Interpretación del árbol



Interpretación

Cada nodo representa una regla de decisión.

Cada hoja representa una predicción basada en la clase mayoritaria del nodo.

Árboles y sobreajuste

Los árboles tienden a sobreajustarse (se vuelven muy complejos y se adaptan demasiado a la muestra).

Para controlar esto se usa la poda (pruning), basada en el parámetro de complejidad (CP):

Árboles y sobreajuste

```
printcp(arbol_clas)
```

Classification tree:

```
rpart(formula = ingreso_bajo ~ sexo + area + pobreza, data = muestra,  
      method = "class")
```

Variables actually used in tree construction:

```
[1] area    pobreza
```

Root node error: 250/500 = 0.5

n= 500

	CP	nsplit	rel error	xerror	xstd
1	0.208	0	1.000	1.088	0.044548
2	0.096	1	0.792	0.792	0.043743
3	0.010	2	0.696	0.696	0.042605

Ejemplo práctico: árbol de regresión

Ahora construiremos un árbol que predice el **ingreso del hogar** (`ingreso_hh`) usando variables socioeconómicas.

```
arbol_reg <- rpart(  
  ingreso ~ sexo + area + pobreza,  
  data = muestra,  
  method = "anova"      # <-- regresión  
)
```

Ejemplo práctico: árbol de regresión

```
arbol_reg
```

```
n= 500
```


```
node), split, n, deviance, yval  
    * denotes terminal node
```

```
1) root 500 10478500000 3508.067  
  2) pobreza=1,2 74 3251636000 2127.462 *  
  3) pobreza=3 426 7061313000 3747.891  
    6) area=2 100 836240800 2683.304 *  
    7) area=1 326 6076972000 4074.451 *
```


Visualización del árbol de regresión

```
library(rpart.plot)

rpart.plot(arbol_reg,type = 2,under = TRUE,
           main = "Árbol de regresión: ingreso del hogar",
           cex = 1.1
           )
```



Interpretación del árbol de regresión

Interpretación (regresión)

Cada nodo representa una regla usada para dividir los datos según valores numéricos.

Cada hoja muestra el promedio del ingreso de los hogares en ese grupo.

El árbol escoge las divisiones que reducen la variabilidad dentro de los nodos.

Conclusiones de la Clase

Tema	Idea principal	Herramienta
Árbol de clasificación	Predice categorías; busca nodos puros (Gini / Entropía)	<code>rpart(method = "class")</code>
Árbol de regresión	Predice valores numéricos; minimiza la variabilidad interna	<code>rpart(method = "anova")</code>
Estructura del árbol	Nodo raíz → nodos internos → hojas; reglas de decisión	—
Criterios de división	Clasificación: pureza; Regresión: menor variabilidad	Automático en <code>rpart</code>
Sobreajuste	Los árboles pueden crecer demasiado	—
Poda (pruning)	Controla el tamaño del árbol mediante el parámetro CP	<code>printcp()</code>