

Fundamentos de ciencia de datos con R - Módulo 7

Clase 1: Árboles de clasificación y de regresión

CEPAL - Unidad de Estadísticas Sociales

2025-11-25

Introducción

Los árboles de decisión son modelos predictivos basados en un conjunto de reglas de división que separan los datos en grupos cada vez más homogéneos.

Son ampliamente utilizados porque:

- ▶ No requieren supuestos estadísticos fuertes.
- ▶ Capturan relaciones no lineales.
- ▶ Son fáciles de interpretar y explicar.
- ▶ Funcionan tanto para variables categóricas como numéricas.

Árboles de clasificación y regresión

Los árboles pueden ser de dos tipos:

- ▶ Árboles de clasificación: Cuando la variable objetivo es categórica (por ejemplo, pobreza vs no pobreza).
- ▶ Árboles de regresión: Cuando la variable objetivo es numérica (por ejemplo, ingreso del hogar).

Cómo funciona un árbol

Un árbol se construye dividiendo los datos paso a paso:

- ▶ Nodo raíz: contiene todos los datos.
- ▶ Nodos internos: puntos donde se hace una pregunta (split).
- ▶ Hojas: grupos finales donde se hace la predicción.



Idea principal

Un árbol divide los datos en grupos cada vez más homogéneos.

Árboles de clasificación

En clasificación, el algoritmo evalúa distintas formas de dividir los datos y selecciona las que producen nodos lo más “puros” posibles (es decir, donde domina una sola categoría).

Las medidas más usadas son:

1. Índice Gini

$$G = \sum_k p_k(1 - p_k)$$

2. Entropía

$$H = - \sum_k p_k \log(p_k)$$

Donde p_k es la proporción de casos en la clase k dentro del nodo.

Las divisiones buscan nodos “puros”, es decir, donde una clase domina claramente.

Árboles de regresión

En regresión, en lugar de pureza de clases, nos interesa que los valores de la variable objetivo sean similares dentro de cada nodo.

$$SST = \sum (y_i - \bar{y})^2$$

La regla es:

Buscar particiones que minimicen el error cuadrático medio dentro de cada nodo.

En cada hoja, la predicción es el promedio de la variable objetivo en ese grupo.

Ejemplo práctico: clasificación

Usaremos la variable dicotómica de pobreza:

- ▶ **1 = pobres** (pobreza extrema o moderada)
- ▶ **0 = no pobres**

Se utilizan todas las observaciones disponibles.

```
library(tidyverse)
library(rpart)

datos <- readRDS("../Data/base_personas_gasto.rds") %>%
  mutate(
    pobreza3 = if_else(pobreza2 %in% c(1,2), "1", "0"),
  ) %>% select(id_hogar, area, pobreza3, ingreso, sexo,
              etnia, edad_hh, anoest_hh)
```

Ejemplo práctico: clasificación

```
head(datos, 10)
```

id_hogar	area	pobreza3	ingreso	sexo	etnia	edad_hh	anoest_hh
262	1	0	5391.527	Hombre	0	4	4
262	1	0	5391.527	Mujer	0	4	3
265	1	0	7077.083	Mujer	0	2	4
265	1	0	7105.557	Hombre	0	2	4
265	1	1	7077.083	Hombre	1	1	1
277	1	0	2418.750	Mujer	0	3	4
277	1	0	2390.277	Mujer	1	2	4
277	1	0	2390.277	Hombre	1	2	3
277	1	0	2418.750	Mujer	1	1	2
288	1	0	1375.000	Hombre	0	4	3

Ajuste del árbol de clasificación

Ahora construiremos un árbol que predice si **el hogar es pobre** usando variables sociodemográficas.


```
arbol_pobreza <- rpart(  
  pobreza3 ~ area + sexo + etnia + edad_hh + anoest_hh,  
  data = datos,  
  method = "class"  
)
```

Visualización del árbol

```
library(rpart.plot)

rpart.plot(arbol_pobreza, type = 2, extra = 104, under = TRUE,
           main = "Árbol de clasificación: pobreza (1 = pobre)")
```

Árbol de clasificación: pobreza (1 = pobre)



Interpretación del árbol



Cómo leer el árbol

El árbol realizó una sola división, usando la variable años de educación (`anoest_hh`), porque:

- ▶ Los hogares con educación mostraron una probabilidad muy baja de pobreza (solo 15 %).
- ▶ Los hogares sin educación presentaron una probabilidad extremadamente alta de pobreza (100 %).

Esta diferencia es tan fuerte y tan clara que el modelo no necesitó más preguntas para separar a pobres y no pobres.

Interpretación del árbol

¿Por qué NO se dividió por área, edad, o sexo?

Porque ninguna de esas variables generaba una diferencia tan marcada en la pobreza como la educación. Es decir:

- ▶ Zona urbana vs rural → diferencias pequeñas.
- ▶ Sexo del jefe → diferencias muy bajas.
- ▶ Edad del jefe del hogar → poca separación entre pobres y no pobres.

En cambio, la educación sí generó dos grupos extremadamente distintos, lo que hace que el algoritmo la tome como la mejor primera división.

Zoom a las predicciones del árbol

Luego de ajustar el modelo, podemos obtener dos tipos de predicciones:

1. La clase predicha (0 = no pobre, 1 = pobre)
2. La probabilidad estimada de ser pobre

Esto permite ver cómo el árbol clasifica a cada hogar según sus características.

Zoom a las predicciones del árbol

```
# Predicción de la clase (0/1)
pred_clase <- predict(arbol_pobreza, type = "class")

# Probabilidad predicha de ser pobre
pred_prob <- predict(arbol_pobreza, type = "prob")[, "1"]

# Unir predicciones a la base original
resultados <- datos %>%
  mutate(
    prediccion = pred_clase,
    prob_pobre = pred_prob
  ) %>%
  select(
    anoest_hh,    pobreza3,
    prediccion, prob_pobre
  )
```

Zoom a las predicciones del árbol

```
head(resultados, 10)
```

anoest_hh	pobreza3	prediccion	prob_pobre
4	0	0	0.1514046
3	0	0	0.1514046
4	0	0	0.1514046
4	0	0	0.1514046
1	1	1	1.0000000
4	0	0	0.1514046
4	0	0	0.1514046
3	0	0	0.1514046
2	0	0	0.1514046
3	0	0	0.1514046

Ejemplo práctico: árbol de regresión

Ahora construiremos un árbol que predice el **ingreso del hogar (ingreso)** usando variables sociodemográficas.


```
arbol_reg <- rpart(  
  ingreso ~ area + sexo + etnia + edad_hh + anoest_hh,  
  data = datos,  
  method = "anova"      # regresión  
)
```


Visualización del árbol de regresión

```
library(rpart.plot)

rpart.plot(arbol_reg,type = 2,under = TRUE,
           main = "Árbol de regresión: ingreso del hogar",
           cex = 1.1
           )
```

Árbol de regresión: ingreso del hogar



Interpretación del árbol de regresión



Interpretación (regresión)

- ▶ Cada nodo aplica una regla para dividir a los hogares según sus características.
- ▶ Cada hoja muestra el ingreso promedio del grupo formado.
- ▶ El árbol elige las divisiones que reducen la variabilidad del ingreso, creando grupos más homogéneos.

En este caso, primero divide por educación, porque es la variable que más diferencia los ingresos, y luego por edad, para refinar aún más la predicción.

Zoom a las predicciones del árbol

```
# Predicción del ingreso para cada hogar
ingreso_pred <- predict(arbol_reg)

# Nodo terminal al que pertenece cada hogar
nodos <- arbol_reg$where

# Tabla limpia de resultados
resultados_reg <- datos %>%
  mutate(
    ingreso_obs = ingreso,
    ingreso_pred = ingreso_pred,
    nodo_terminal = nodos
  ) %>%
  select(nodo_terminal, ingreso_obs, ingreso_pred,
         anoest_hh, edad_hh, area, sexo)
```

Zoom a las predicciones del árbol

```
head(resultados_reg, 10)
```

nodo_terminal	ingreso_obs	ingreso_pred	anoest_hh	edad_hh	area	sexo
5	5391.527	8228.085	4	4	1	Hombre
2	5391.527	2742.892	3	4	1	Mujer
4	7077.083	5197.454	4	2	1	Mujer
4	7105.557	5197.454	4	2	1	Hombre
2	7077.083	2742.892	1	1	1	Hombre
4	2418.750	5197.454	4	3	1	Mujer
4	2390.277	5197.454	4	2	1	Mujer
2	2390.277	2742.892	3	2	1	Hombre
2	2418.750	2742.892	2	1	1	Mujer
2	1375.000	2742.892	3	4	1	Hombre

Zoom a las predicciones del árbol

i ¿Qué vemos en esta tabla?

- ▶ ingreso_obs: ingreso observado del hogar en la base original.
- ▶ ingreso_pred: ingreso que el árbol de regresión predice para ese hogar.
- ▶ nodo_terminal: grupo (hoja) del árbol al que pertenece el hogar, según su perfil sociodemográfico.

Dentro de cada nodo, el modelo asigna un mismo ingreso predicho a todos los hogares, que corresponde al promedio del ingreso en ese grupo.

Esta tabla permite comparar el ingreso real con el ingreso estimado por el modelo y entender cómo el árbol traduce las características del hogar en una predicción numérica.

Resumen de la Clase

Tema	Definición breve	Herramienta
Árbol de clasificación	Predice categorías; divide los datos buscando nodos lo más puros posible.	<code>rpart(method = "class")</code>
Árbol de regresión	Predice valores numéricos; forma grupos con promedios de ingreso homogéneos.	<code>rpart(method = "anova")</code>
Estructura del árbol	Nodo raíz → nodos internos → hojas; cada nodo es una regla de decisión.	—
Criterios de división	Clasificación: pureza (Gini/Entropía). Regresión: menor variabilidad.	Automático en <code>rpart</code>
Predicción final	Cada hoja asigna una clase o un valor promedio a todos los casos del grupo.	—