

Fundamentos de ciencia de datos con R - Módulo 7

Clase 1: Árboles de clasificación y de regresión

CEPAL - Unidad de Estadísticas Sociales

2025-11-17

Introducción

Los árboles de decisión son modelos predictivos basados en un conjunto de reglas de división que separan los datos en grupos cada vez más homogéneos.

Son ampliamente utilizados porque:

- ▶ No requieren supuestos estadísticos fuertes.
- ▶ Capturan relaciones no lineales.
- ▶ Son fáciles de interpretar y explicar.
- ▶ Funcionan tanto para variables categóricas como numéricas.

Árboles de clasificación y regresión

Los árboles pueden ser de dos tipos:

- ▶ Árboles de clasificación: Cuando la variable objetivo es categórica (por ejemplo, pobreza vs no pobreza).
- ▶ Árboles de regresión: Cuando la variable objetivo es numérica (por ejemplo, ingreso del hogar).

Estructura de un árbol de decisión

Un árbol de decisión se compone de:

- ▶ **Nodo raíz:** inicio del árbol, contiene a todas las observaciones.
- ▶ **Nodos internos:** puntos donde se realiza una división (split) de los datos según una variable explicativa.
- ▶ **Hojas o nodos terminales:** segmentos finales donde se entrega la predicción (clase o valor).



Idea Clase

Un árbol segmenta el espacio de las covariables en regiones donde la respuesta es “más homogénea” dentro de cada región.

Árboles de clasificación

Para clasificación, cada partición se elige minimizando medidas de impureza, como:

1. Índice Gini

$$G = \sum_k p_k(1 - p_k)$$

2. Entropía

$$H = - \sum_k p_k \log(p_k)$$

Donde p_k es la proporción de casos en la clase k dentro del nodo.

Las divisiones buscan nodos “puros”, es decir, donde una clase domina claramente.

Árboles de regresión

En regresión la medida que se minimiza es el Error cuadrático (SSE):

$$SST = \sum (y_i - \bar{y})^2$$

La partición óptima minimiza la variabilidad dentro de cada nodo.

Ejemplo práctico: clasificación

Usaremos la base `base_personas_gasto.rds` para predecir si un hogar tiene ingreso bajo.

```
library(tidyverse)
library(rpart)
datos <- readRDS("../Data/base_personas_gasto.rds")

set.seed(123)
muestra <- slice_sample(datos, n = 500) %>%
  mutate(
    ingreso_bajo = if_else(ingreso_hh < median(ingreso_hh, na.rm = TRUE),
    ingreso_bajo = factor(ingreso_bajo)
  ) %>%
  select(ingreso_bajo, edad, sexo, gasto_hh)
```

Ejemplo práctico: clasificación

```
head(muestra, 10)
```

ingreso_bajo	edad	sexo	gasto_hh
Sí	35	Hombre	7236.040
No	65	Mujer	12036.117
Sí	58	Hombre	5414.580
Sí	27	Hombre	7923.053
No	38	Hombre	9714.580
Sí	80	Mujer	5728.647
No	58	Hombre	13989.580
No	60	Hombre	11139.010
No	17	Mujer	13910.910
Sí	19	Hombre	6281.937

Ajuste del árbol de clasificación

```
arbol_clas <- rpart(  
  ingreso_bajo ~ edad + sexo + gasto_hh,  
  data = muestra,  
  method = "class"  
)  
arbol_clas
```

n= 500


node), split, n, loss, yval, (yprob)
* denotes terminal node

- 1) root 500 250 No (0.5000000 0.5000000)
- 2) gasto_hh>=8058.495 250 0 No (1.0000000 0.0000000) *
- 3) gasto_hh< 8058.495 250 0 Sí (0.0000000 1.0000000) *

Visualización del árbol

```
library(rpart.plot)
```

```
rpart.plot(arbol_clas, type = 2, extra = 104, under = TRUE)
```



Interpretación del árbol



Interpretación

Cada nodo representa una regla de decisión.

Cada hoja representa una predicción basada en la clase mayoritaria del nodo.

Árboles y sobreajuste

Los árboles tienden a sobreajustarse: siguen demasiado de cerca los datos de la muestra.

Por eso se utiliza la poda (pruning) basada en el parámetro de complejidad (CP).

```
printcp(arbol_clas)
```

Classification tree:

```
rpart(formula = ingreso_bajo ~ edad + sexo + gasto_hh, data = muestra,  
      method = "class")
```

Variables actually used in tree construction:

```
[1] gasto_hh
```

Root node error: $250/500 = 0.5$

n= 500

CP	nsplit	rel error	xerror	xstd
----	--------	-----------	--------	------