

Fundamentos de ciencia de datos con R - Módulo 7

Clase 1: Árboles de clasificación y de regresión

CEPAL - Unidad de Estadísticas Sociales

2025-12-04

Introducción

Los árboles de decisión son modelos predictivos basados en un conjunto de reglas de división que separan los datos en grupos cada vez más homogéneos.

Son ampliamente utilizados porque:

- ▶ No requieren supuestos estadísticos fuertes.
- ▶ Capturan relaciones no lineales.
- ▶ Son fáciles de interpretar y explicar.
- ▶ Funcionan tanto para variables categóricas como numéricas.

Árboles de clasificación y regresión

Los árboles pueden ser de dos tipos:

- ▶ Árboles de clasificación: Cuando la variable objetivo es categórica (por ejemplo, pobreza vs no pobreza).
- ▶ Árboles de regresión: Cuando la variable objetivo es numérica (por ejemplo, ingreso del hogar).

Cómo funciona un árbol

Un árbol se construye dividiendo los datos paso a paso:

- ▶ Nodo raíz: contiene todos los datos.
- ▶ Nodos internos: puntos donde se hace una pregunta (split).
- ▶ Hojas: grupos finales donde se hace la predicción.



Idea principal

Un árbol divide los datos en grupos cada vez más homogéneos.

Árboles de clasificación

En clasificación, el algoritmo evalúa distintas formas de dividir los datos y selecciona las que producen nodos lo más “puros” posibles (es decir, donde domina una sola categoría).

Las medidas más usadas son:

1. Índice Gini

$$G = \sum_k p_k(1 - p_k)$$

2. Entropía

$$H = - \sum_k p_k \log(p_k)$$

Donde p_k es la proporción de casos en la clase k dentro del nodo.

Las divisiones buscan nodos “puros”, es decir, donde una clase domina claramente.

Árboles de regresión

En regresión, en lugar de pureza de clases, nos interesa que los valores de la variable objetivo sean similares dentro de cada nodo.

$$SST = \sum (y_i - \bar{y})^2$$

La regla es:

Buscar particiones que minimicen el error cuadrático medio dentro de cada nodo.

En cada hoja, la predicción es el promedio de la variable objetivo en ese grupo.

Historia: El botánico que quería identificar especies

Un instituto de botánica recibía cada semana flores enviadas desde distintas regiones del país. Muchas veces llegaban sin etiqueta, y los investigadores perdían horas tratando de clasificar manualmente la especie.

El jefe del laboratorio planteó una pregunta:



Pregunta problema

“¿Podemos construir un modelo que identifique automáticamente la especie de una flor?”

La variable de interés especie (setosa, versicolor, virginica) es categórica → caso ideal para un **árbol de clasificación**.

Datos: flores del conjunto Iris

Para responder la pregunta, el jefe del laboratorio decidió **sistematizar** toda la información que venían recogiendo desde hace años.

Cada vez que llegaba una flor al instituto, los asistentes medían cuidadosamente:

- ▶ el largo y ancho del **sépalo**,
- ▶ el largo y ancho del **pétalo**,
- ▶ y registraban la **especie** confirmada por un experto.

Con el tiempo, fueron construyendo una tabla donde **cada fila es una flor** y **cada columna es una de estas mediciones**.

Datos: flores del conjunto Iris

```
library(tidyverse)

datos_clas <- iris %>%
  as_tibble()

head(datos_clas, 5)
```

Sepal.Length	Sepal.Width	Petal.Length	Petal.Width	Species
5.1	3.5	1.4	0.2	setosa
4.9	3.0	1.4	0.2	setosa
4.7	3.2	1.3	0.2	setosa
4.6	3.1	1.5	0.2	setosa
5.0	3.6	1.4	0.2	setosa

Modelo de árbol de clasificación

i Variables del modelo

Y (respuesta): Species → especie de la flor (setosa, versicolor, virginica).

X (predictores):

- ▶ Sepal.Length → largo del sépalo
- ▶ Sepal.Width → ancho del sépalo
- ▶ Petal.Length → largo del pétalo
- ▶ Petal.Width → ancho del pétalo

Modelo de árbol de clasificación


```
library(rpart)
library(rpart.plot)

set.seed(123)

arbol_clas <- rpart(
  Species ~ Sepal.Length + Sepal.Width + Petal.Length + Petal.Width,
  data      = datos_clas,
  method    = "class"
)
```

Visualización del árbol

```
rpart.plot(arbol_clas,type = 2, extra = 104,fallen.leaves = TRUE)
```



Visualización del árbol

💡 ¿Qué evidenció el jefe al correr el modelo?

Al generar el árbol, el jefe notó tres patrones inmediatos:

1. **Pétalos cortos → setosa**

El primer corte fue `Petal.Length < 2.5`, creando un nodo completamente puro de *setosa*.

La especie se distingue casi automáticamente.

2. **Pétalos largos pero angostos → versicolor**

Entre las flores con pétalos más largos, el modelo separó por `Petal.Width < 1.8`,
revelando que las *versicolor* tienen pétalos más delgados.

3. **Pétalos largos y anchos → virginica**

Cuando ambos atributos son grandes, el árbol clasifica con alta precisión como *virginica*.

El jefe concluyó que **dos preguntas eran suficientes** para identificar la especie de cualquier flor.

Predicción y matriz de confusión

Después de ver el árbol, el jefe del laboratorio quiso asegurarse de que el modelo no solo *luciera* claro, sino que realmente **predijera bien** la especie de las flores. Por eso pidió calcular las **predicciones** del árbol y evaluar su desempeño mediante una **matriz de confusión**, comparando lo predicho con la especie real.

Predicción y matriz de confusión

```
# Predicciones del árbol

datos_clas$pred_arbol <- predict(arbol_clas, type = "class")

# Matriz de confusión

tab_conf <- table(
  Real      = datos_clas$Species,
  Predicho  = datos_clas$pred_arbol
)
```

Predicción y matriz de confusión

tab_conf

Real/Predicho	setosa	versicolor	virginica
setosa	50	0	0
versicolor	0	49	1
virginica	0	5	45

💡 Interpretación rápida de la matriz de confusión

- ▶ Las celdas de la diagonal (setosa→setosa, versicolor→versicolor, etc.) son las flores correctamente clasificadas.
- ▶ Las celdas fuera de la diagonal muestran errores de clasificación (por ejemplo, versicolor predicha como virginica).

Exactitud (accuracy) del árbol

Al revisar la matriz de confusión, el jefe del laboratorio ya podía ver dónde el modelo acertaba y dónde confundía especies.

Pero quiso una medida **resumida y directa** que respondiera a la pregunta clave:

“En promedio, ¿qué tan bien está clasificando el árbol nuestras flores?”

Para eso calculó la **exactitud (accuracy)**, la proporción total de flores correctamente clasificadas por el modelo.

```
accuracy_arbol <- mean(datos_clas$Species == datos_clas$pred_arbol)
```

Exactitud (accuracy) del árbol

```
accuracy_arbol
```

```
[1] 0.96
```

i Exactitud del modelo

En este caso, el árbol logra una exactitud muy alta, lo que significa que:
El instituto puede usar este árbol como una herramienta eficaz para identificar automáticamente la especie de nuevas flores a partir de sus mediciones.

Predicción para una nueva flor

```
nueva_flor <- tibble(  
  Sepal.Length = 5.5,  
  Sepal.Width  = 3.5,  
  Petal.Length = 1.4,  
  Petal.Width  = 0.2  
)  
  
# Clase predicha  
  
predict(arbol_clas, newdata = nueva_flor, type = "class")
```

1

setosa

Levels: setosa versicolor virginica

Predicción para una nueva flor



Cierre de la historia

El botánico ya no necesita clasificar a mano cada flor: introduce las 4 medidas en el modelo y el árbol de clasificación sugiere la especie más probable, con una precisión muy alta.

¿Y cómo sería si Y fuera una variable continua?

i Si la variable Y fuera cuantitativa

Hasta ahora trabajamos con un árbol de clasificación, porque la respuesta era una especie (categoría). Pero si el laboratorio quisiera predecir un valor numérico, por ejemplo:

- ▶ el peso de la flor,
- ▶ la cantidad de néctar,
- ▶ o la longitud esperada del tallo,

entonces el modelo apropiado sería un **árbol de regresión**.

En lugar de buscar nodos “puros” de una clase, el árbol intentaría crear grupos donde los valores numéricos de Y fueran lo más similares posible.

- ▶ Cada división se escogería para minimizar la variabilidad interna (SST).
- ▶ Y en cada hoja, la predicción sería simplemente el promedio de Y en ese nodo.

Así, el árbol ya no “clasifica especies”, sino que estima un número.

Resumen de la Clase

Tema	Definición breve	Herramienta
Árbol de clasificación	Predice categorías; divide los datos buscando nodos lo más puros posible.	<code>rpart(method = "class")</code>
Árbol de regresión	Predice valores numéricos; forma grupos con promedios de ingreso homogéneos.	<code>rpart(method = "anova")</code>
Estructura del árbol	Nodo raíz → nodos internos → hojas; cada nodo es una regla de decisión.	—
Criterios de división	Clasificación: pureza (Gini/Entropía). Regresión: menor variabilidad.	Automático en <code>rpart</code>
Predicción final	Cada hoja asigna una clase o un valor promedio a todos los casos del grupo.	—