

# Fundamentos de ciencia de datos con R - Módulo 7

## Clase 2: Gradient Boosting Machines (GBM)

CEPAL - Unidad de Estadísticas Sociales

2025-11-25

# Introducción

Los Gradient Boosting Machines (GBM) son una familia de modelos que combinan muchos árboles pequeños (débiles) para producir un modelo fuerte y altamente predictivo. Son uno de los métodos más poderosos en machine learning estructurado.

## **¿Por qué funcionan tan bien?**

- ▶ Cada árbol intenta corregir los errores del árbol anterior.
- ▶ Se ajustan de manera secuencial (boosting).
- ▶ Utilizan gradiente descendente para mejorar paso a paso.
- ▶ Permiten controlar el sobreajuste mediante learning rate y profundidad.

# ¿Qué es el Boosting?

## Idea principal

Boosting construye el modelo agregando árboles pequeños, donde cada árbol corrige los errores del modelo anterior.

Proceso simplificado:

- ▶ Empieza con un modelo base (por ejemplo, un valor promedio).
- ▶ Ajusta un árbol pequeño a los residuos del modelo anterior.
- ▶ Actualiza la predicción del modelo:  $\text{Modelo} \leftarrow \text{Modelo anterior} + (\text{learning rate} \times \text{árbol nuevo})$ .
- ▶ Repite 100–1000 veces.

**Resultado:** Un modelo fuerte que combina muchos modelos débiles.

## Componentes importantes

| Componente           | Función                                              |
|----------------------|------------------------------------------------------|
| <b>Learning rate</b> | Qué tanto aprende cada árbol (0.01–0.1 recomendado). |
| <b>n.trees</b>       | Número de árboles (100–3000).                        |
| <b>Depth</b>         | Profundidad de cada árbol (1–6).                     |
| <b>Loss function</b> | Define el error: MSE, Log-loss, MAE                  |
| <b>Subsampling</b>   | Reduce sobreajuste y mejora estabilidad.             |

## Ejemplo práctico en R (Gradient Boosting con gbm)

Vamos a predecir ingreso bajo como ejemplo tipo clasificación.

```
library(tidyverse)

datos <- readRDS("../Data/base_personas_gasto.rds") %>%
  mutate(
    pobreza3 = if_else(pobreza2 %in% c(1,2),1,0),
  ) %>% select(id_hogar,area,pobreza3, ingreso, sexo,
              etnia,edad_hh, anoest_hh)
```

## Ejemplo práctico en R (Gradient Boosting con gbm)

```
head(datos, 10)
```

| id_hogar | area | pobreza3 | ingreso  | sexo   | etnia | edad_hh | anoest_hh |
|----------|------|----------|----------|--------|-------|---------|-----------|
| 262      | 1    | 0        | 5391.527 | Hombre | 0     | 4       | 4         |
| 262      | 1    | 0        | 5391.527 | Mujer  | 0     | 4       | 3         |
| 265      | 1    | 0        | 7077.083 | Mujer  | 0     | 2       | 4         |
| 265      | 1    | 0        | 7105.557 | Hombre | 0     | 2       | 4         |
| 265      | 1    | 1        | 7077.083 | Hombre | 1     | 1       | 1         |
| 277      | 1    | 0        | 2418.750 | Mujer  | 0     | 3       | 4         |
| 277      | 1    | 0        | 2390.277 | Mujer  | 1     | 2       | 4         |
| 277      | 1    | 0        | 2390.277 | Hombre | 1     | 2       | 3         |
| 277      | 1    | 0        | 2418.750 | Mujer  | 1     | 1       | 2         |
| 288      | 1    | 0        | 1375.000 | Hombre | 0     | 4       | 3         |


## Ajuste del modelo GBM para ingreso

```
library(gbm)

modelo_gbm_ing <- gbm(
  formula = ingreso ~ area + sexo + etnia + edad_hh + anoest_hh,
  data = datos,
  distribution = "gaussian", # regresión
  n.trees = 1000,
  interaction.depth = 3,
  shrinkage = 0.05,
  n.minobsinnode = 20
)
```

# Importancia de variables

```
summary(modelo_gbm_ing)
```



| var       |           | rel.inf   |
|-----------|-----------|-----------|
| anoest_hh | anoest_hh | 51.617227 |
| edad_hh   | edad_hh   | 31.125753 |
| sexo      | sexo      | 9.696243  |
| area      | area      | 4.901037  |
| etnia     | etnia     | 2.659740  |



# Importancia de variables

## Interpretación

La **importancia relativa de variables** en un modelo GBM indica cuánto aporta cada variable a reducir el error del modelo a lo largo de todos los árboles.

► **Años de estudio del hogar (anoest\_hh, 53 %)**

Es la variable más influyente. El nivel educativo del hogar es el factor que más ayuda a explicar diferencias en el ingreso.

► **Edad del hogar (edad\_hh, 31 %)**

También tiene un peso importante: hogares en distintas etapas del ciclo de vida presentan niveles de ingreso distintos.

► **Sexo (sexo, 9 %)**

Aporta información adicional, pero con mucho menos peso que educación y edad.

► **Área (area, 5 %) y etnia (etnia, 2 %)**

Tienen una influencia menor en el modelo; ayudan a refinar la predicción, pero no son las variables principales.

## Comparación con un árbol de regresión

```
library(rpart)
arbol_ing <- rpart(
  ingreso ~ area + sexo + etnia + edad_hh + anoest_hh,
  data = datos,
  method = "anova"    # regresión
)

# Predicciones

pred_gbm_ing    <- predict(modelo_gbm_ing, datos, n.trees = 1000)
pred_arbol_ing  <- predict(arbol_ing, datos)

# Función para RMSE

rmse <- function(obs, pred) sqrt(mean((obs - pred)^2))

rmse_gbm    <- rmse(datos$ingreso, pred_gbm_ing)
rmse_arbol  <- rmse(datos$ingreso, pred_arbol_ing)
```

## Comparación con un árbol de regresión

```
tibble(  
  Modelo = c("Árbol simple", "GBM"),  
  RMSE    = c(rmse_arbol, rmse_gbm)  
)
```

| Modelo       | RMSE     |
|--------------|----------|
| Árbol simple | 5566.678 |
| GBM          | 5522.148 |

### Interpretación comparación (ingreso)

El RMSE mide el error promedio en unidades de ingreso:

Un RMSE menor indica un modelo más preciso.

Usualmente el GBM logra un RMSE más bajo que el árbol simple, mostrando que captura mejor las relaciones entre ingreso y variables sociodemográficas.

## Zoom a las predicciones del GBM (ingreso)


```
plot_gbm <- datos %>%  
mutate(  
  ingreso_obs = ingreso,  
  ingreso_pred = pred_gbm_ing  
)  
  
head(plot_gbm, 6)
```

| id_hogar | area | pobreza3 | ingreso  | sexo   | etnia | edad_hh | hanoest_hh | ingreso_obs | ingreso_pred |
|----------|------|----------|----------|--------|-------|---------|------------|-------------|--------------|
| 262      | 1    | 0        | 5391.527 | Hombre | 0     | 4       | 4          | 5391.527    | 9189.703     |
| 262      | 1    | 0        | 5391.527 | Mujer  | 0     | 4       | 3          | 5391.527    | 3165.832     |
| 265      | 1    | 0        | 7077.083 | Mujer  | 0     | 2       | 4          | 7077.083    | 4504.431     |
| 265      | 1    | 0        | 7105.557 | Hombre | 0     | 2       | 4          | 7105.557    | 4796.093     |
| 265      | 1    | 1        | 7077.083 | Hombre | 1     | 1       | 1          | 7077.083    | 1985.852     |
| 277      | 1    | 0        | 2418.750 | Mujer  | 0     | 3       | 4          | 2418.750    | 5982.129     |

# Zoom a las predicciones del GBM (ingreso)

gra1

Ingreso observado vs ingreso predicho (GBM) – Escala logarítmica



## Zoom a las predicciones del GBM (ingreso)

### **i** Interpretación del gráfico (GBM – ingreso)


- ▶ Cada punto es un hogar, en **escala logarítmica** de ingreso.
- ▶ En el eje X está el **ingreso predicho por el GBM** y en el eje Y el **ingreso observado**.
- ▶ La nube de puntos tiene una clara **tendencia creciente**: a mayor ingreso predicho, mayor ingreso observado.
- ▶ La recta azul resume esa relación.
- ▶ La dispersión alrededor de la recta muestra que el modelo no es perfecto, pero sí captura razonablemente el patrón general del ingreso.

## Ajuste del modelo GBM para pobreza

```
modelo_gbm_pob <- gbm(  
  formula = pobreza3 ~ area + sexo + etnia + edad_hh + anoest_hh,  
  data = datos,  
  distribution = "bernoulli",    # clasificación binaria  
  n.trees = 1000,  
  interaction.depth = 3,  
  shrinkage = 0.05,  
  n.minobsinnode = 20  
)
```

# Ajuste del modelo GBM para pobreza

```
summary(modelo_gbm_pob)
```



|           | var       | rel.inf   |
|-----------|-----------|-----------|
| anoest_hh | anoest_hh | 84.273767 |
| edad_hh   | edad_hh   | 9.578659  |
| etnia     | etnia     | 2.432305  |
| sexo      | sexo      | 1.967043  |
| area      | area      | 1.748226  |



# Ajuste del modelo GBM para pobreza

## Importancia (pobreza)

La importancia relativa indica cuánto ayuda cada variable a reducir el error al clasificar hogares pobres (1) y no pobres (0).

Las variables más importantes son las que el GBM usa con mayor frecuencia para separar estos dos grupos.

## Zoom a las predicciones del GBM (pobreza)

```
# Probabilidad predicha de ser pobre
prob_gbm_pob <- predict(
  modelo_gbm_pob,
  datos,
  n.trees = 1000,
  type = "response"
)

# Clasificación 0/1 usando umbral 0.5
clase_gbm_pob <- if_else(prob_gbm_pob > 0.5, 1, 0)

resultados_pob <- datos %>%
  mutate(
    prob_pobre_gbm = prob_gbm_pob,
    pobreza_pred_gbm = clase_gbm_pob
  ) %>%
  select(pobreza3, prob_pobre_gbm, pobreza_pred_gbm,
    area, sexo, edad_hh, anoest_hh)
```

## Zoom a las predicciones del GBM (pobreza)

```
head(resultados_pob, 10)
```

| pobreza3 | prob_pobre_gbm | pobreza_pred_gbm | area | sexo   | edad_hh | anoest_hh |
|----------|----------------|------------------|------|--------|---------|-----------|
| 0        | 0.0859059      | 0                | 1    | Hombre | 4       | 4         |
| 0        | 0.1334835      | 0                | 1    | Mujer  | 4       | 3         |
| 0        | 0.1361730      | 0                | 1    | Mujer  | 2       | 4         |
| 0        | 0.1120693      | 0                | 1    | Hombre | 2       | 4         |
| 1        | 0.9972330      | 1                | 1    | Hombre | 1       | 1         |
| 0        | 0.0770936      | 0                | 1    | Mujer  | 3       | 4         |
| 0        | 0.1708572      | 0                | 1    | Mujer  | 2       | 4         |
| 0        | 0.2253978      | 0                | 1    | Hombre | 2       | 3         |
| 0        | 0.3248884      | 0                | 1    | Mujer  | 1       | 2         |
| 0        | 0.1243240      | 0                | 1    | Hombre | 4       | 3         |

## Zoom a las predicciones del GBM (pobreza)

**i** ¿Qué vemos en esta tabla?

- ▶ pobreza3: pobreza observada (0 = no pobre, 1 = pobre).
- ▶ prob\_pobre\_gbm: probabilidad estimada de ser pobre según el GBM.
- ▶ pobreza\_pred\_gbm: clasificación final según el umbral 0.5.

El GBM asigna una probabilidad distinta a cada hogar, combinando la información de área, sexo, edad, educación y etnia. A partir de esa probabilidad se decide si el hogar se clasifica como pobre o no pobre.

# Ventajas y desventajas de GBM

| Ventajas                                | Desventajas                           |
|-----------------------------------------|---------------------------------------|
| Muy alta precisión                      | Puede ser lento                       |
| Se adapta bien a no-linealidades        | Muchos hiperparámetros                |
| Excelente para variables tabulares      | Fácil de sobreajustar si no se regula |
| Maneja bien interacción entre variables | Menos interpretable que un solo árbol |

## Resumen de la Clase

| Tema              | Idea principal                             | Herramienta                                  |
|-------------------|--------------------------------------------|----------------------------------------------|
| Learning rate     | Controla la velocidad de aprendizaje       | <code>shrinkage</code>                       |
| Número de árboles | A mayor número, mayor capacidad predictiva | <code>n.trees</code>                         |
| Profundidad       | Controla complejidad e interacciones       | <code>interaction.depth</code>               |
| GBM clasificación | Predice categorías                         | <code>gbm(distribution = "bernoulli")</code> |
| GBM regresión     | Predice valores numéricos                  | <code>gbm(distribution = "gaussian")</code>  |