

Fundamentos de ciencia de datos con R - Módulo 7

Clase 2: Gradient Boosting Machines (GBM)

CEPAL - Unidad de Estadísticas Sociales

2025-11-20

Introducción

Los Gradient Boosting Machines (GBM) son una familia de modelos que combinan muchos árboles pequeños (débiles) para producir un modelo fuerte y altamente predictivo. Son uno de los métodos más poderosos en machine learning estructurado.

¿Por qué funcionan tan bien?

- ▶ Cada árbol intenta corregir los errores del árbol anterior.
- ▶ Se ajustan de manera secuencial (boosting).
- ▶ Utilizan gradiente descendente para mejorar paso a paso.
- ▶ Permiten controlar el sobreajuste mediante learning rate y profundidad.

¿Qué es el Boosting?

Idea principal

Boosting construye el modelo agregando árboles pequeños, donde cada árbol corrige los errores del modelo anterior.

Proceso simplificado:

- ▶ Empieza con un modelo base (por ejemplo, un valor promedio).
- ▶ Ajusta un árbol pequeño a los residuos del modelo anterior.
- ▶ Actualiza la predicción del modelo: $\text{Modelo} \leftarrow \text{Modelo anterior} + (\text{learning rate} \times \text{árbol nuevo})$.
- ▶ Repite 100–1000 veces.

Resultado: Un modelo fuerte que combina muchos modelos débiles.

Componentes importantes

Componente	Función
Learning rate	Qué tanto aprende cada árbol (0.01–0.1 recomendado).
n.trees	Número de árboles (100–3000).
Depth	Profundidad de cada árbol (1–6).
Loss function	Define el error: MSE, Log-loss, MAE
Subsampling	Reduce sobreajuste y mejora estabilidad.

Ejemplo práctico en R (Gradient Boosting con gbm)

Vamos a predecir ingreso bajo como ejemplo tipo clasificación.

```
library(tidyverse)
library(rpart)
datos <- readRDS("../Data/base_personas_gasto.rds")

set.seed(123)
muestra <- slice_sample(datos, n = 1000) %>%
  mutate(
    ingreso_bajo = if_else(ingreso < median(ingreso, na.rm = TRUE), 1L, 0L)
  ) %>%
  select(ingreso_bajo, edad, sexo, gasto_hh, area, pobreza, ingreso)
```

Ejemplo práctico en R (Gradient Boosting con gbm)

```
head(muestra, 10)
```

ingreso_bajo	edad	sexo	gasto_hh	area	pobreza	ingreso
0	35	Hombre	7236.040	1	3	2412.013
0	65	Mujer	12036.117	2	3	6018.058
1	58	Hombre	5414.580	1	3	1804.860
0	27	Hombre	7923.053	1	3	3961.527
0	38	Hombre	9714.580	2	3	3238.193
0	80	Mujer	5728.647	2	3	2864.323
0	58	Hombre	13989.580	1	3	4663.193
1	60	Hombre	11139.010	2	3	1856.502
1	17	Mujer	13910.910	1	3	1738.864
1	19	Hombre	6281.937	1	3	1256.387

Ajuste del modelo GBM


```
library(gbm)

muestra$sexo    = as.factor(muestra$sexo)
muestra$area    = as.factor(muestra$area)
muestra$pobreza = as.factor(muestra$pobreza)

modelo_gbm <- gbm(
  formula = ingreso_bajo ~ pobreza + sexo + area,
  data = muestra,
  distribution = "bernoulli",
  n.trees = 1000,
  interaction.depth = 3,
  shrinkage = 0.05,
  n.minobsinnode = 10
)
```

Importancia de variables

```
summary(modelo_gbm)
```



var		rel.inf
pobreza	pobreza	39.23319
area	area	32.29532
sexo	sexo	28.47149

Importancia de variables

Interpretación

La **importancia relativa de variables** en un modelo GBM indica cuánto aporta cada variable a reducir el error del modelo a lo largo de todos los árboles construidos.

- ▶ **pobreza (39 %)**

Es la variable más influyente. El modelo la usa con mayor frecuencia para mejorar la predicción de ingreso bajo.

- ▶ **area (32 %)**

También contribuye de manera importante a separar correctamente los hogares (por ejemplo: urbano vs rural).

- ▶ **sexo (28 %)**

Tiene una influencia menor, pero sigue aportando información útil al modelo.

Predicción y comparación con un árbol tradicional

```
library(rpart)

arbol_simple <- rpart(
  ingreso_bajo ~ edad + sexo + gasto_hh, data = muestra,
  method = "class")

# Predicción GBM

pred_gbm <- predict(modelo_gbm, muestra, n.trees = 1000,
                    type = "response")

# Predicción árbol simple

pred_arbol <- predict(arbol_simple, muestra, type = "prob")[,2]

cor(pred_gbm, pred_arbol)
```

```
[1] 0.3901111
```

Predicción y comparación con un árbol tradicional



Interpretación

correlación 1 $\rightarrow$ ambos modelos hacen predicciones muy similares.

correlación 0 $\rightarrow$ las predicciones no tienen relación entre sí.

correlación -1 $\rightarrow$ predicen exactamente lo contrario.

0.39 = correlación baja-moderada

$\rightarrow$ El GBM está corrigiendo varios errores del árbol simple, por lo que sus probabilidades predichas son diferentes, más complejas y generalmente más precisas.

Ventajas y desventajas de GBM

Ventajas	Desventajas
Muy alta precisión	Puede ser lento
Se adapta bien a no-linealidades	Muchos hiperparámetros
Excelente para variables tabulares	Fácil de sobreajustar si no se regula
Maneja bien interacción entre variables	Menos interpretable que un solo árbol

Resumen de la Clase

Tema	Idea principal	Herramienta
Boosting	Combina muchos árboles pequeños para mejorar error	—
Learning rate	Controla la velocidad de aprendizaje	Parámetro shrinkage
Número de árboles	A mayor número, mayor capacidad predictiva	n.trees
Profundidad	Controla complejidad e interacciones	interaction.depth
GBM clasificación	Predice categorías	gbm(distribution="bernoulli")
GBM regresión	Predice valores numéricos	gbm(distribution="gaussian")