

Fundamentos de ciencia de datos con R - Módulo 7

Clase 4: Random forest

CEPAL - Unidad de Estadísticas Sociales

2025-12-17

Introducción

Los Random Forest son una extensión poderosa de los árboles de decisión. En lugar de entrenar un solo árbol, Random Forest construye muchos árboles, cada uno ligeramente diferente, y luego combina sus predicciones.



Idea principal

Random Forest disminuye el sobreajuste de los árboles individuales al promediar muchos modelos diferentes.

¿Qué es Random Forest?

Un Random Forest es un modelo que combina múltiples árboles de decisión, cada uno entrenado sobre una muestra diferente de los datos y usando subconjuntos aleatorios de variables. La predicción final es una agregación de todas las predicciones individuales.

Construcción de cada árbol

Cada árbol T_b se entrena con una muestra bootstrap del conjunto de datos:

$$D_b \sim \text{Bootstrap}(D)$$

En cada nodo, el árbol elige el mejor split solo entre un subconjunto aleatorio de variables m :

$$m \subseteq \{X_1, X_2, \dots, X_p\}, \quad |m| = \text{mtry}$$

Esto introduce diversidad entre árboles, reduciendo la correlación entre ellos.

Predicción del Random Forest

Para regresión (caso continuo):

La predicción final es el **promedio** de los árboles:

$$\hat{y} = \frac{1}{B} \sum_{b=1}^B T_b(x)$$

Para clasificación:

El Random Forest usa votación mayoritaria:

$$\hat{y} = \text{mode}\{T_1(x), T_2(x), \dots, T_B(x)\}$$

Error OOB (Out-of-Bag)

Cada observación no aparece en $\sim 36\%$ de los bootstraps. Esas observaciones sirven como “test interno”:

$$\text{OOB Error} = \frac{1}{n} \sum_{i=1}^n L(y_i, \hat{y}_{i,\text{OOB}})$$

- ▶ Donde n es el número total de observaciones en el conjunto de datos.
- ▶ L es la función de pérdida (por ejemplo, el error cuadrático medio para regresión o la tasa de clasificación errónea para clasificación).
- ▶ $\hat{y}_{i,\text{OOB}}$ es la predicción para la observación i , obtenida promediando (o votando) **solo** los árboles que no usaron la observación i en su entrenamiento (es decir, aquellos donde i estaba *Out-Of-Bag*).

Importancia de variables

La importancia de una variable X_j se mide por el **Incremento en el Error Cuadrático Medio** (IncMSE_j) después de permutar sus valores en los datos Out-Of-Bag (OOB).

$$\text{IncMSE}_j = \frac{1}{B} \sum_{b=1}^B (\text{MSE}_{b,j}^{\text{perm}} - \text{MSE}_b)$$

i En resumen

Random Forest = bootstrap + submuestreo de variables + muchos árboles + agregación.

Este enfoque reduce la **varianza**, mejora la **estabilidad** del modelo y evita el **sobreajuste** característico de un solo árbol.

Historia: La oficina de calidad del aire que quería anticipar el nivel de ozono

La Oficina de Calidad del Aire enfrentaba un desafío creciente: los niveles de ozono ambiental variaban abruptamente de un día a otro. El director necesitaba una herramienta capaz de anticipar estos niveles para emitir alertas tempranas.

Los modelos lineales que usaban hasta ahora no lograban capturar la complejidad del fenómeno.

El director de monitoreo planteó la pregunta clave:



Pregunta problema

“¿Podemos usar muchos árboles de decisión para predecir el ozono de manera más estable?”

Historia: La oficina de calidad del aire que quería anticipar el nivel de ozono

El equipo decidió probar Random Forest, un método que combina muchos árboles de decisión, cada uno entrenado con una versión ligeramente distinta de los datos.

La idea es simple pero poderosa:

- ▶ Cada árbol aprende una parte del patrón.
- ▶ Todos los árboles juntos producen una predicción estable y robusta.

Datos: mediciones ambientales del conjunto airquality

La oficina contaba con mediciones meteorológicas diarias:

- ▶ Ozone: concentración de ozono (lo que queremos predecir)
- ▶ Solar.R: radiación solar
- ▶ Wind: velocidad del viento
- ▶ Temp: temperatura

El equipo cargó los datos históricos de Nueva York para entrenar el modelo.

Datos: mediciones ambientales del conjunto airquality

```
library(tidyverse)
datos_rf <- airquality %>%
  drop_na() %>%
  as_tibble()

head(datos_rf, 5)
```

Ozone	Solar.R	Wind	Temp	Month	Day
41	190	7.4	67	5	1
36	118	8.0	72	5	2
12	149	12.6	74	5	3
18	313	11.5	62	5	4
23	299	8.6	65	5	7

Separación en entrenamiento y prueba

```
set.seed(123)
n <- nrow(datos_rf)
id_train <- sample(seq_len(n), size = 0.7 * n)

datos_train <- datos_rf[id_train, ]
datos_test  <- datos_rf[-id_train, ]
```

Ajuste del modelo Random Forest

```
library(randomForest)



set.seed(123)

modelo_rf <- randomForest(
  Ozone ~ Solar.R + Wind + Temp,
  data = datos_train,
  ntree = 500,
  mtry = 2,
  importance = TRUE
)
```

Importancia de variables

```
varImpPlot(modelo_rf)
```

modelo_rf



Importancia de variables

💡 Lo que descubrió el director con el gráfico

- ▶ Temperatura (Temp) fue, por lejos, la variable más influyente. Esto confirmó un patrón conocido: los días más cálidos tienden a presentar mayores concentraciones de ozono.
- ▶ Viento (Wind) ocupó el segundo lugar en importancia. Su influencia negativa tenía sentido: el viento dispersa los contaminantes, reduciendo la concentración de ozono en el aire.
- ▶ Radiación solar (Solar.R) también contribuyó, pero en menor medida. Aun así, el director entendió que la formación de ozono depende de procesos fotoquímicos, por lo que su inclusión era coherente.

Predicción de ozono

```
datos_test <- datos_test %>%  
  mutate(Ozone_pred = predict(modelo_rf, newdata = datos_test))  
  
head(datos_test %>% dplyr :: select(Ozone, Ozone_pred), 5)
```

Ozone	Ozone_pred
41	29.10203
36	22.63130
12	15.71107
14	19.58137
18	10.98433

Predicción de ozono

i ¿Qué vio el director al comparar Ozone y Ozone_pred?

Al mirar la tabla, el director notó que las predicciones del Random Forest (**Ozone_pred**) no coinciden exactamente con los valores reales de ozono (**Ozone**), pero **sí están razonablemente cerca**.

Eso es justamente lo que esperamos de un buen modelo de regresión:

- ▶ si fueran iguales número por número → sospecharíamos de sobreajuste;
- ▶ si fueran totalmente diferentes → el modelo no estaría aprendiendo nada.

Aquí las diferencias son moderadas: el bosque no es perfecto, pero **captura bien la tendencia general** de los niveles de ozono.

Evaluación del modelo

```
rmse_rf <- sqrt(mean((datos_test$Ozone - datos_test$Ozone_pred)^2))  
mae_rf  <- mean(abs(datos_test$Ozone - datos_test$Ozone_pred))  
  
c(RMSE = rmse_rf, MAE = mae_rf)
```

RMSE	MAE
21.05305	16.63307



Tip

- ▶ RMSE: cuántas unidades de ozono se equivoca en promedio.
- ▶ MAE: error absoluto promedio.

Gráfico final: Real vs Predicho




Gráfico final: Real vs Predicho



Interpretación visual

Cuando los puntos se acercan a la diagonal, significa que el modelo predice bien. El director vio que la mayoría de puntos caía cerca de la línea → Random Forest estaba listo para usarse en la práctica.

Resumen de la clase

Concepto	Descripción técnica
Random Forest	Ensamble de múltiples árboles entrenados con <i>bootstrap</i> + selección aleatoria de variables (<i>mtry</i>).
Bootstrap	Cada árbol se entrena sobre una muestra con reemplazo del conjunto original. Reduce correlación entre árboles.
Submuestreo de variables	En cada split, solo un subconjunto de variables es evaluado → aumenta diversidad entre árboles.
Predicción	Regresión: $\hat{y} = \frac{1}{B} \sum_{b=1}^B T_b(x)$. Clasificación: votación mayoritaria.
Error OOB	Estimación interna del error: cada observación es predicha por árboles donde no fue usada en entrenamiento.
Importancia de variables	Basada en aumento del MSE por permutación (%IncMSE) o reducción de impureza (IncNodePurity).
Ventajas	No lineal, robusto al sobreajuste, escala bien, maneja interacciones complejas.
Desventajas	Menor interpretabilidad que un árbol simple, mayor costo computacional.