

Fundamentos de ciencia de datos con R - Módulo 7

Clase 2: Gradient Boosting Machines (GBM)

CEPAL - Unidad de Estadísticas Sociales

2025-12-04

Introducción

Los Gradient Boosting Machines (GBM) son una familia de modelos que combinan muchos árboles pequeños (débiles) para producir un modelo fuerte y altamente predictivo. Son uno de los métodos más poderosos en machine learning estructurado.

¿Por qué funcionan tan bien?

- ▶ Cada árbol intenta corregir los errores del árbol anterior.
- ▶ Se ajustan de manera secuencial (boosting).
- ▶ Utilizan gradiente descendente para mejorar paso a paso.
- ▶ Permiten controlar el sobreajuste mediante learning rate y profundidad.

¿Qué es el Boosting?

Idea principal

Boosting construye el modelo agregando árboles pequeños, donde cada árbol corrige los errores del modelo anterior.

Proceso simplificado:

- ▶ Empieza con un modelo base (por ejemplo, un valor promedio).
- ▶ Ajusta un árbol pequeño a los residuos del modelo anterior.
- ▶ Actualiza la predicción del modelo: $\text{Modelo} \leftarrow \text{Modelo anterior} + (\text{learning rate} \times \text{árbol nuevo})$.
- ▶ Repite 100–1000 veces.

Resultado: Un modelo fuerte que combina muchos modelos débiles.

Componentes importantes

Componente	Función
Learning rate	Qué tanto aprende cada árbol (0.01–0.1 recomendado).
n.trees	Número de árboles (100–3000).
Depth	Profundidad de cada árbol (1–6).
Loss function	Define el error: MSE, Log-loss, MAE
Subsampling	Reduce sobreajuste y mejora estabilidad.

Random Forest vs GBM

Aspecto	Random Forest	GBM
Forma de entrenamiento	Muchos árboles en paralelo	Árboles en secuencia
Objetivo principal	Reducir varianza	Reducir sesgo
Construcción	Bootstrap + submuestreo de variables	Ajuste a residuos del árbol previo
Riesgo de sobreajuste	Bajo	Alto si no se ajusta learning rate
Hiperparámetros clave	ntree, mtry	learning_rate, n.trees, depth
Ventaja clave	Robusto, poco tuning	Altísima precisión

Historia: El ingeniero que quería predecir el consumo de combustible

Un centro de investigación automotriz buscaba desarrollar vehículos más eficientes. Tenían acceso a registros detallados de varios modelos de autos: características del motor, peso, cilindros, caballos de fuerza y desempeño general.

El jefe del laboratorio planteó la pregunta clave:



Pregunta problema

“¿Podemos predecir el consumo de combustible de un auto usando sus características mecánicas?”

Historia: El ingeniero que quería predecir el consumo de combustible

La variable objetivo era:

- ▶ mpg → millas por galón (consumo de combustible, variable cuantitativa)

Y contaban con predictores como:

- ▶ hp → caballos de fuerza
- ▶ wt → peso del vehículo
- ▶ cyl → número de cilindros

Este es un caso ideal para un **GBM de regresión**, donde Y es continua.

Datos: autos del conjunto mtcars

```
library(tidyverse)

datos_gbm <- mtcars %>%
  as_tibble()

head(datos_gbm, 5)
```

mpg	cyl	disp	hp	drat	wt	qsec	vs	am	gear	carb
21.0	6	160	110	3.90	2.620	16.46	0	1	4	4
21.0	6	160	110	3.90	2.875	17.02	0	1	4	4
22.8	4	108	93	3.85	2.320	18.61	1	1	4	1
21.4	6	258	110	3.08	3.215	19.44	1	0	3	1
18.7	8	360	175	3.15	3.440	17.02	0	0	3	2

Ajuste de un GBM de regresión


```
library(gbm)

set.seed(123)

modelo_gbm <- gbm(
  formula = mpg ~ hp + wt + cyl,
  data = datos_gbm,
  distribution = "gaussian",    # REGRESIÓN
  n.trees = 1500,
  interaction.depth = 3,
  shrinkage = 0.01,
  n.minobsinnode = 5
)
```

Ajuste de un GBM de regresión

```
summary(modelo_gbm)
```



		rel.inf
var		
hp	hp	43.55666
wt	wt	41.65883
cyl	cyl	14.78451

Ajuste de un GBM de regresión

💡 ¿Qué encontró el jefe al revisar el summary del GBM?

Al revisar el `summary(modelo_gbm)`, el jefe del laboratorio entendió **qué variables estaban impulsando realmente las predicciones del consumo**.

Descubrió que:

- ▶ **hp (caballos de fuerza)** era la variable más influyente: motores más potentes tienden a consumir más combustible.
- ▶ **wt (peso del auto)** aportaba casi la misma importancia que hp, mostrando que los vehículos más pesados requieren mayor energía para moverse.
- ▶ **cyl (cilindros)** también influía, aunque en menor medida, pues parte de su efecto ya se reflejaba en la potencia y el peso.

Evaluación del modelo GBM

Saber qué variables eran importantes no era suficiente.

El jefe del laboratorio quería responder una pregunta muy concreta:

“¿Qué tan cerca están las predicciones del GBM del consumo real (mpg) de cada auto?”

Para ello decidió calcular las **predicciones del modelo** y medir el **error** entre lo predicho y lo observado.

Predicciones del modelo sobre los mismos datos

```
datos_gbm <- datos_gbm %>%  
mutate(  
  mpg_pred = predict(modelo_gbm, n.trees = 1500)  
)  
  
datos_gbm %>%  
dplyr::select(mpg, mpg_pred) %>%  
head(5)
```

mpg	mpg_pred
21.0	21.10225
21.0	20.78987
22.8	26.68934
21.4	20.62135
18.7	18.57019


Predicciones del modelo sobre los mismos datos

Nota

Cada fila muestra el **consumo real** (`mpg`) y el **consumo predicho** (`mpg_pred`) por el GBM.

Si el modelo fuera perfecto, estos dos valores serían casi iguales para todos los autos.

Gráfico: consumo real vs consumo predicho



El jefe observó que la mayoría de puntos se ubicaban cerca de la diagonal, por lo que concluyó que el GBM **capturaba bien el patrón de consumo** en función del peso, los caballos de fuerza y los cilindros.

Métricas de error: RMSE y MAE

```
rmse <- sqrt(mean((datos_gbm$mpg - datos_gbm$mpg_pred)^2))  
mae <- mean(abs(datos_gbm$mpg - datos_gbm$mpg_pred))  
  
c(RMSE = rmse, MAE = mae)
```

RMSE	MAE
1.712000	1.243091

Métricas de error: RMSE y MAE



Interpretación de las métricas de error

► RMSE (Root Mean Squared Error)

Es el error cuadrático medio en la misma escala de mpg.

Indica, en promedio, cuánto se equivoca el modelo en términos de *millas por galón* cuando predice el consumo.

► MAE (Mean Absolute Error)

Mide el error absoluto promedio.

Es más fácil de interpretar:

“En promedio, el modelo se equivoca aproximadamente MAE millas por galón.”

Cuanto **más pequeños** sean RMSE y MAE, **mejor está ajustando** el GBM al consumo real.

¿Qué pasaría si la variable Y fuera categórica?

i GBM para clasificación

Si Y no fuera continua (como mpg) sino **categórica** —por ejemplo, *bajo consumo* / *alto consumo*—

el modelo tendría que cambiar a un **GBM de clasificación**.

¿Qué cambiaría?

- ▶ En `gbm()`, usaríamos
 - ▶ `distribution = "bernoulli"` para 0/1
 - ▶ `distribution = "multinomial"` para más clases
- ▶ Las predicciones ya no serían valores numéricos, sino **probabilidades por clase**.
- ▶ La interpretación pasaría de “*predice X mpg*” a “*predice que este auto tiene un 82 % de probabilidad de ser de alto consumo*”.

Ventajas y desventajas de GBM

Ventajas	Desventajas
Muy alta precisión	Puede ser lento
Se adapta bien a no-linealidades	Muchos hiperparámetros
Excelente para variables tabulares	Fácil de sobreajustar si no se regula
Maneja bien interacción entre variables	Menos interpretable que un solo árbol

Resumen de la Clase

Tema	Qué aprendimos
Boosting	Combina muchos árboles pequeños para corregirse entre sí y formar un modelo fuerte.
GBM de regresión	Usa <i>distribution = "gaussian"</i> y minimiza MSE para predecir valores continuos.
Ejemplo práctico	Predecimos mpg usando hp, wt, cyl del conjunto <i>mtcars</i> .
Importancia de variables	hp y wt resultaron ser los predictores más influyentes; cyl aportó menos.
Evaluación del modelo	Calculamos predicciones, RMSE, MAE y un gráfico real vs. predicho.
¿Y si Y fuera categórica?	Cambiaríamos a <i>distribution = "bernoulli"</i> o <i>"multinomial"</i> , y el modelo predeciría probabilidades , no valores numéricos.