

Fundamentos de ciencia de datos con R - Módulo 7

Clase 4: Redes neuronales

CEPAL - Unidad de Estadísticas Sociales

2025-11-20

Introducción

Las **Redes Neuronales Artificiales (RNA)** son modelos inspirados en el funcionamiento del cerebro humano.

Se utilizan para resolver tareas como clasificación, regresión, reconocimiento de patrones, etc.

La unidad básica es la **neurona artificial**, que recibe entradas, las combina y produce una salida.



Idea principal

Una red neuronal aprende combinaciones no lineales de las variables mediante capas de neuronas. Es especialmente útil cuando las relaciones entre variables son complejas.

¿Cómo funciona una neurona?

Una neurona recibe entradas $x_1, x_2, \dots, x_p$

$$z = w_1x_1 + w_2x_2 + \dots + w_px_p + b$$

Luego aplica una función no lineal $g(z)$:

$$\hat{y} = g(z)$$

Funciones de activación comunes:

► Sigmoide

$$g(z) = \frac{1}{1 + e^{-z}}$$

- ReLU

$$g(z) = \max(0, z)$$

Capas de una red

Una RNA suele tener:

- ▶ Capa de entrada: recibe las variables.
- ▶ Capa(s) oculta(s): hacen transformaciones no lineales.
- ▶ Capa de salida: produce la predicción final.



Interpretación

Cada capa aprende representaciones más abstractas de los datos.

Entrenamiento: Regla general

Las redes se entrenan minimizando una función de error:

$$L = \sum_{i=1}^n (y_i - \hat{y}_i)^2 \quad (\text{regresión})$$

o bien:

$$L = - \sum_{i=1}^n y_i \log(\hat{y}_i) \quad (\text{clasificación binaria})$$

Los pesos se actualizan usando gradiente descendente.

Ejemplo práctico: clasificación de ingreso bajo

Usaremos tres covariables: sexo, área y gasto del hogar

```
library(tidyverse)
library(neuralnet)

datos <- readRDS("../Data/base_personas_gasto.rds")

set.seed(123)
muestra <- datos %>%
  slice_sample(n = 600) %>%
  mutate(
    ingreso_bajo = if_else(ingreso < median(ingreso, na.rm = TRUE),
      1, 0),
    sexo = factor(sexo),
    area = factor(area)
  ) %>%
  select(ingreso_bajo, sexo, area, gasto)
```

Ejemplo práctico: clasificación de ingreso bajo

```
head(muestra, 10)
```

ingreso_bajo	sexo	area	gasto
0	Hombre	1	2412.013
0	Mujer	2	6018.058
1	Hombre	1	1804.860
0	Hombre	1	3961.527
0	Hombre	2	3238.193
0	Mujer	2	2864.323
0	Hombre	1	4663.193
1	Hombre	2	1856.502
1	Mujer	1	1738.864
1	Hombre	1	1256.387

Transformación de variables categóricas a dummies

```
muestra_nn <- model.matrix(ingreso_bajo ~ ., data = muestra) %>% as.data.frame()
muestra_nn$ingreso_bajo <- muestra$ingreso_bajo

head(muestra_nn)
```

(Intercept)	sexoMujer	area2	gasto	ingreso_bajo
1	0	0	2412.013	0
1	1	1	6018.058	0
1	0	0	1804.860	1
1	0	0	3961.527	0
1	0	1	3238.193	0
1	1	1	2864.323	0

Separación en entrenamiento y prueba

```
set.seed(123)
n <- nrow(muestra_nn)
id_train <- sample(seq_len(n), 0.7*n)

train <- muestra_nn[id_train, ]
test  <- muestra_nn[-id_train, ]

train
```

	(Intercept)	sexoMujer	area2	gasto	ingreso_bajo
415	1	0	0	1672.43001	1
463	1	1	0	1622.00001	1
179	1	0	0	2821.01668	0
526	1	0	0	1198.02000	1
195	1	1	1	2168.92834	1
118	1	0	1	1040.26810	1
299	1	1	0	2027.72750	1
229	1	1	0	618.05334	1

Ajuste del modelo de red neuronal

```
set.seed(123)

nn_model <- neuralnet(
  ingreso_bajo ~ sexoMujer + area2 + gasto,
  data = train,
  hidden = c(4, 3), # dos capas ocultas
  act.fct = "logistic",
  linear.output = FALSE
)
```

Visualización de la red

```
a <- plot(nn_model)
a
```

NULL

Predicción

```
pred <- compute(nn_model, test %>% select(-ingreso_bajo))$net.result
pred_class <- ifelse(pred > 0.5, 1, 0)

table(Observado = test$ingreso_bajo, Predicho = pred_class)
```

Observado/Predicho		1
0		91
1		89

Exactitud del modelo

```
mean(pred_class == test$ingreso_bajo)
```

```
[1] 0.4944444
```

Interpretación



Interpretación del modelo

Matriz de confusión:

Muestra cuántas observaciones fueron clasificadas correctamente o incorrectamente.

Exactitud:

Porcentaje de aciertos sobre el total.

Ejemplo: 0.74 significa que la red neuronal acierta el **74 %** de los casos.

Nota:

Las redes requieren más datos que otros modelos y pueden sobreajustar fácilmente si se usan muchas capas.

Resumen de la clase

Tema	Idea principal	Herramienta
Neurona artificial	Combina entradas y aplica no linealidad	—
Capas ocultas	Aprenden representaciones internas	—
Funciones de activación	Sigmoide, ReLU	—
Entrenamiento	Gradiente descendente	—
Red en R	<code>neuralnet()</code>	<code>neuralnet</code>
Evaluación	Matriz de confusión, exactitud	<code>table()</code> , <code>mean()</code>