

Fundamentos de ciencia de datos con R - Módulo 7

Clase 5: Máquinas de soporte Vectorial

CEPAL - Unidad de Estadísticas Sociales

2025-11-20

Introducción

Las Máquinas de Soporte Vectorial (SVM) son modelos diseñados originalmente para **clasificación binaria**, es decir, para separar el espacio de datos en dos clases:

$$y_i \in \{-1, +1\}.$$

La idea esencial es encontrar una **frontera óptima** que divida las dos clases y que maximice el **margen**, es decir, la distancia entre la frontera y las observaciones más cercanas.



Idea principal

Una SVM busca el hiperplano que mejor separa las clases, asegurando el mayor margen. Las observaciones que definen esa frontera se llaman **vectores de soporte**.

SVM lineal: intuición geométrica

Una SVM lineal busca un hiperplano de la forma:

$$f(x) = w^{\top}x + b = 0.$$

La regla de predicción es:

$$\hat{y} = \text{sign}(w^{\top}x + b).$$

SVM lineal: intuición geométrica

El margen geométrico es:

$$\text{margen} = \frac{2}{\|w\|}.$$

Interpretación

Maximizar el margen equivale a minimizar

$$(\|w\|)$$

, lo que da una frontera más estable y generalizable.

Formulación SVM lineal (caso separable)

$$\min_{w,b} \quad \frac{1}{2} \|w\|^2$$

sujeto a:

$$y_i(w^\top x_i + b) \geq 1, \quad i = 1, \dots, n.$$

- ▶ Asegura que cada observación quede del lado correcto.
- ▶ Impone que esté fuera de la banda del margen.

Los puntos que “tocan” la banda son los **vectores de soporte**.

Caso no separable: variables de holgura

Cuando las clases no se pueden separar perfectamente, añadimos

$$(\xi_i)$$

:

$$\min_{w,b,\xi} \quad \frac{1}{2} \|w\|^2 + C \sum_{i=1}^n \xi_i$$

sujeto a:

$$y_i(w^\top x_i + b) \geq 1 - \xi_i, \quad \xi_i \geq 0.$$

Caso no separable: variables de holgura

💡 El parámetro C

- ▶ **C grande** → penaliza mucho los errores → modelo rígido (riesgo de sobreajuste).
- ▶ **C pequeño** → permite más errores → modelo flexible con mejor generalización.

Versión dual y vectores de soporte

La SVM puede escribirse como:

$$f(x) = \sum_{i=1}^n \alpha_i y_i x_i^\top x + b,$$

donde los **vectores de soporte** son los que cumplen:

$$\alpha_i > 0.$$

SVM con kernels

Cuando las clases no pueden separarse linealmente, usamos **kernels**:

$$K(x_i, x_j) = \phi(x_i)^\top \phi(x_j).$$

La función de decisión se convierte en:

$$f(x) = \sum_{i=1}^n \alpha_i y_i K(x_i, x) + b.$$

SVM con kernels

Kernels comunes:

► Lineal

$$K(x_i, x_j) = x_i^\top x_j$$

► Polinómico

$$(\gamma x_i^\top x_j + r)^d$$

► Radial (RBF)

$$K(x_i, x_j) = \exp(-\gamma \|x_i - x_j\|^2)$$

SVM con kernels

Kernels comunes:



Kernel radial (RBF)

El kernel más usado.

Permite fronteras curvas controladas por ().

Ejemplo práctico en R: clasificación binaria con SVM

Vamos a predecir si un hogar tiene **ingreso bajo** usando: sexo, área ,gasto

```
library(tidyverse)
library(e1071)

datos <- readRDS("../Data/base_personas_gasto.rds")
set.seed(123)
muestra <- datos %>%
  slice_sample(n = 600) %>%
  mutate(
    ingreso_bajo = if_else(
      ingreso < median(ingreso, na.rm = TRUE),
      "Sí", "No"
    ),
    ingreso_bajo = factor(ingreso_bajo),
    sexo = factor(sexo),
    area = factor(area)
  ) %>%
  select(ingreso_bajo, sexo, area, gasto, edad)
```

Ejemplo práctico en R: clasificación binaria con SVM

```
head(muestra, 10)
```

ingreso_bajo	sexo	area	gasto	edad
No	Hombre	1	2412.013	35
No	Mujer	2	6018.058	65
Sí	Hombre	1	1804.860	58
No	Hombre	1	3961.527	27
No	Hombre	2	3238.193	38
No	Mujer	2	2864.323	80
No	Hombre	1	4663.193	58
Sí	Hombre	2	1856.502	60
Sí	Mujer	1	1738.864	17
Sí	Hombre	1	1256.387	19

Separación en entrenamiento y prueba

```
set.seed(123)
n <- nrow(muestra)
id_train <- sample(seq_len(n), 0.7*n)

train <- muestra[id_train, ]
test  <- muestra[-id_train, ]

table(train$ingreso_bajo)
```

No	Sí
209	211

```
table(test$ingreso_bajo)
```

No	Sí
91	89

Ajuste del modelo SVM (kernel radial)

```
svm_model <- svm(  
  ingreso_bajo ~ sexo + area + gasto,  
  data      = train,  
  kernel    = "radial",  
  cost      = 1,  
  gamma     = 0.1,  
  scale     = TRUE  
)
```

Predicciones y evaluación

```
pred_svm <- predict(svm_model, newdata = test)

conf_matrix <- table(Observado = test$ingreso_bajo,
Predicho = pred_svm)
conf_matrix
```

Observado/Predicho	No	Sí
No	75	16
Sí	0	89

```
exactitud <- mean(pred_svm == test$ingreso_bajo)
exactitud
```

```
[1] 0.9111111
```


Interpretación



Interpretación del resultado SVM

Matriz de confusión

Muestra cuántos hogares fueron clasificados correctamente o incorrectamente.

Exactitud

Proporción total de aciertos del modelo en el conjunto de prueba.

Por ejemplo, una exactitud de 0.76 indica que el modelo acierta el **76 %** de las predicciones.

Comparación rápida: SVM lineal vs SVM radial

```
svm_linear <- svm(  
  ingreso_bajo ~ sexo + area + gasto,  
  data      = train,  
  kernel    = "linear",  
  cost      = 1,  
  scale     = TRUE  
)  
  
pred_lin <- predict(svm_linear, newdata = test)
```

Comparación rápida: SVM lineal vs SVM radial

```
tibble(  
  modelo      = c("SVM radial", "SVM lineal"),  
  exactitud = c(mean(pred_svm == test$ingreso_bajo),  
    mean(pred_lin == test$ingreso_bajo))  
)
```

modelo	exactitud
SVM radial	0.9111111
SVM lineal	0.9666667

Interpretación

SVM lineal funciona si la frontera es casi recta.

SVM radial funciona mejor cuando la frontera es curva.

Resumen de la clase

Tema	Idea principal	Herramienta
SVM binaria	Separa dos clases con un hiperplano	—
Margen	Distancia entre frontera y puntos más cercanos	—
Vectores de soporte	Observaciones que definen la frontera	—
Kernel radial	Permite fronteras no lineales	<code>kernel="radial"</code>
Evaluación del modelo	Matriz de confusión y exactitud	<code>table()</code> , <code>mean()</code>