

Fundamentos de ciencia de datos con R - Módulo 7

Clase 5: Máquinas de soporte Vectorial

CEPAL - Unidad de Estadísticas Sociales

2025-12-08

Introducción

Las Máquinas de Soporte Vectorial (SVM) son modelos diseñados originalmente para **clasificación binaria**, es decir, para separar el espacio de datos en dos clases:

$$y_i \in \{-1, +1\}.$$

La idea esencial es encontrar una **frontera óptima** que divida las dos clases y que maximice el **margen**, es decir, la distancia entre la frontera y las observaciones más cercanas.



Idea principal

Una SVM busca el hiperplano que mejor separa las clases, asegurando el mayor margen. Las observaciones que definen esa frontera se llaman **vectores de soporte**.

SVM lineal: intuición geométrica

Una SVM lineal busca un hiperplano de la forma:

$$f(x) = w^\top x + b = 0.$$

La regla de predicción es:

$$\hat{y} = \text{sign}(w^\top x + b).$$

SVM lineal: intuición geométrica

El margen geométrico es:

$$\text{margen} = \frac{2}{\|w\|}.$$



Interpretación

Maximizar el margen equivale a minimizar

$$(\|w\|)$$

, lo que da una frontera más estable y generalizable.

Formulación SVM lineal (caso separable)

$$\min_{w,b} \quad \frac{1}{2} \|w\|^2$$

sujeto a:

$$y_i(w^\top x_i + b) \geq 1, \quad i = 1, \dots, n.$$

- ▶ Asegura que cada observación quede del lado correcto.
- ▶ Impone que esté fuera de la banda del margen.

Los puntos que “tocan” la banda son los **vectores de soporte**.

Caso no separable: variables de holgura

Cuando las clases no se pueden separar perfectamente, añadimos

$$(\xi_i)$$

:

$$\min_{w,b,\xi} \quad \frac{1}{2} \|w\|^2 + C \sum_{i=1}^n \xi_i$$

sujeto a:

$$y_i(w^\top x_i + b) \geq 1 - \xi_i, \quad \xi_i \geq 0.$$

Caso no separable: variables de holgura

💡 El parámetro C

- ▶ **C grande** → penaliza mucho los errores → modelo rígido (riesgo de sobreajuste).
- ▶ **C pequeño** → permite más errores → modelo flexible con mejor generalización.

Versión dual y vectores de soporte

La SVM puede escribirse como:

$$f(x) = \sum_{i=1}^n \alpha_i y_i x_i^\top x + b,$$

donde los **vectores de soporte** son los que cumplen:

$$\alpha_i > 0.$$

SVM con kernels

Cuando las clases no pueden separarse linealmente, usamos **kernels**:

$$K(x_i, x_j) = \phi(x_i)^\top \phi(x_j).$$

La función de decisión se convierte en:

$$f(x) = \sum_{i=1}^n \alpha_i y_i K(x_i, x) + b$$

SVM con kernels

Kernels comunes:

► Lineal

$$K(x_i, x_j) = x_i^\top x_j$$

► Polinómico

$$(\gamma x_i^\top x_j + r)^d$$

► Radial (RBF)

$$K(x_i, x_j) = \exp(-\gamma \|x_i - x_j\|^2)$$

SVM con kernels

Kernels comunes:



Kernel radial (RBF)

El kernel más usado.

Permite fronteras curvas controladas por ().

Historia: El equipo que quería distinguir minas de rocas

Un equipo de investigación marina trabajaba con dispositivos de sonar para detectar minas submarinas en zonas de navegación. El sonar emitía pulsos de sonido y registraba el eco devuelto por objetos en el fondo marino.

Cada eco podía ser:

- ▶ Una roca inofensiva (R), o
- ▶ Una mina (M) que representaba un riesgo real.

Historia: El equipo que quería distinguir minas de rocas

Los ingenieros habían logrado registrar, para cada eco de sonar:

- ▶ La energía reflejada en distintas bandas de frecuencia.
- ▶ Un rótulo final asignado por expertos: M (mina) o R (roca).

Sin embargo, al graficar algunos pares de variables, notaban que:

- ▶ En algunos casos, las minas y rocas se mezclaban.
- ▶ No era posible separarlas con una simple línea recta.

Pregunta problema

“¿Podemos construir un modelo que distinga minas de rocas, incluso cuando la frontera de separación es compleja?”

Los ingenieros decidieron entonces aplicar **Máquinas de Soporte Vectorial**.

Datos: Sonar (mlbench)

```
library(mlbench)
data(Sonar)
head(Sonar[1:8],5)
```

V1	V2	V3	V4	V5	V6	V7	V8
0.0200	0.0371	0.0428	0.0207	0.0954	0.0986	0.1539	0.1601
0.0453	0.0523	0.0843	0.0689	0.1183	0.2583	0.2156	0.3481
0.0262	0.0582	0.1099	0.1083	0.0974	0.2280	0.2431	0.3771
0.0100	0.0171	0.0623	0.0205	0.0205	0.0368	0.1098	0.1276
0.0762	0.0666	0.0481	0.0394	0.0590	0.0649	0.1209	0.2467

Preparación de los datos

Al contrastar la metodología para Máquinas de Soporte Vectorial, los ingenieros concluyeron que **el primer paso imprescindible era estandarizar las covariables**.


```
X <- as.data.frame(scale(Sonar[, 1:60])) # predictores estandarizados
y <- Sonar$Class                         # clase: M / R

datos <- cbind(X, Class = y)
head(datos[, 1:8])
```

V1	V2	V3	V4	V5	V6	V7	V8
-	-	-	-	0.3635789	-	0.5203830	0.2971264
0.3985897	0.0405504	0.0268608	0.7133841		0.1010092		
0.7018450	0.4206156	1.0530777	0.3225521	0.7758040	2.6009418	1.5189605	2.5049382
-	0.5996209	1.7192567	1.1693547	0.3995811	2.0882987	1.9640315	2.8455049
0.1289180							
-	-	0.4805802	-	-	-	-	-
0.8335442	0.6473478		0.7176825	0.9847033	1.1465983	0.1933491	0.0845432
2.0458542	0.8544758	0.1110590	-	-	-	-	1.3141291
			0.3114752	0.2916611	0.6711767	0.0137023	

Visualización preliminar (PCA)

El equipo decidió empezar con una SVM lineal, para observar qué tan separables eran las clases en el espacio original.



Visualización preliminar (PCA)

i ¿Qué observaron los analistas en la PCA?

Las observaciones correspondientes a minas y rocas no se separan de forma perfectamente lineal en el plano PCA. Hay zonas de mezcla entre clases, lo que sugiere la necesidad de un clasificador con fronteras no lineales, como una SVM con kernel radial.

SVM con kernel radial (RBF)

```
library(e1071)
svm_rbf <- svm(Class ~ ., data = datos,
kernel = "radial",
cost    = 10,
gamma   = 0.05)

svm_rbf
```

Call:

```
svm(formula = Class ~ ., data = datos, kernel = "radial", cost = 10,
    gamma = 0.05)
```

Parameters:

```
SVM-Type:  C-classification
SVM-Kernel: radial
cost:      10
```

SVM con kernel radial (RBF)

```
pred_rbf <- predict(svm_rbf, datos)
tab_rbf  <- table(Predicho = pred_rbf, Real = datos$Class)
tab_rbf
```

Predicho/Real	M	R
M	111	0
R	0	97

```
acc_rbf <- sum(diag(tab_rbf)) / sum(tab_rbf)
acc_rbf
```

```
[1] 1
```

SVM con kernel radial (RBF)

i ¿Qué observaron los analistas al evaluar el modelo RBF?

Al revisar los resultados del modelo SVM con kernel radial, los analistas notaron un desempeño excepcional: la matriz de confusión mostró que todas las minas fueron correctamente clasificadas como minas y todas las rocas como rocas, sin errores de predicción. Esto se reflejó en una precisión igual a 1, es decir, una clasificación perfecta en el conjunto de entrenamiento.

Vectores de soporte

```
svm_rbf$nSV
```

```
[1] 89 100
```

i ¿Qué observaron los analistas sobre los vectores de soporte?

Al revisar el objeto del modelo, los analistas notaron que la SVM con kernel radial utilizaba **89 vectores de soporte de una clase y 100 de la otra**, es decir, casi todas las observaciones del conjunto de datos participaban en la definición de la frontera de decisión.

Resumen de la clase

Tema	Idea principal	Herramienta
SVM	Modelo para clasificar o predecir valores	<code>svm()</code>
Margen	SVM busca la separación más amplia entre clases	—
Vectores de soporte	Puntos que definen la frontera	—
Kernel radial (RBF)	Permite fronteras curvas	<code>kernel="radial"</code>
Regresión SVM	Predice ingreso y se evalúa con RMSE	RMSE
Clasificación SVM	Predice pobreza (0/1) con umbral 0.5	<code>if_else()</code>
Evaluación	Calidad del modelo via matriz de confusión	<code>table()</code> , <code>mean()</code>