

Fundamentos de ciencia de datos con R - Módulo 8

Clase 1: Componentes principales

CEPAL - Unidad de Estadísticas Sociales

2025-12-05

Introducción

En esta clase veremos Componentes Principales (PCA), una técnica para reducir la dimensionalidad de un conjunto de variables correlacionadas.

Es útil cuando tenemos muchas variables numéricas que contienen información redundante.



Idea principal

PCA identifica nuevas variables (componentes) que resumen la mayor parte de la varianza en los datos.

¿Por qué necesitamos reducir dimensionalidad?

- ▶ Muchas variables → análisis difícil.
- ▶ Variables correlacionadas → información duplicada.
- ▶ Modelos más complejos → mayor riesgo de sobreajuste.



PCA ayuda a...

- ▶ Simplificar
- ▶ Visualizar
- ▶ Encontrar patrones
- ▶ Crear índices o factores sintéticos

Varianza y correlación

PCA se basa en dos conceptos:

- ▶ Varianza: cantidad de información de una variable.
- ▶ Correlación: mide si las variables se mueven juntas.

Cuando existe alta correlación, PCA puede resumir la información en pocos componentes.

Historia: El ministerio que quería resumir demasiados indicadores

El Ministerio de Seguridad gestionaba más de 20 indicadores distintos para evaluar la situación de cada región: tasas de arrestos, violencia, robos, asaltos, armas, etc.

Los analistas estaban abrumados: muchas variables estaban altamente correlacionadas, y entender patrones generales era cada vez más complicado.

El director planteó entonces una pregunta:



Pregunta problema

“¿Podemos resumir todos estos indicadores en unos pocos factores que capturen la mayor parte de la información?”

Historia: El ministerio que quería resumir demasiados indicadores

El equipo de estadística propuso usar Componentes Principales (PCA), una técnica diseñada precisamente para:

- ▶ reducir dimensionalidad,
- ▶ eliminar redundancia,
- ▶ y revelar patrones globales en los datos.

¿Qué hace matemáticamente PCA?

Dado un conjunto de variables centradas en cero:

$$X = \{x_1, x_2, \dots, x_p\}$$

PCA encuentra vectores $w_1, w_2, \dots, w_p$ tales que:

$$PC_1 = w_1^\top X \quad \text{maximiza varianza}$$

bajo la restricción:

$$\|w_1\| = 1$$

El segundo componente:

$$PC_2 = w_2^\top X$$

maximiza varianza bajo la condición de ser **ortogonal** a PC_1 .

Datos: indicadores del conjunto USArrests

```
library(tidyverse)

datos_pca <- USArrests %>%
  as_tibble()

head(datos_pca, 5)
```

Murder	Assault	UrbanPop	Rape
13.2	236	58	21.2
10.0	263	48	44.5
8.1	294	80	31.0
8.8	190	50	19.5
9.0	276	91	40.6

¿Qué dijeron los analistas al ver esta base?

i Observaciones iniciales

- ▶ Las variables están en escalas completamente distintas (por ejemplo, Assault tiene valores mucho más grandes que UrbanPop).
- ▶ Variables como Murder y Assault parecen estar relacionadas.
- ▶ Para que PCA funcione correctamente, hay que evitar que una variable “domine” por su escala.

Los analistas concluyeron que debían estandarizar las variables antes de calcular PCA.

Estandarización de la base

```
datos_scaled <- scale(datos_pca)
head(datos_scaled, 5)
```

Murder	Assault	UrbanPop	Rape
1.2425641	0.7828393	-0.5209066	-0.0034165
0.5078625	1.1068225	-1.2117642	2.4842029
0.0716334	1.4788032	0.9989801	1.0428784
0.2323494	0.2308680	-1.0735927	-0.1849166
0.2782682	1.2628144	1.7589234	2.0678203

Ajuste del PCA

```
pca_model <- prcomp(datos_scaled, center = TRUE, scale. = TRUE)  
  
summary(pca_model)
```

Importance of components:

	PC1	PC2	PC3	PC4
Standard deviation	1.5749	0.9949	0.59713	0.41645
Proportion of Variance	0.6201	0.2474	0.08914	0.04336
Cumulative Proportion	0.6201	0.8675	0.95664	1.00000

Interpretación del PCA según el resumen


💡 ¿Qué descubrieron los analistas al revisar el summary?

- ▶ PC1 explica el 62 % de la variabilidad total. Esto significa que un solo componente resume más de la mitad de toda la información contenida en las cuatro variables originales.
- ▶ PC2 agrega un 24.7 % adicional. Con PC1 + PC2, ya se alcanza 86.7 % de la varianza acumulada. Para los analistas, esto fue una señal clara de que dos componentes eran suficientes para representar casi toda la estructura de los datos.
- ▶ PC3 y PC4 contribuyen muy poco (8.9 % y 4.3 %). Su aportación es marginal y no justificaría incluirlos en un análisis interpretativo o visual.

Conclusión operativa: El equipo podía trabajar con solo dos dimensiones sin perder casi nada de información, simplificando enormemente el análisis posterior.

Scree Plot (gráfico de codo)

```
plot(pca_model, type = "l", main = "Scree Plot")
```



Scree Plot (gráfico de codo)

i ¿Qué muestra el Scree Plot?

- ▶ PC1 y PC2 concentran la mayor parte de la información.
- ▶ A partir de PC3, la varianza adicional es pequeña.
- ▶ El “codo” del gráfico aparece después del segundo componente → señal de que 2 componentes son suficientes.

Loadings (pesos de cada variable)

```
pca_model$rotation
```

	PC1	PC2	PC3	PC4
Murder	-0.5358995	-0.4181809	0.3412327	0.6492278
Assault	-0.5831836	-0.1879856	0.2681484	-0.7434075
UrbanPop	-0.2781909	0.8728062	0.3780158	0.1338777
Rape	-0.5434321	0.1673186	-0.8177779	0.0890243

Loadings (pesos de cada variable)

Interpretación de los loadings


- ▶ **En PC1**, Murder, Assault y Rape tienen cargas grandes y de signo similar. Esto indica que el componente resume un **nivel general de violencia**, donde todas las tasas de delitos se mueven juntas.
- ▶ **En PC2**, la variable con mayor carga es UrbanPop (0.87), mientras que las tasas de delitos aportan menos. Este componente representa principalmente **el grado de urbanización** de cada región.

En conjunto, los analistas concluyeron que:

- ▶ **PC1** **Violencia / Criminalidad general**
- ▶ **PC2** **Urbanización**

Biplot del PCA

```
biplot(pca_model, scale = 0)
```



Biplot del PCA



Interpretación biplot

- ▶ **Murder, Assault y Rape** apuntan en la misma dirección → representan un **eje común de violencia**.
- ▶ **UrbanPop** apunta hacia otra dirección → capta **urbanización**, casi independiente de la violencia.
- ▶ Estados hacia la **derecha (PC1 alto)**: mayor criminalidad.
- ▶ Estados hacia **arriba (PC2 alto)**: mayor urbanización.

En resumen:

PC1 = violencia general

PC2 = urbanización

Moraleja de la historia

Al final, los analistas vieron que PC1 reunía toda la información relacionada con los delitos violentos; las variables Murder, Assault y Rape se movían juntas y el componente actuaba como un resumen del nivel de violencia en cada estado. Por otro lado, PC2 agrupaba principalmente la información de UrbanPop, reflejando diferencias en urbanización.

En síntesis: - PC1 = violencia - PC2 = urbanización

Con solo estos dos componentes lograron capturar casi toda la información relevante.

Resumen de la clase

Concepto	Definición breve
PCA	Técnica que reduce dimensionalidad creando nuevas variables que concentran la varianza.
Componente Principal	Combinación lineal que captura la mayor varianza posible.
Varianza explicada	Proporción de información retenida por cada componente.
Loadings (cargas)	Aporte de cada variable a cada componente.
Biplot	Gráfico que muestra componentes, variables y observaciones simultáneamente.