

Fundamentos de ciencia de datos con R - Módulo 8

Clase 3: Análisis factorial

CEPAL - Unidad de Estadísticas Sociales

2025-12-22

Introducción

El Análisis Factorial (FA) es una técnica multivariada cuyo objetivo es:

- ▶ Identificar factores latentes
- ▶ Explicar las correlaciones entre un conjunto de variables numéricas

Es especialmente útil cuando:

- ▶ Varias variables parecen medir el mismo concepto
- ▶ Existen correlaciones altas entre ellas
- ▶ Queremos sintetizar la información con pocos factores



Idea principal

El análisis factorial busca descubrir estructuras ocultas (factores) que explican por qué un conjunto de variables está correlacionado.

Diferencias con PCA

Tema	PCA	Análisis Factorial
Objetivo	Resumir varianza total	Explicar correlaciones
Modelo	No probabilístico	Probabilístico
Errores	No modela error específico	Separa factor común y error único
Interpretación	Componentes	Factores latentes
Ideal para	Reducción de dimensión	Identificar constructos no observables

Regla práctica

PCA explica la varianza. FA explica las correlaciones.

Modelo general del análisis factorial

El modelo asume que:

$$X = \Lambda F + \epsilon$$

Donde:

- ▶ X = **variables observadas**
- ▶ Λ = matriz de **cargas factoriales**
- ▶ F = **factores comunes**
- ▶ ϵ = **errores únicos**

Interpretación

Cada variable se explica por:

1. Un componente común (factores), y
2. Un componente único o específico (error).

Factores comunes y únicos

- ▶ Factores comunes Afectan simultáneamente a varias variables.
- ▶ Factores únicos Variabilidad particular de cada variable no compartida con otras.

Hipótesis básicas

- ▶ Las variables deben ser continuas.
- ▶ Deben existir correlaciones significativas entre ellas.
- ▶ Cada variable tiene una parte común y otra única.
- ▶ Los factores están correlacionados o no, según el modelo.

Advertencia

Si las variables no están correlacionadas → NO tiene sentido aplicar FA.

Historia: La psicóloga que quería entender el bienestar de los jóvenes

Un equipo de psicometría de una organización internacional buscaba comprender mejor **cómo se organizan los rasgos psicológicos de jóvenes en distintos países.**

Durante meses diseñaron un cuestionario con **25 ítems tipo Likert (1 a 6)**

El objetivo era claro:



Pregunta problema

“¿Podemos descubrir **factores latentes** que expliquen cómo se organizan estos 25 ítems
y así resumirlos en unas pocas dimensiones psicológicas?”

Historia: La psicóloga que quería entender el bienestar de los jóvenes

Era un caso clásico de:

- ▶ Muchas variables numéricas (ítems del cuestionario)
- ▶ Correlacionadas entre sí
- ▶ Donde sospechamos **pocos factores** detrás

Situación ideal para aplicar Análisis Factorial.

Datos: Cuestionario de rasgos psicológicos (bfi)

Para estudiar el problema, el equipo diseñó y aplicó una encuesta a un gran grupo de jóvenes. El cuestionario incluía 25 ítems tipo Likert (1 a 6) relacionados con rasgos psicológicos como responsabilidad, extraversión, neuroticismo, apertura y amabilidad.

Después del trabajo de campo, los investigadores consolidaron una base de datos con más de 2.000 personas. En esta base:

- ▶ Cada fila corresponde a un participante,
- ▶ Cada columna (A1, A2, C1, C2, E1, E2, N1, N2, O1, O2, etc.) representa la respuesta a uno de los ítems del cuestionario.

Datos: Cuestionario de rasgos psicológicos (bfi)

```
library(psych)
# Cargar los datos
data(bfi)

# Filtramos únicamente las 25 variables del cuestionario
items <- bfi[, 1:25]

# Quitamos valores perdidos
items <- na.omit(items)

dim(items)
```

```
[1] 2436    25
```


Matriz de correlaciones

Antes de aplicar FA, verificaron si existe estructura correlacional.

```
R <- cor(items)
```

```
library(corrplot)
```

```
corrplot(R, method = "color", type = "lower", tl.cex = 0.6, number.cex = 0.5)
```



Matriz de correlaciones

i ¿Qué observaron los analistas en el mapa de correlaciones?

Los analistas identificaron un patrón general ordenado en la matriz de correlaciones: se apreciaban zonas de asociación moderada entre grupos de ítems y correlaciones bajas entre grupos distintos. El mapa no mostraba valores extremos ni problemas evidentes, pero sí una estructura suficientemente definida como para indicar la presencia de dimensiones comunes subyacentes.

Pruebas de adecuación para aplicar FA

Test de Bartlett

¿La matriz de correlaciones es distinta de la identidad?

```
bart <- cortest.bartlett(R, n = nrow(items))  
bart
```

```
$chisq
```

```
[1] 18146.07
```

```
$p.value
```

```
[1] 0
```

```
$df
```

```
[1] 300
```

Pruebas de adecuación para aplicar FA

i ¿Qué observaron los analistas en el test de Bartlett?

Al examinar el test de Bartlett, los analistas notaron un estadístico chi-cuadrado muy elevado y un p-valor prácticamente cero. Esto indicó que la matriz de correlaciones era claramente distinta de la identidad y que existía suficiente estructura compartida entre los ítems como para justificar el uso de un análisis factorial.

Pruebas de adecuación para aplicar FA

KMO ¿Los ítems comparten varianza común suficiente?

```
kmo <- KMO(R)
kmo
```

Kaiser-Meyer-Olkin factor adequacy

Call: KMO(r = R)

Overall MSA = 0.85

MSA for each item =

A1	A2	A3	A4	A5	C1	C2	C3	C4	C5	E1	E2	E3	E4	E5
0.75	0.84	0.87	0.88	0.90	0.84	0.80	0.85	0.83	0.86	0.84	0.88	0.90	0.88	0.89
N2	N3	N4	N5	O1	O2	O3	O4	O5						
0.78	0.86	0.89	0.86	0.86	0.78	0.84	0.77	0.76						

Pruebas de adecuación para aplicar FA


i ¿Qué observaron los analistas en el índice KMO?

Los analistas notaron que el índice KMO general alcanzaba un valor alto y que la mayoría de los ítems presentaban medidas de adecuación muestral en rangos favorables. El patrón global sugería que los ítems compartían suficiente varianza común como para permitir la extracción de factores de manera estable.

¿Cuántos factores extraer?

```
fa.parallel(items, fm = "ml", fa = "fa")
```

Parallel Analysis Scree Plots



Parallel analysis suggests that the number of factors = 6 and the number of components = NA

Ajuste del modelo factorial

```
fa_bfi <- fa(items,  
nfactors = 6,  
fm       = "ml",  
rotate   = "oblimin")
```

```
head(fa_bfi,5)
```

\$residual

	A1	A2	A3	A4	A5
A1	0.674933640	-0.0101895971	0.0086961309	0.017173105	1.709891e-02
A2	-0.010189597	0.4821927595	0.0024891673	0.010683163	-2.111042e-02
A3	0.008696131	0.0024891673	0.4734162052	0.023721870	3.697222e-02
A4	0.017173105	0.0106831625	0.0237218700	0.696269527	-1.251776e-02
A5	0.017098914	-0.0211104171	0.0369722238	-0.012517756	5.156235e-01
C1	-0.004416689	-0.0007188593	-0.0061098798	-0.045853692	8.907775e-03
C2	-0.012495117	-0.0046246992	-0.0062110149	0.036263169	-2.504553e-02
C3	0.013625742	0.0421483951	-0.0127345372	-0.054462065	3.412909e-03
C4	0.011775384	0.0230780501	0.0007173472	0.008404168	-1.604697e-02
C5	-0.005976232	0.0204866333	-0.0112801188	-0.041906714	2.983738e-03
E1	0.033671640	-0.0048965469	0.0451287503	0.015941926	2.385451e-02
E2	0.016562839	-0.0006431352	0.0116993574	0.013370578	2.526209e-02
E3	0.007203787	-0.0197386256	0.0218356681	-0.008511462	1.570252e-02
E4	-0.002028814	-0.0130571686	-0.0181031541	0.008993320	2.582535e-02
E5	0.012746255	0.0636964080	-0.0176932332	-0.020875788	-1.359886e-02
N1	0.002311897	-0.0110096985	0.0202083026	0.024010521	-6.972977e-05
N2	0.012744840	0.0095101134	0.0059486603	-0.020070517	1.250608e-02
N3	-0.001273092	-0.0213501626	-0.0079660870	0.009470335	-8.467243e-03
N4	-0.014270924	-0.0024156671	-0.0141939387	-0.019392574	-1.069219e-02
N5	-0.027358966	0.0043717978	-0.0473133848	-0.002209727	-4.200667e-03
O1	0.020887248	0.0213388731	0.0033770807	0.015015588	-1.299052e-02
O2	0.004650076	0.0249324961	-0.0108371795	-0.023664776	-1.072825e-02
O3	-0.014803416	-0.0055273058	0.0053779636	0.001803337	-8.017538e-03
O4	-0.021138546	0.0092015243	-0.0253164506	-0.017479122	2.865738e-03

Cargas factoriales

```
print(fa_bfi$loadings, cutoff = 0.3)
```

Loadings:

	ML2	ML1	ML3	ML5	ML4	ML6
A1				-0.566		
A2				0.709		
A3				0.630		
A4				0.409		
A5				0.455		
C1			0.555			
C2			0.682			
C3			0.560			
C4			-0.662			
C5			-0.551			
E1		0.588				
E2		0.673				
E3		-0.350			0.378	
E4		-0.560				
E5		-0.403				
N1	0.862					
N2	0.854					
N3	0.636					
N4	0.384	0.455				
N5	0.395					
O1				0.554		
O2				-0.429		
O3				0.656		
O4		0.358		0.364		
O5				-0.496	0.341	

	ML2	ML1	ML3	ML5	ML4	ML6
SS loadings	2.321	2.000	1.989	1.766	1.629	0.706
Proportion Var	0.093	0.080	0.080	0.071	0.065	0.028
Cumulative Var	0.093	0.173	0.252	0.323	0.388	0.416

Cargas factoriales

i ¿Qué observaron los analistas en las cargas factoriales y la varianza?

Los analistas advirtieron que la mayoría de los ítems se agrupaban claramente en cinco factores principales, cada uno explicando una proporción razonable de la varianza. Sin embargo, observaron que el sexto factor aportaba muy poco, con una varianza explicada marginal, lo que sugería que no añadía mucho valor adicional al modelo.

Ajuste del modelo factorial 2

```
print(fa_bfi2$loadings, cutoff = 0.3)
```

Loadings:

	ML2	ML5	ML3	ML1	ML4
A1		-0.394			
A2		0.626			
A3		0.688			
A4		0.471			
A5		0.575			
C1			0.542		
C2			0.642		
C3			0.572		
C4			-0.669		
C5			-0.578		
E1				0.564	
E2				0.655	
E3				-0.343	0.331
E4		0.355		-0.537	
E5				-0.393	
N1	0.865				
N2	0.818				
N3	0.664				
N4	0.413			0.435	
N5	0.438				
O1					0.538
O2					-0.461
O3					0.639
O4				0.360	0.367
O5					-0.522
SS loadings	2.428	1.990	1.988	1.862	1.609
Proportion Var	0.097	0.080	0.080	0.074	0.064
Cumulative Var	0.097	0.177	0.256	0.331	0.395

Puntajes factoriales (dimensiones psicológicas por persona)

```
fa5_scores <- fa(items,  
  nfactors = 5,  
  fm       = "ml",  
  rotate   = "oblimin",  
  scores   = "regression")  
  
head(fa5_scores$scores)
```

	ML2	ML5	ML3	ML1	ML4
61617	-0.1368946	-0.8476829	-1.2818229	-0.2550135	-1.6297864
61618	0.0815998	0.0022531	-0.5884780	-0.4596861	-0.1303406
61620	0.7037807	-0.5242594	-0.0619712	-0.1486623	0.2328693
61621	-0.0890108	-0.0002566	-1.0826019	-0.0469290	-1.0221110
61622	-0.2505929	-0.5866460	-0.0868080	-0.5097691	-0.6452909
61623	0.2762325	0.4538981	1.3744784	-1.0307536	0.6742498

Puntajes factoriales (dimensiones psicológicas por persona)

Puntajes factoriales

Una vez obtenidos los puntajes factoriales, el equipo contó con medidas numéricas que resumían cada una de las dimensiones latentes identificadas. Estos puntajes permitieron transformar las respuestas a los 25 ítems en indicadores compactos y comparables entre personas. Con ellos, el equipo pudo:

- ▶ Construir índices psicológicos individuales.
- ▶ Analizar cómo estos rasgos se relacionaban con otros resultados.
- ▶ Identificar perfiles de personalidad.
- ▶ Clasificar grupos de jóvenes según patrones de rasgos.

Los puntajes factoriales ofrecieron al equipo una forma clara y operativa de utilizar la información latente descubierta, convirtiéndola en variables listas para análisis posteriores.

Resumen de la Clase

Tema	Definición breve	Herramienta / Concepto
Objetivo del FA	Identificar factores latentes que explican correlaciones.	Modelo factorial
Modelo general	Variables = cargas $\times$ factores + error único.	$(X = \Lambda F + \epsilon$
Factores comunes	Parte compartida entre variables.	Varianza común
Factores únicos	Variabilidad específica de cada ítem.	Error único
PCA vs FA	PCA resume varianza; FA explica correlaciones.	PCA FA
Adecuación de datos	Evalúa si existe estructura correlacional suficiente.	Bartlett, KMO
Número de factores	Se determina según autovalores y análisis paralelo.	Parallel analysis
Cargas factoriales	Miden el aporte de cada ítem a cada factor.	$f_a()$
Puntajes factoriales	Representan la posición de cada persona en cada dimensión.	Scores = "regression"