

# Fundamentos de ciencia de datos con R - Módulo 8

## Clase 3: Análisis factorial

CEPAL - Unidad de Estadísticas Sociales

2025-12-08

# Introducción

El Análisis Factorial (FA) es una técnica multivariada cuyo objetivo es:

- ▶ Identificar factores latentes
- ▶ Explicar las correlaciones entre un conjunto de variables numéricas

Es especialmente útil cuando:

- ▶ Varias variables parecen medir el mismo concepto
- ▶ Existen correlaciones altas entre ellas
- ▶ Queremos sintetizar la información con pocos factores



## Idea principal

El análisis factorial busca descubrir estructuras ocultas (factores) que explican por qué un conjunto de variables está correlacionado.

# Diferencias con PCA

| Tema           | PCA                        | Análisis Factorial                     |
|----------------|----------------------------|----------------------------------------|
| Objetivo       | Resumir varianza total     | Explicar correlaciones                 |
| Modelo         | No probabilístico          | Probabilístico                         |
| Errores        | No modela error específico | Separa factor común y error único      |
| Interpretación | Componentes                | Factores latentes                      |
| Ideal para     | Reducción de dimensión     | Identificar constructos no observables |

## Regla práctica

PCA explica la varianza. FA explica las correlaciones.

# Modelo general del análisis factorial

El modelo asume que:

$$X = \Lambda F + \epsilon$$

Donde:

- ▶  $X$  = **variables observadas**
- ▶  $\Lambda$  = matriz de **cargas factoriales**
- ▶  $F$  = **factores comunes**
- ▶  $\epsilon$  = **errores únicos**

## Interpretación

Cada variable se explica por:

1. Un componente común (factores), y
2. Un componente único o específico (error).

## Factores comunes y únicos

- ▶ Factores comunes Afectan simultáneamente a varias variables.
- ▶ Factores únicos Variabilidad particular de cada variable no compartida con otras.

# Hipótesis básicas

- ▶ Las variables deben ser continuas.
- ▶ Deben existir correlaciones significativas entre ellas.
- ▶ Cada variable tiene una parte común y otra única.
- ▶ Los factores están correlacionados o no, según el modelo.

## Advertencia

Si las variables no están correlacionadas → NO tiene sentido aplicar FA.

# Historia: La psicóloga que quería entender el bienestar de los jóvenes

Un equipo de psicometría de una organización internacional buscaba comprender mejor **cómo se organizan los rasgos psicológicos de jóvenes en distintos países.**

Durante meses diseñaron un cuestionario con **25 ítems tipo Likert (1 a 6)**

El objetivo era claro:



Pregunta problema

“¿Podemos descubrir **factores latentes** que expliquen cómo se organizan estos 25 ítems  
y así resumirlos en unas pocas dimensiones psicológicas?”

# Historia: La psicóloga que quería entender el bienestar de los jóvenes

Era un caso clásico de:

- ▶ Muchas variables numéricas (ítems del cuestionario)
- ▶ Correlacionadas entre sí
- ▶ Donde sospechamos **pocos factores** detrás

**Situación ideal para aplicar Análisis Factorial.**



## Datos: Cuestionario de rasgos psicológicos (bfi)

Para estudiar el problema, el equipo diseñó y aplicó una encuesta a un gran grupo de jóvenes. El cuestionario incluía 25 ítems tipo Likert (1 a 6) relacionados con rasgos psicológicos como responsabilidad, extraversión, neuroticismo, apertura y amabilidad.

Después del trabajo de campo, los investigadores consolidaron una base de datos con más de 2.000 personas. En esta base:

- ▶ Cada fila corresponde a un participante,
- ▶ Cada columna (A1, A2, C1, C2, E1, E2, N1, N2, O1, O2, etc.) representa la respuesta a uno de los ítems del cuestionario.

## Datos: Cuestionario de rasgos psicológicos (bfi)

```
library(psych)
# Cargar los datos
data(bfi)

# Filtramos únicamente las 25 variables del cuestionario
items <- bfi[, 1:25]

# Quitamos valores perdidos
items <- na.omit(items)

dim(items)
```

```
[1] 2436    25
```


# Matriz de correlaciones

Antes de aplicar FA, verificaron si existe estructura correlacional.

```
R <- cor(items)
```

```
library(corrplot)
```

```
corrplot(R, method = "color", type = "lower", tl.cex = 0.6, number.cex = 0.5)
```



# Matriz de correlaciones

**i** ¿Qué observaron los analistas en el mapa de correlaciones?

Los analistas identificaron un patrón general ordenado en la matriz de correlaciones: se apreciaban zonas de asociación moderada entre grupos de ítems y correlaciones bajas entre grupos distintos. El mapa no mostraba valores extremos ni problemas evidentes, pero sí una estructura suficientemente definida como para indicar la presencia de dimensiones comunes subyacentes.

# Pruebas de adecuación para aplicar FA

## Test de Bartlett

¿La matriz de correlaciones es distinta de la identidad?

```
bart <- cortest.bartlett(R, n = nrow(items))  
bart
```

```
$chisq
```

```
[1] 18146.07
```

```
$p.value
```

```
[1] 0
```

```
$df
```

```
[1] 300
```

# Pruebas de adecuación para aplicar FA

**i** ¿Qué observaron los analistas en el test de Bartlett?

Al examinar el test de Bartlett, los analistas notaron un estadístico chi-cuadrado muy elevado y un p-valor prácticamente cero. Esto indicó que la matriz de correlaciones era claramente distinta de la identidad y que existía suficiente estructura compartida entre los ítems como para justificar el uso de un análisis factorial.

# Pruebas de adecuación para aplicar FA

**KMO** ¿Los ítems comparten varianza común suficiente?

```
kmo <- KMO(R)
kmo
```

Kaiser-Meyer-Olkin factor adequacy

Call: KMO(r = R)

Overall MSA = 0.85

MSA for each item =

| A1   | A2   | A3   | A4   | A5   | C1   | C2   | C3   | C4   | C5   | E1   | E2   | E3   | E4   | E5   |
|------|------|------|------|------|------|------|------|------|------|------|------|------|------|------|
| 0.75 | 0.84 | 0.87 | 0.88 | 0.90 | 0.84 | 0.80 | 0.85 | 0.83 | 0.86 | 0.84 | 0.88 | 0.90 | 0.88 | 0.89 |
| N2   | N3   | N4   | N5   | O1   | O2   | O3   | O4   | O5   |      |      |      |      |      |      |
| 0.78 | 0.86 | 0.89 | 0.86 | 0.86 | 0.78 | 0.84 | 0.77 | 0.76 |      |      |      |      |      |      |

# Pruebas de adecuación para aplicar FA

**i** ¿Qué observaron los analistas en el índice KMO?


Los analistas notaron que el índice KMO general alcanzaba un valor alto y que la mayoría de los ítems presentaban medidas de adecuación muestral en rangos favorables. El patrón global sugería que los ítems compartían suficiente varianza común como para permitir la extracción de factores de manera estable.



# ¿Cuántos factores extraer?

```
fa.parallel(items, fm = "ml", fa = "fa")
```

Parallel Analysis Scree Plots



Parallel analysis suggests that the number of factors = 6 and the number of components = NA

## Ajuste del modelo factorial

```
fa_bfi <- fa(items,  
  nfactors = 6,  
  fm       = "ml",  
  rotate   = "oblimin")
```

```
head(fa_bfi,5)
```

\$residual

|    | A1           | A2            | A3            | A4           | A5            |
|----|--------------|---------------|---------------|--------------|---------------|
| A1 | 0.674933640  | -0.0101895971 | 0.0086961309  | 0.017173105  | 1.709891e-02  |
| A2 | -0.010189597 | 0.4821927595  | 0.0024891673  | 0.010683163  | -2.111042e-02 |
| A3 | 0.008696131  | 0.0024891673  | 0.4734162052  | 0.023721870  | 3.697222e-02  |
| A4 | 0.017173105  | 0.0106831625  | 0.0237218700  | 0.696269527  | -1.251776e-02 |
| A5 | 0.017098914  | -0.0211104171 | 0.0369722238  | -0.012517756 | 5.156235e-01  |
| C1 | -0.004416689 | -0.0007188593 | -0.0061098798 | -0.045853692 | 8.907775e-03  |
| C2 | -0.012495117 | -0.0046246992 | -0.0062110149 | 0.036263169  | -2.504553e-02 |
| C3 | 0.013625742  | 0.0421483951  | -0.0127345372 | -0.054462065 | 3.412909e-03  |
| C4 | 0.011775384  | 0.0230780501  | 0.0007173472  | 0.008404168  | -1.604697e-02 |
| C5 | -0.005976232 | 0.0204866333  | -0.0112801188 | -0.041906714 | 2.983738e-03  |
| E1 | 0.033671640  | -0.0048965469 | 0.0451287503  | 0.015941926  | 2.385451e-02  |
| E2 | 0.016562839  | -0.0006431352 | 0.0116993574  | 0.013370578  | 2.526209e-02  |

# Cargas factoriales

```
print(fa_bfi$loadings, cutoff = 0.3)
```

Loadings:

|    | ML2   | ML1    | ML3    | ML5    | ML4   | ML6 |
|----|-------|--------|--------|--------|-------|-----|
| A1 |       |        |        | -0.566 |       |     |
| A2 |       |        |        | 0.709  |       |     |
| A3 |       |        |        | 0.630  |       |     |
| A4 |       |        |        | 0.409  |       |     |
| A5 |       |        |        | 0.455  |       |     |
| C1 |       |        | 0.555  |        |       |     |
| C2 |       |        | 0.682  |        |       |     |
| C3 |       |        | 0.560  |        |       |     |
| C4 |       |        | -0.662 |        |       |     |
| C5 |       |        | -0.551 |        |       |     |
| E1 |       | 0.588  |        |        |       |     |
| E2 |       | 0.673  |        |        |       |     |
| E3 |       | -0.350 |        |        | 0.378 |     |
| E4 |       | -0.560 |        |        |       |     |
| E5 |       | -0.403 |        |        |       |     |
| N1 | 0.862 |        |        |        |       |     |
| N2 | 0.854 |        |        |        |       |     |
| N3 | 0.636 |        |        |        |       |     |
| N4 | 0.384 | 0.455  |        |        |       |     |
| N5 | 0.395 |        |        |        |       |     |
| O1 |       |        |        | 0.554  |       |     |
| O2 |       |        |        | -0.429 |       |     |
| O3 |       |        |        | 0.656  |       |     |
| O4 |       | 0.358  |        | 0.364  |       |     |
| O5 |       |        |        | -0.496 | 0.341 |     |

|                | ML2   | ML1   | ML3   | ML5   | ML4   | ML6   |
|----------------|-------|-------|-------|-------|-------|-------|
| SS loadings    | 2.321 | 2.000 | 1.989 | 1.766 | 1.629 | 0.706 |
| Proportion Var | 0.093 | 0.080 | 0.080 | 0.071 | 0.065 | 0.028 |
| Cumulative Var | 0.093 | 0.173 | 0.252 | 0.323 | 0.388 | 0.416 |

# Cargas factoriales

**i** ¿Qué observaron los analistas en las cargas factoriales y la varianza?

Los analistas advirtieron que la mayoría de los ítems se agrupaban claramente en cinco factores principales, cada uno explicando una proporción razonable de la varianza. Sin embargo, observaron que el sexto factor aportaba muy poco, con una varianza explicada marginal, lo que sugería que no añadía mucho valor adicional al modelo.

# Ajuste del modelo factorial 2

```
print(fa_bfi2$loadings, cutoff = 0.3)
```

Loadings:

|    | ML2   | ML5    | ML3    | ML1    | ML4    |
|----|-------|--------|--------|--------|--------|
| A1 |       | -0.394 |        |        |        |
| A2 |       | 0.626  |        |        |        |
| A3 |       | 0.688  |        |        |        |
| A4 |       | 0.471  |        |        |        |
| A5 |       | 0.575  |        |        |        |
| C1 |       |        | 0.542  |        |        |
| C2 |       |        | 0.642  |        |        |
| C3 |       |        | 0.572  |        |        |
| C4 |       |        | -0.669 |        |        |
| C5 |       |        | -0.578 |        |        |
| E1 |       |        |        | 0.564  |        |
| E2 |       |        |        | 0.655  |        |
| E3 |       |        |        | -0.343 | 0.331  |
| E4 |       | 0.355  |        | -0.537 |        |
| E5 |       |        |        | -0.393 |        |
| N1 | 0.865 |        |        |        |        |
| N2 | 0.818 |        |        |        |        |
| N3 | 0.664 |        |        |        |        |
| N4 | 0.413 |        |        | 0.435  |        |
| N5 | 0.438 |        |        |        |        |
| O1 |       |        |        |        | 0.538  |
| O2 |       |        |        |        | -0.461 |
| O3 |       |        |        |        | 0.639  |
| O4 |       |        |        | 0.360  | 0.367  |
| O5 |       |        |        |        | -0.522 |

|                | ML2   | ML5   | ML3   | ML1   | ML4   |
|----------------|-------|-------|-------|-------|-------|
| SS loadings    | 2.428 | 1.990 | 1.988 | 1.862 | 1.609 |
| Proportion Var | 0.097 | 0.080 | 0.080 | 0.074 | 0.064 |
| Cumulative Var | 0.097 | 0.177 | 0.256 | 0.331 | 0.395 |

## Puntajes factoriales (dimensiones psicológicas por persona)

```
fa5_scores <- fa(items,  
  nfactors = 5,  
  fm       = "ml",  
  rotate   = "oblimin",  
  scores    = "regression")  
  
head(fa5_scores$scores)
```

|       | ML2        | ML5        | ML3        | ML1        | ML4        |
|-------|------------|------------|------------|------------|------------|
| 61617 | -0.1368946 | -0.8476829 | -1.2818229 | -0.2550135 | -1.6297864 |
| 61618 | 0.0815998  | 0.0022531  | -0.5884780 | -0.4596861 | -0.1303406 |
| 61620 | 0.7037807  | -0.5242594 | -0.0619712 | -0.1486623 | 0.2328693  |
| 61621 | -0.0890108 | -0.0002566 | -1.0826019 | -0.0469290 | -1.0221110 |
| 61622 | -0.2505929 | -0.5866460 | -0.0868080 | -0.5097691 | -0.6452909 |
| 61623 | 0.2762325  | 0.4538981  | 1.3744784  | -1.0307536 | 0.6742498  |

# Puntajes factoriales (dimensiones psicológicas por persona)

## Puntajes factoriales

Una vez obtenidos los puntajes factoriales, el equipo contó con medidas numéricas que resumían cada una de las dimensiones latentes identificadas. Estos puntajes permitieron transformar las respuestas a los 25 ítems en indicadores compactos y comparables entre personas. Con ellos, el equipo pudo:

- ▶ Construir índices psicológicos individuales.
- ▶ Analizar cómo estos rasgos se relacionaban con otros resultados.
- ▶ Identificar perfiles de personalidad.
- ▶ Clasificar grupos de jóvenes según patrones de rasgos.

Los puntajes factoriales ofrecieron al equipo una forma clara y operativa de utilizar la información latente descubierta, convirtiéndola en variables listas para análisis posteriores.

# Resumen de la Clase

| Tema                        | Definición breve                                           | Herramienta / Concepto      |
|-----------------------------|------------------------------------------------------------|-----------------------------|
| <b>Objetivo del FA</b>      | Identificar factores latentes que explican correlaciones.  | Modelo factorial            |
| <b>Modelo general</b>       | Variables = cargas $\times$ factores + error único.        | $(X = \Lambda F + \epsilon$ |
| <b>Factores comunes</b>     | Parte compartida entre variables.                          | Varianza común              |
| <b>Factores únicos</b>      | Variabilidad específica de cada ítem.                      | Error único                 |
| <b>PCA vs FA</b>            | PCA resume varianza; FA explica correlaciones.             | PCA FA                      |
| <b>Adecuación de datos</b>  | Evalúa si existe estructura correlacional suficiente.      | Bartlett, KMO               |
| <b>Número de factores</b>   | Se determina según autovalores y análisis paralelo.        | Parallel analysis           |
| <b>Cargas factoriales</b>   | Miden el aporte de cada ítem a cada factor.                | $f_a()$                     |
| <b>Puntajes factoriales</b> | Representan la posición de cada persona en cada dimensión. | Scores = "regression"       |