

Fundamentos de ciencia de datos con R - Módulo 8

Clase 4: Non-Hierarchical Cluster

CEPAL - Unidad de Estadísticas Sociales

2025-12-09

Introducción

El análisis de clusters es una herramienta de aprendizaje no supervisado cuyo propósito es descubrir estructuras ocultas en los datos. A diferencia de los métodos de clasificación tradicionales, en clustering no existen categorías predefinidas: es el propio algoritmo el que identifica grupos de observaciones similares entre sí.

Entre las diferentes familias de algoritmos, los métodos de clustering no jerárquico (Non-Hierarchical Cluster) son especialmente útiles cuando:

- ▶ se trabaja con bases de datos medianas o grandes,
- ▶ se requieren resultados rápidos y eficientes,
- ▶ se desea obtener k grupos bien definidos,
- ▶ se necesita flexibilidad en la reasignación de observaciones.

En este módulo aprenderemos qué es el clustering no jerárquico, cómo funciona, qué supuestos requiere y cómo aplicarlo a datos reales.

¿Qué es el Non-Hierarchical Cluster?

El clustering no jerárquico es una familia de métodos de partición cuyo objetivo es dividir un conjunto de datos en k grupos previamente especificados, de manera que:

- ▶ las observaciones dentro de un mismo grupo sean lo más similares posible, y
- ▶ las observaciones entre distintos grupos sean lo más diferentes posible.

A diferencia del clustering jerárquico, estos métodos no construyen una estructura en forma de árbol (dendrograma). En su lugar, parten de una asignación inicial de las observaciones a los k grupos y luego iteran reasignando cada elemento para mejorar una medida de calidad, típicamente minimizando la variación interna de cada grupo.

¿Qué es el Non-Hierarchical Cluster?

Entre sus características principales se destacan:

- ▶ Requiere especificar k , el número de grupos deseados.
- ▶ Iterativo: las observaciones pueden cambiar de grupo durante el proceso.
- ▶ Eficiente: adecuado para bases de datos grandes.
- ▶ Flexible: permite actualizar la solución ante nuevos datos.

El algoritmo más conocido de esta familia es k -means, aunque existen otros como k -medoids (PAM) y métodos basados en optimización o distancia.

Diferencia entre Non-Hierarchical Cluster y k-means

Concepto	Qué es	Alcance	Ejemplos incluidos
Non-Hierarchical Cluster	Una familia de métodos	Amplio	k-means, k-medoids (PAM), CLARA, algoritmos de partición, métodos basados en optimización
k-means	Un algoritmo particular dentro de esa familia	Específico	Solo uno de los métodos posibles

Consideraciones generales antes de aplicar clustering

Antes de aplicar cualquier algoritmo de la familia, conviene considerar:

- ▶ Escala de las variables: Distancias como la euclidiana son sensibles a magnitudes distintas.
- ▶ Tipo de variables: Algunos algoritmos requieren variables numéricas.
- ▶ -Presencia de outliers: k-means es sensible; k-medoids es más robusto.
- ▶ Cantidad de clusters k : Se debe decidir antes de ejecutar el algoritmo.

Algoritmo k -medoids (PAM)

El algoritmo Partitioning Around Medoids (PAM), o k -medoids, es una alternativa robusta a k -means. A diferencia de k -means, que usa el centroide (media) como centro del cluster, k -medoids utiliza un punto de datos real, llamado medoide, como representante del grupo.

El funcionamiento general es:

1. Seleccionar k observaciones como medoides iniciales.
2. Asignar cada observación al medoide más cercano.
3. Probar intercambios entre medoides y observaciones para mejorar la calidad.
4. Repetir hasta que no mejore la solución.

Historia: El cantón que quería entender sus regiones

Un equipo de estadística territorial en Suiza trabajaba con información socioeconómica de 47 provincias: tasa de fertilidad, nivel de educación, proporción de profesiones agrícolas, porcentaje de católicos y nivel de ejército.

El ministro planteó la siguiente inquietud:



Pregunta problema

“¿Podemos identificar tipos de regiones sin definir categorías de antemano, para orientar políticas sociales y educativas?”

El equipo decidió aplicar clustering no jerárquico, usando k-medoids, debido a su robustez e interpretabilidad.

Base utilizada: swiss

El conjunto swiss contiene:

- ▶ 47 observaciones (provincias)
- ▶ 5 variables numéricas: Fertility, Agriculture, Examination, Education, Catholic, Infant.Mortality

```
head(swiss, 5)
```

	Fertility	Agriculture	Examination	Education	Catholic	Infant.Mortality
Courtelary	80.2	17.0	15	12	9.96	22.2
Delemont	83.1	45.1	6	9	84.84	22.2
Franches-Mnt	92.5	39.7	5	5	93.40	20.2
Moutier	85.8	36.5	12	7	33.77	20.3
Neuveville	76.9	43.5	17	15	5.16	20.6

Estandarización de la base

```
swiss_scaled <- scale(swiss)
round(head(swiss_scaled, 5), 3)
```

	Fertility	Agriculture	Examination	Education	Catholic	Infant.Mortality
Courtelary	0.805	-1.482	-0.187	0.106	-0.748	0.775
Delemont	1.037	-0.245	-1.315	-0.206	1.048	0.775
Franches-Mnt	1.790	-0.483	-1.440	-0.622	1.253	0.088
Moutier	1.253	-0.623	-0.563	-0.414	-0.177	0.123
Neuveville	0.541	-0.315	0.064	0.418	-0.863	0.226

Aplicación del método k-medoids (PAM)

El equipo decidió explorar $k = 3$ clusters, suponiendo que podrían existir:

- ▶ regiones más urbanizadas/educadas,
- ▶ regiones más agrícolas,
- ▶ regiones más tradicionales.

Ejecutaron PAM:

```
library(cluster)
modelo_pam <- pam(swiss_scaled, k = 3)
```

```
modelo_pam$clustering
```

Courtellary	Delemont	Franches-Mnt	Moutier	Neuveville	Porrentruy
1	2	2	1	1	2
Broye	Glane	Gruyere	Sarine	Veveyse	Aigle
2	2	2	2	2	1
Aubonne	Avenches	Cossonay	Echallens	Grandson	Lausanne
1	1	1	1	1	3
La Vallee	Lavaux	Morges	Moudon	Nyone	Orbe
3	1	1	1	1	1
Oron	Payerne	Paysd'enhaut	Rolle	Vevey	Yverdon
1	1	1	1	3	1
Conthey	Entremont	Herens	Martigwy	Monthey	St Maurice
2	2	2	2	2	2
Sierre	Sion	Boudry	La Chauxdfnd	Le Locle	Neuchatel
2	2	1	1	1	3
Val de Ruz	ValdeTravers	V. De Geneve	Rive Droite	Rive Gauche	
1	1	3	3	3	

¿Qué encontraron los analistas?

Interpretación

Los clusters correspondían aproximadamente a:

1. Regiones con mayor educación, menor fertilidad y menor agricultura
2. Regiones agrícolas tradicionales con mayor fertilidad
3. Regiones con alta influencia católica y variabilidad intermedia en educación

Estos grupos surgieron de forma automática, sin categorías predefinidas.

Medoides: las provincias representativas

```
round(modelo_pam$medoids,3)
```

	Fertility	Agriculture	Examination	Education	Catholic	Infant.Mortality
Grandson	0.125	-0.734	0.064	-0.31	-0.907	0.020
Monthey	0.741	0.627	-1.189	-0.83	1.369	0.088
Lausanne	-1.156	-1.376	1.192	1.77	-0.696	0.088

Cada medoide corresponde a una provincia real, representando:

- ▶ la región típica del cluster,
- ▶ un ejemplo concreto para interpretar políticas,
- ▶ un perfil observacional real y no un centroide abstracto.

Evaluación del clustering: silhouette

Para evaluar la calidad del agrupamiento:

```
head(silhouette(modelo_pam) %>% as.data.frame(),10)
```

	cluster	neighbor	sil_width
Morges	1	2	0.5152814
Grandson	1	2	0.5081113
Cossonay	1	2	0.4759005
Lavaux	1	2	0.4600963
Aigle	1	3	0.4476789
Aubonne	1	2	0.4424008
Yverdon	1	2	0.4419693
Val de Ruz	1	2	0.4368198
Neuveville	1	2	0.4359583
Rolle	1	2	0.4329730

Evaluación del clustering: silhouette

Interpretación del silhouette

Valores $> 0.5 \rightarrow$ clustering claro

Valores cercanos a 0 $\rightarrow$ posible solapamiento

Valores negativos $\rightarrow$ mala asignación

El promedio silhouette para swiss mostró una separación adecuada, indicando buena estructura entre los grupos.

Moraleja de la historia

El equipo suizo logró identificar tres tipos de regiones:

- ▶ Provincias modernas con alta educación
- ▶ Provincias agrícolas tradicionales
- ▶ Provincias con fuerte componente religioso

Sin usar etiquetas previas, k-medoids reveló patrones útiles para segmentar políticas públicas.

Resumen de la clase

Concepto	Definición
Non-Hierarchical Cluster	Métodos que dividen datos en k grupos mediante iteraciones.
k-medoids (PAM)	Método robusto que usa observaciones reales como centros.
Medoide	Observación representativa del cluster.
Silhouette	Medida de calidad de la partición.