

Fundamentos de ciencia de datos con R - Módulo 8

Clase 5: Hierarchical Cluster

CEPAL - Unidad de Estadísticas Sociales

2025-12-09

Introducción

En el módulo anterior exploramos el clustering no jerárquico (como k -medoids), donde el número de grupos (k) se especifica de antemano. Ahora, nos enfocaremos en el **Clustering Jerárquico** (Hierarchical Cluster), una familia de métodos de aprendizaje no supervisado que construye una estructura de clusters anidada, permitiendo visualizar las relaciones entre las observaciones a diferentes niveles de similitud.

¿Por qué usar Clustering Jerárquico?

El clustering jerárquico es útil cuando:

- Se desea entender la estructura inherente de los datos sin pre-especificar k .
- El número óptimo de clusters es desconocido o ambiguo.
- Se necesita una representación visual clara de cómo se agrupan las observaciones (el dendrograma).
- Se trabaja con bases de datos pequeñas a medianas (debido a su mayor costo computacional en comparación con métodos no jerárquicos).

¿Qué es el Hierarchical Cluster?

El clustering jerárquico es un método que organiza los datos en una secuencia de particiones anidadas, representada gráficamente por un dendrograma.

Existen dos enfoques principales para construir esta jerarquía:

1. Enfoque Aglomerativo (Bottom-Up)
2. Enfoque Divisivo (Top-Down)



Idea general

El clustering jerárquico no produce una sola partición, sino **todas las posibles**, desde 1 cluster hasta n clusters, en una estructura anidada.

Comparación: Jerárquico vs. No Jerárquico

Característica	Jerárquico (HAC)	No Jerárquico (k -medoids)
Necesidad de k	No (se decide <i>a posteriori</i> con el dendrograma)	Sí (se debe especificar antes del proceso)
Estructura	Jerárquica (Anidada)	Particional (Plana)
Visualización	Dendrograma (Excelente)	Dispersión (Buena, pero no muestra la relación de fusión)
Costo Computacional	Alto ($O(n^3)$ o $O(n^2)$)	Bajo ($O(k \cdot n \cdot i)$)
Tamaño de Datos	Pequeño a Mediano	Mediano a Grande

Enfoque aglomerativo (Bottom-Up)

El enfoque aglomerativo comienza con cada observación en su propio cluster y, en cada paso, fusiona los dos clusters más similares hasta obtener un solo grupo.

Pasos generales:

1. Iniciar con n clusters (cada observación es un cluster).
2. Calcular la matriz de distancias entre todos los clusters.
3. Fusionar los dos clusters más cercanos.
4. Recalcular distancias entre el nuevo cluster y los restantes.
5. Repetir hasta que todas las observaciones queden en un único cluster.

Resultado

El proceso produce una **historia de fusiones**, que se representa en el dendrograma.

Enfoque divisivo (Top-Down)

El enfoque divisivo comienza con un solo cluster que contiene todas las observaciones y, en cada paso, divide uno de los clusters en dos.

Pasos generales:

1. Iniciar con un único cluster que contiene todas las observaciones.
2. Elegir el cluster a dividir (por ejemplo, el más heterogéneo).
3. Dividirlo en dos subclusters usando algún criterio de partición.
4. Repetir hasta alcanzar el número deseado de clusters o un criterio de parada.

En la práctica, el enfoque aglomerativo es el más utilizado y el que implementa la función `hclust()` en R.

Medidas de distancia

El clustering jerárquico se basa en una **matriz de distancias** entre observaciones. Las más utilizadas son:

- ▶ **Distancia euclidiana**
- ▶ **Distancia Manhattan**
- ▶ **Distancia de Minkowski**



Escala de las variables

Antes de calcular distancias, suele ser necesario **estandarizar** las variables, para que ninguna domine por su escala.

Métodos de enlace (linkage)

La distancia entre clusters se define a través del **método de enlace**:

- ▶ **Single linkage**: distancia mínima entre elementos de dos clusters.
- ▶ **Complete linkage**: distancia máxima entre elementos de dos clusters.
- ▶ **Average linkage**: promedio de todas las distancias entre elementos de los dos clusters.
- ▶ **Ward**: minimiza el incremento en la suma de cuadrados dentro de los clusters.

Elección del método

El método de enlace afecta la forma del dendrograma y la estructura de los clusters; es recomendable comparar varias opciones.

Historia: el análisis de estados

Un equipo de estadística territorial trabajaba con información socioeconómica de los estados:

ingresos, educación, crimen, pobreza, esperanza de vida y otros indicadores.

El objetivo institucional era **construir una tipología oficial de regiones** para apoyar la planificación, pero el equipo enfrentaba un problema:

- ▶ algunos estados eran muy similares entre sí,
- ▶ otros tenían perfiles mixtos,
- ▶ y no estaba claro cuántos grupos debían existir.

Historia: el análisis de estados

Durante una reunión, la directora del área planteó:



Pregunta problema

“¿Existe una forma de entender cómo se agrupan naturalmente los estados sin decidir antes cuántos grupos deben existir?”

El equipo necesitaba una herramienta que no exigiera fijar k desde el inicio y que, además, ofreciera una representación visual clara.

La respuesta fue el **clustering jerárquico**.

Datos: state.x77

Para organizar el análisis, construyeron una base de datos multivariada con varios indicadores.

```
datos_states <- as.data.frame(state.x77)
head(datos_states, 5)
```

	Population	Income	Illiteracy	Life Exp	Murder	HS Grad	Frost	Area
Alabama	3615	3624	2.1	69.05	15.1	41.3	20	50708
Alaska	365	6315	1.5	69.31	11.3	66.7	152	566432
Arizona	2212	4530	1.8	70.55	7.8	58.1	15	113417
Arkansas	2110	3378	1.9	70.66	10.1	39.9	65	51945
California	21198	5114	1.1	71.71	10.3	62.6	20	156361

Estandarización de la base

Primero, estandarizaron todas las variables para evitar que la escala dominara las distancias.

```
datos_scaled <- scale(datos_states)
round(head(datos_scaled, 5), 2)
```

	Population	Income	Illiteracy	Life Exp	Murder	HS Grad	Frost	Area
Alabama	-0.14	-1.32	1.53	-1.36	2.09	-1.46	-1.62	-0.23
Alaska	-0.87	3.06	0.54	-1.17	1.06	1.68	0.91	5.81
Arizona	-0.46	0.15	1.03	-0.24	0.11	0.62	-1.72	0.50
Arkansas	-0.48	-1.72	1.20	-0.16	0.74	-1.64	-0.76	-0.22
California	3.80	1.10	-0.11	0.62	0.79	1.18	-1.62	1.00

Cálculo de distancias y ajuste del clustering

Luego aplicaron **clustering jerárquico aglomerativo** con distancia euclidiana y método de enlace *complete*, porque buscaban grupos relativamente compactos.

```
dist_states <- dist(datos_scaled, method = "euclidean")

modelo_hclust <- hclust(dist_states, method = "complete")
modelo_hclust
```

Call:


```
hclust(d = dist_states, method = "complete")
```

```
Cluster method      : complete
Distance             : euclidean
Number of objects: 50
```

Dendrograma

```
plot(modelo_hclust,  
main = "Dendrograma - Clustering jerárquico",  
xlab = "Estados",  
sub = "")  
abline(h = 5, col = "red", lty = 2) # línea de corte ilustrativa
```

Dendrograma – Clustering jerárquico



Dendrograma

i ¿Qué observó el equipo?

- ▶ **Alaska aparece como un caso atípico**, separándose a una altura muy alta del dendrograma.
- ▶ Un corte alrededor de **h 5** sugiere **tres grupos principales** de estados.
- ▶ Algunas regiones se unen a alturas bajas → **perfiles muy similares**.
- ▶ Otras fusiones ocurren mucho más arriba → **mayores diferencias internas**.

En conjunto, el dendrograma reveló una estructura clara de agrupamiento entre los estados.

Elección del número de clusters

Después de revisar el dendrograma, el equipo decidió cortar en $k = 3$

```
clusters_3 <- cutree(modelo_hclust, k = 3)
table(clusters_3)
```

1	2	3
11	1	38

Luego construyeron perfiles promedio:

```
round(aggregate(datos_states, by = list(Cluster = clusters_3), FUN = mean))
```

Cluster	Population	Income	Illiteracy	Life Exp	Murder	HS Grad	Frost	Area
1	3233.00	3636.09	2.02	69.30	11.41	41.67	67.00	50766.82
2	365.00	6315.00	1.50	69.31	11.30	66.70	152.00	566432.00
3	4641.92	4617.84	0.92	71.38	6.11	56.06	114.05	63471.76

Elección del número de clusters

Conclusión operativa del equipo

Los clusters representaban:

1. Estados con altos ingresos y alta educación
2. 2.3 Estados con mayor criminalidad y menor esperanza de vida

Estados intermedios, con niveles medios en la mayoría de las variables

Por primera vez, el equipo disponía de una tipología clara, reproducible y estadísticamente sustentada, sin subjetividades.

Resumen de la clase

Concepto	Idea clave
Clustering jerárquico	Construye una estructura anidada de clusters representada por un dendrograma.
Enfoque aglomerativo	Parte de n clusters individuales y va fusionando hasta llegar a 1 solo.
Enfoque divisivo	Parte de 1 cluster y lo va dividiendo en subgrupos.
Dendrograma	Muestra visualmente cuándo y cómo se fusionan los clusters.
Métodos de enlace	Reglas para medir distancia entre clusters (single, complete, average, Ward).
Elección de k	Se realiza “cortando” el dendrograma a cierta altura según criterios analíticos y sustantivos.